Universidade de Fortaleza (UNIFOR) · **Centro de Ciências Tecnológicas**
Programa de Pós-Graduação em Informática Aplicada (PPGIA)

A lei de Zipf nas manchas urbanas do Nordeste brasileiro

Cidades definidas pelo *City Clustering Algorithm* sobre o GPW v4, comparadas aos municípios

Thiago de Oliveira Sampaio
Mestrado em Informática Aplicada, pesquisa de dissertação

Resumo. A lei de Zipf afirma que a população da cidade de posto r decai como $S(r) \propto r^{-\alpha}$, com $\alpha = 1$. Testá-la exige uma definição de cidade independente das fronteiras municipais, mas a definição por densidade do *City Clustering Algorithm* (CCA) depende de dois parâmetros livres, o limiar de densidade D^* e a distância de ligação ℓ. Aplicamos o CCA ao raster de população GPW v4 (2020) do Brasil, varremos 15 000 pares (D^*,ℓ) e escolhemos o par em que as 50, 100 e 200 maiores manchas ficam mais próximas de Zipf. Com $D^* = 1\,450\,\text{hab/km}^2$ e $\ell = 1{,}8\,\text{km}$, as 4 702 manchas do país seguem Zipf com precisão notável: α entre 0,99 e 1,00 no topo e $\alpha = 1{,}00 \pm 0{,}04$ na cauda ajustada por máxima verossimilhança. Os municípios do Censo 2022 não seguem ($\alpha = 0{,}91$, lei de potência rejeitada). No Nordeste, com a mesma definição de cidade, a cauda das 1 729 manchas é compatível com Zipf ($\alpha = 0{,}92 \pm 0{,}05$), mas o topo não: as nove maiores manchas são as nove capitais estaduais, maiores do que Zipf prevê, e em nenhum dos pares de parâmetros com ℓ acima da resolução da grade o topo do *ranking* regional se ajusta a Zipf. A lei de Zipf é uma propriedade do sistema urbano nacional que a rede de capitais do Nordeste não reproduz em escala regional.

Palavras-chave: lei de Zipf, *City Clustering Algorithm* (CCA), GPW v4, Nordeste, rede urbana, estimador de Hill.

1 Qual é o problema?

Cidades não são objetos naturalmente delimitados. No Brasil, a população é divulgada por município, e o município é uma unidade política: a metrópole do Recife está repartida entre Recife, Olinda, Jaboatão dos Guararapes e outros municípios, enquanto muitos municípios do sertão somam uma sede pequena e uma grande área rural. Qualquer lei estatística sobre o tamanho das cidades depende, portanto, de uma escolha prévia que normalmente fica implícita.

A **lei de Zipf** [1] é o exemplo canônico dessa dependência. Na forma de posto e tamanho, a população S da cidade de posto r obedece

$$S(r) \;\propto\; r^{-\alpha}, \qquad \alpha = 1, \tag{1}$$

o que equivale a uma densidade $p(x) \propto x^{-\gamma}$ e a uma lei de Pareto $P(X \geq x) \propto x^{-\zeta}$, com $\zeta = \gamma - 1 = 1/\alpha$. Zipf é o caso $\gamma = 2$ dessa família de leis de potência [2]. Para os municípios brasileiros, Moura Jr. e Ribeiro [3] estudaram a lei de Zipf com dados censitários.

Rozenfeld *et al.* [4, 5] mostraram que o expoente medido muda quando as cidades deixam de ser fronteiras legais e passam a ser aglomerados construídos a partir da densidade, e propuseram o *City Clustering Algorithm* (CCA) como essa definição. O mesmo agrupamento entra no estudo de emissões de CO_2 [6] e de mobilidade e criminalidade [7]. O CCA, porém, troca as fronteiras por dois parâmetros: o limiar D^*, acima do qual uma célula é urbana, e a distância ℓ abaixo da qual duas células urbanas pertencem à mesma mancha. Fixá-los por convenção deixa o expoente refém de uma escolha arbitrária.

Este trabalho responde a três perguntas. **(i)** Existe um par (D^*,ℓ) em que as manchas urbanas do Brasil seguem Zipf, e quão sensível é o expoente a essa escolha? **(ii)** Com a mesma definição de cidade, o Nordeste segue Zipf? **(iii)** O que muda quando, em vez de manchas, se usam municípios?

2 O que foi feito

Dados. A população vem do *Gridded Population of the World* v4 (GPW v4, revisão 11) [8], um raster de contagem de pessoas para 2020 com resolução de 30 segundos de arco ($\approx 0{,}93\,\text{km}$), que redistribui os dados censitários numa grade regular. As células fora do Brasil e o pertencimento de cada célula ao Nordeste são definidas pelas malhas do país e das nove unidades da federação do Nordeste, obtidas na API de malhas do IBGE [9]. O recorte tem 215,8 milhões de habitantes, dos quais 59,5 milhões no Nordeste. Para a comparação administrativa, usamos a população dos 5 570 municípios no Censo 2022 [10], dos quais 1 794 no Nordeste.

Definição de cidade (CCA). Uma célula é urbana quando sua densidade supera D^*, com a área da célula corrigida pelo fator cos(lat). Duas células urbanas pertencem à mesma mancha quando a distância haversine, que é uma equação matemática usada para calcular a distância mais curta (distância ortodrômica) entre dois pontos na superfície de uma esfera, considerando a curvatura da Terra, entre os seus centros é menor que ℓ, e a relação é transitiva. O CCA roda sobre o Brasil

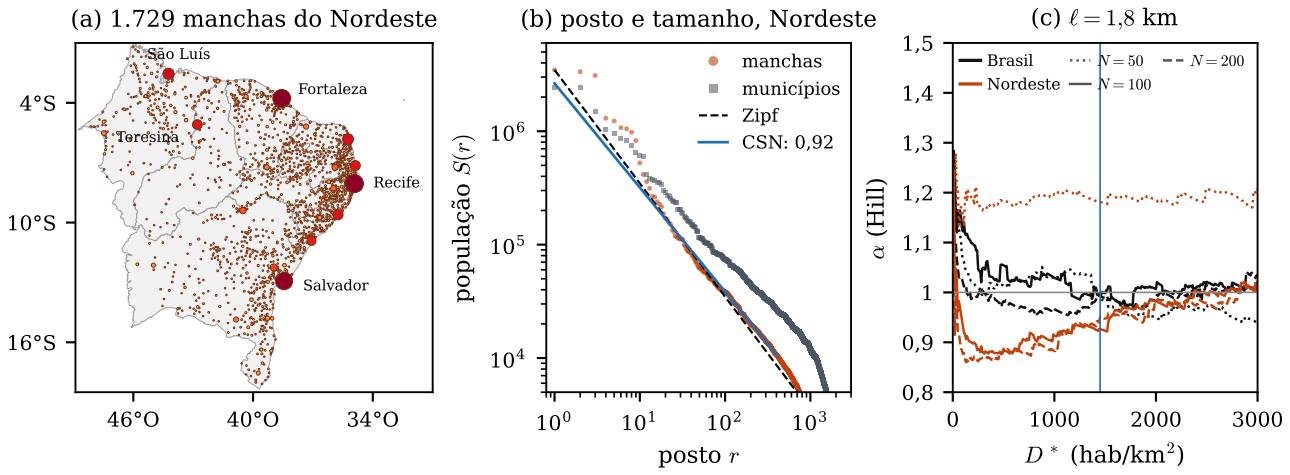


Figura 1: Manchas urbanas do Nordeste e sensibilidade do expoente. **(a)** Centroides das 1 729 manchas do Nordeste no par calibrado para o Brasil ($D^* = 1\,450$ hab/km^2, $\ell = 1{,}8$ km); a área e a cor dos círculos crescem com a população. **(b)** População contra o posto no Nordeste: manchas do CCA (laranja) e municípios do Censo 2022 (cinza). Tracejado: Zipf, S_1/r, com S_1 a maior mancha; reta azul: ajuste de Clauset, Shalizi e Newman das manchas ($x \geq 10\,439$ hab, $n = 414$). **(c)** Expoente de Hill das N maiores manchas contra D^*, com $\ell = 1{,}8$ km, no Brasil (preto) e no Nordeste (laranja); a linha vertical marca o D^* calibrado.

inteiro, e uma mancha é do Nordeste quando a maior parte da sua população está na região. Assim as divisas estaduais não cortam manchas.

Varredura de parâmetros. Varremos $D^* = 10, 20, \ldots, 3\,000$ hab/km^2 e $\ell = 100, 200, \ldots, 5\,000$ m, num total de 15 000 pares. Com ℓ fixo, as células urbanas para um limiar contêm as de qualquer limiar maior. As células são então ativadas em ordem decrescente de densidade e unidas, por uma estrutura de união e busca [11], às vizinhas já ativas a menos de ℓ. Quando a densidade cruza um valor da grade, as manchas presentes são exatamente as do CCA com aquele D^*, e uma única passada por ℓ produz os 300 limiares. Como conferência, com $\ell = 1{,}4$ km o CCA no Brasil equivale à rotulagem com vizinhança de 8 células, e as duas dão as mesmas 6 088 manchas para $D^* = 1\,000$ hab/km^2.

Expoente e critério. Em cada par, o expoente das N maiores manchas é estimado pelo método de Hill [12], $\hat{\alpha}_N = \frac{1}{N-1}\sum_{i \leq N} \ln(S_i/S_N)$, para $N = 50$, 100 e 200. Se as manchas seguem Zipf, $\hat{\alpha}_N \approx 1$ para qualquer N. O par escolhido minimiza o pior desvio, $\Delta = \max_N |\hat{\alpha}_N - 1|$, entre os pares com $\ell \geq \ell_{\min} = 1{,}4$ km. Abaixo da diagonal entre centros de células vizinhas ($\approx 1{,}3$ km), o CCA deixa de ligar células adjacentes e produz manchas fragmentadas pela própria grade.

Ajuste da cauda. A cauda é ajustada pelo método de Clauset, Shalizi e Newman (CSN) [13]: γ por máxima verossimilhança no ramo $x \geq x_{\min}$, $x_{\min}$ pela menor distância de Kolmogorov–Smirnov (KS) e bondade de ajuste por *bootstrap* com 200 réplicas, em que $p > 0{,}1$ significa que a lei de potência **não é rejeitada**. A lei de potência é comparada às alternativas lognormal, exponencial e truncada pela razão de verossimilhança de Vuong [14, 15].

3 Resultados e conclusões

Brasil: Zipf nas manchas, não nos municípios. O par calibrado é $D^* = 1\,450$ hab/km^2 e $\ell = 1{,}8$ km, com $\hat{\alpha}_{50} = 0{,}99$, $\hat{\alpha}_{100} = 1{,}00$, $\hat{\alpha}_{200} = 1{,}00$ e $\Delta = 0{,}007$. As 4 702 manchas somam 151 milhões de habitantes, 70% da população. A escolha é pouco sensível: 5 566 dos 11 100 pares com $\ell \geq \ell_{\min}$ têm $\Delta < 0{,}10$, com D^* de 90 a 3 000 hab/km^2, e $\hat{\alpha}_{100}$ fica entre 0,96 e 1,33 em toda essa parte da grade (Fig. 1c, em preto). O ajuste CSN escolhe $x_{\min} = 28\,777$ habitantes ($n = 596$) e dá $\alpha = 1{,}00 \pm 0{,}04$, com KS = 0,021 abaixo do valor crítico de 0,056 e $p = 0{,}47$. A lei de potência é muito melhor que a exponencial ($R = 4{,}5$, $p < 10^{-5}$) e não se distingue da lognormal nem da truncada ($p = 0{,}99$ e 0,48). São Paulo (20,0 M) e Rio de Janeiro (8,9 M) estão na razão de 0,45, perto do 0,5 de Zipf. Os 5 570 municípios dão outro resultado: $\alpha = 0{,}91 \pm 0{,}02$ na cauda ($x_{\min} = 22\,393$), com $p = 0{,}045$, o que **rejeita** a lei de potência, e um topo achatado, com $\hat{\alpha}_{50} = 0{,}70$.

Nordeste: a cauda segue Zipf, o topo não. Com a definição nacional de cidade, o Nordeste tem 1 729 manchas, que somam 35,5 milhões de habitantes, 60% da população da região (Fig. 1a). A cauda é compatível com Zipf: o ajuste CSN dá $\alpha = 0{,}92 \pm 0{,}05$ acima de $x_{\min} = 10\,439$ habitantes ($n = 414$), com KS = 0,026 abaixo do crítico de 0,067 e $p = 0{,}45$. O topo, porém, não segue (Fig. 1b). As nove maiores manchas são as nove capitais estaduais: Recife (3,47 M), Fortaleza (3,35 M) e Salvador (3,10 M), quase empatadas, e depois São Luís (1,30 M), Natal (1,23 M), Maceió (1,07 M), João Pessoa (1,05 M), Teresina (0,98 M) e Aracaju (0,83 M). Zipf daria à segunda mancha metade da primeira, e não 97%, e à nona 0,39 M, menos da metade de Aracaju. O primeiro centro não capital, Feira de Santana (0,53 M), vem só em décimo. Esse degrau aparece no estimador: $\hat{\alpha}_{50} = 1{,}18$, contra $\hat{\alpha}_{100} = 0{,}93$ e $\hat{\alpha}_{200} = 0{,}95$. O

degrau não depende da definição de cidade: em todos os 11 100 pares com $\ell \geq \ell_{\min}$, $\hat{\alpha}_{50}$ do Nordeste fica entre 1,07 e 1,34 (Fig. 1c, em laranja). A calibração feita só com o Nordeste confirma isso: o melhor par ($D^* = 110\,\mathrm{hab/km^2}$, $\ell = 3{,}4\,\mathrm{km}$) ainda tem $\Delta = 0{,}07$ e põe 81% da população da região em manchas, o que indica que o limiar já inclui ocupação não urbana.

Manchas e municípios. A diferença entre as duas definições é maior nas metrópoles. A mancha do Recife tem 3,47 milhões de habitantes e o município, 1,49 milhão: no *ranking* municipal, Recife é o terceiro do Nordeste, atrás de Fortaleza e Salvador; no de manchas, é o primeiro. Na cauda, os 1 794 municípios dão $\alpha = 0{,}74 \pm 0{,}03$, bem abaixo de 1, o que é esperado quando municípios grandes em área agregam sede e zona rural.

Limitações. O GPW de 2020 é uma extrapolação dos censos de 2010, e soma 59,5 milhões no Nordeste contra 54,7 milhões no Censo 2022; a comparação entre manchas e municípios mistura, portanto, duas fontes e dois anos. A resolução de $\approx 1\,\mathrm{km}$ limita ℓ por baixo. O critério Δ é uma escolha: outro conjunto de N moveria o par calibrado dentro da ampla região de Δ pequeno, sem mudar as conclusões, que valem em toda a grade. A análise usa um único ano e não diz nada sobre a dinâmica de crescimento.

Conclusão. Com cidades definidas pela densidade, o Brasil segue a lei de Zipf com precisão, em uma ampla faixa de parâmetros; com cidades definidas por municípios, não segue. O Nordeste segue Zipf nas cidades médias e pequenas, mas não no topo: sua rede urbana é organizada em torno das nove capitais estaduais, maiores do que Zipf prevê e com três metrópoles de porte semelhante. A lei de Zipf é, assim, uma propriedade do sistema urbano nacional, em que essas capitais ocupam posições intermediárias, e não de cada região.

Referências

[1] George K. Zipf. *Human Behavior and the Principle of Least Effort*. Addison-Wesley, 1949.

[2] M. E. J. Newman. Power laws, Pareto distributions and Zipf's law. *Contemporary Physics*, 46(5):323–351, 2005.

[3] Newton J. Moura, Jr. and Marcelo B. Ribeiro. Zipf law for Brazilian cities. *Physica A: Statistical Mechanics and its Applications*, 367:441–448, 2006.

[4] Hernán D. Rozenfeld, Diego Rybski, José S. Andrade, Jr., Michael Batty, H. Eugene Stanley, and Hernán A. Makse. Laws of population growth. *Proceedings of the National Academy of Sciences*, 105(48):18702–18707, 2008.

[5] Hernán D. Rozenfeld, Diego Rybski, Xavier Gabaix, and Hernán A. Makse. The area and population of cities: New insights from a different perspective on cities. *American Economic Review*, 101(5):2205–2225, 2011.

[6] Erneson A. Oliveira, José S. Andrade, Jr., and Hernán A. Makse. Large cities are less green. *Scientific Reports*, 4:4235, 2014.

[7] Carlos Caminha, Vasco Furtado, Tarcisio H. C. Pequeno, Caio Ponte, Hygor P. M. Melo, Erneson A. Oliveira, and José S. Andrade, Jr. Human mobility in large cities as a proxy for crime. *PLOS ONE*, 12(2):e0171609, 2017.

[8] Center for International Earth Science Information Network (CIESIN). Gridded population of the world, version 4 (gpwv4): Population count, revision 11. NASA Socioeconomic Data and Applications Center (SEDAC), 2018.

[9] Instituto Brasileiro de Geografia e Estatística (IBGE). API de malhas geográficas, versão 3. https://servicodados.ibge.gov.br/api/docs/malhas?versao=3, 2024.

[10] Instituto Brasileiro de Geografia e Estatística (IBGE). Censo demográfico 2022: população residente por município, tabela 4709 do SIDRA. https://sidra.ibge.gov.br/tabela/4709, 2023.

[11] Robert Endre Tarjan. Efficiency of a good but not linear set union algorithm. *Journal of the ACM*, 22(2):215–225, 1975.

[12] Bruce M. Hill. A simple general approach to inference about the tail of a distribution. *The Annals of Statistics*, 3(5):1163–1174, 1975.

[13] Aaron Clauset, Cosma Rohilla Shalizi, and M. E. J. Newman. Power-law distributions in empirical data. *SIAM Review*, 51(4):661–703, 2009.

[14] Quang H. Vuong. Likelihood ratio tests for model selection and non-nested hypotheses. *Econometrica*, 57(2):307–333, 1989.

[15] Jeff Alstott, Ed Bullmore, and Dietmar Plenz. powerlaw: a Python package for analysis of heavy-tailed distributions. *PLoS ONE*, 9(1):e85777, 2014.