Universidade de Fortaleza (UNIFOR) · **Centro de Ciências Tecnológicas**
Programa de Pós-Graduação em Informática Aplicada (PPGIA)

A lei de Pareto nas manchas urbanas dos Estados Unidos

Cidades definidas por agrupamento de densidade populacional (CCA) sobre o GPW v4

Thiago de Oliveira Sampaio
Mestrado em Informática Aplicada, pesquisa de dissertação

Resumo. A lei de Zipf afirma que a população da cidade de posto r decai como $S(r) \propto r^{-\alpha}$, com $\alpha \approx 1$. Esse enunciado é o caso particular $\zeta = 1$ da lei de Pareto, na qual a probabilidade de uma cidade superar o tamanho x decai como $P(X \geq x) \propto x^{-\zeta}$, com $\zeta = 1/\alpha$. Testar as duas exige uma definição de cidade que não dependa de fronteiras administrativas. Aplicamos o *City Clustering Algorithm* (CCA) ao raster de população GPW v4 (2020) dos Estados Unidos contíguos, obtivemos 8 401 manchas urbanas e ajustamos a cauda pelo método de máxima verossimilhança de Clauset, Shalizi e Newman. A lei de Pareto não é rejeitada (KS $= 0{,}014$; $p = 0{,}74$; $n = 1\,780$ manchas na cauda), com expoente $\zeta = 0{,}72 \pm 0{,}02$, equivalente a $\alpha = 1{,}40 \pm 0{,}03$. O valor fica distante de $\zeta = 1$. Mostramos ainda que α cresce de forma monótona com o parâmetro de aglutinação ℓ do CCA: o expoente mede a distribuição de população e, ao mesmo tempo, a definição de cidade adotada.

Palavras-chave: lei de Pareto, lei de Zipf, *City Clustering Algorithm* (CCA), GPW v4, manchas urbanas.

1 Qual é o problema?

Cidades não são objetos naturalmente delimitados. Os dados oficiais de população vêm agregados por unidades administrativas (municípios, *counties*, setores censitários) cujas fronteiras foram traçadas por motivos históricos e políticos, não pela forma da ocupação humana. Uma região metropolitana contínua pode estar repartida em dezenas de municípios, e um município grande pode conter vasta área rural. Qualquer lei estatística sobre o tamanho das cidades depende, portanto, de uma escolha prévia que normalmente fica implícita.

A **lei de Zipf** [1] é o exemplo canônico dessa dependência. Na forma de posto e tamanho, a população S da cidade de posto r obedece

$$S(r) \;\propto\; r^{-\alpha}, \qquad \alpha \approx 1, \tag{1}$$

o que equivale a uma densidade $p(x) \propto x^{-\gamma}$. Os expoentes se ligam por

$$\zeta = \gamma - 1, \qquad \alpha = \frac{1}{\zeta}. \tag{2}$$

Assim, $\alpha = 1$ exatamente quando $\zeta = 1$ e $\gamma = 2$. Aqui ζ é o expoente da **lei de Pareto**: a probabilidade de uma mancha ter população pelo menos x cai como $P(X \geq x) \propto x^{-\zeta}$. Lei de potência, distribuição de Pareto e lei de Zipf são a mesma família vista por expoentes diferentes, e Zipf é somente o caso $\zeta = 1$ [2].

Rozenfeld *et al.* [3, 4] mostraram que o expoente medido muda quando as cidades deixam de ser fronteiras legais e passam a ser aglomerados construídos a partir da densidade, e propuseram o *City Clustering Algorithm* (CCA) como essa definição. O mesmo agrupamento entra no estudo de emissões de CO_2 [5] e de mobilidade e criminalidade [6].

Este trabalho responde a duas perguntas. **(i)** As manchas urbanas produzidas pelo CCA sobre um raster global de população seguem a lei de Pareto e, se seguem, o expoente é o de Zipf ($\zeta = 1$)? **(ii)** Quanto de ζ (ou de α) é propriedade dos dados e quanto é artefato dos parâmetros que definem o que conta como cidade?

2 O que foi feito

Dados. Usamos o *Gridded Population of the World* v4 (GPW v4, revisão 11) [7], um raster global de contagem de pessoas por pixel para o ano de 2020, com resolução de 30 segundos de arco (≈ 1 km). O produto redistribui dados censitários numa grade regular, e por isso a análise não parte de fronteiras administrativas. O recorte é a caixa $[-125{,}0;\ -66{,}9] \times [24{,}5;\ 49{,}5]$, que cobre os Estados Unidos contíguos.

Definição de cidade (CCA). Um pixel é urbano quando sua densidade supera o limiar D^*. Pixels urbanos próximos entram na mesma mancha. A implementação é uma dilatação binária de $\lceil \ell/\Delta x \rceil - 1$ pixels ($\Delta x \approx 928$ m é o lado do pixel), seguida da rotulagem dos componentes conexos. Como as duas manchas crescem na dilatação, o vão fechado é de cerca de 2ℓ. Com $\ell = 3$ km, isso chega a aproximadamente 5,6 km. A Fig. 1c varia, portanto, o parâmetro nominal ℓ. A população de cada mancha soma apenas os pixels densos, para que o halo da dilatação não infle a contagem. Adotamos $D^* = 386$ hab/km^2, o limiar oficial de área urbana do U.S. Census Bureau (1 000 hab/milha^2) [8] convertido para km^2, e $\ell = 3$ km. Como a área de um pixel em graus diminui com a latitude, o limiar em hab/km^2 é convertido para hab/pixel linha a linha pelo fator cos(lat). A correção importa numa janela de 25 graus de latitude.

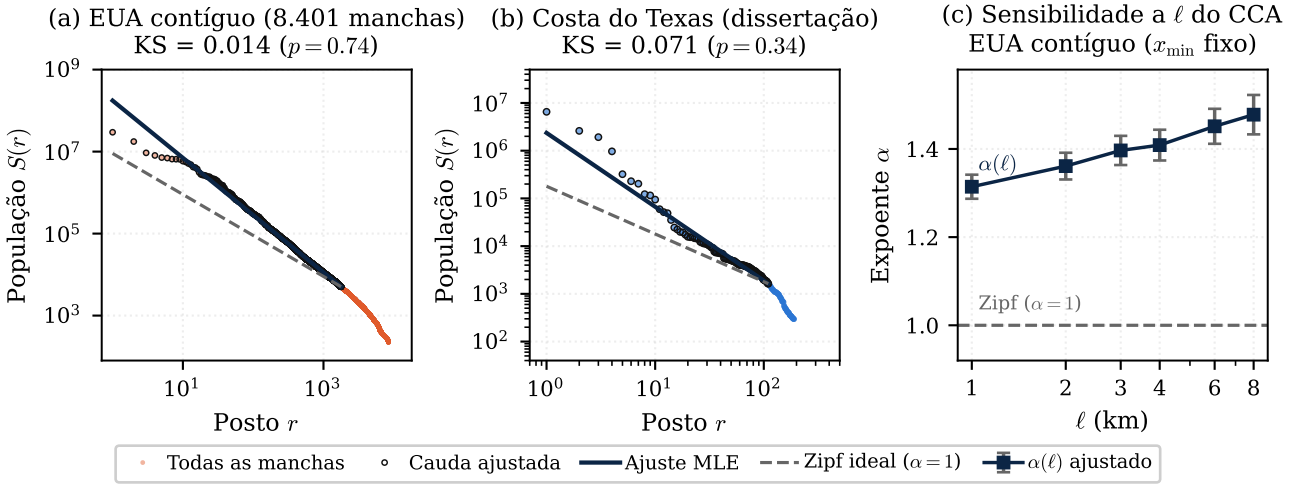


Figura 1: Posto e tamanho, e sensibilidade do CCA. (a) População contra o posto das 8 401 manchas urbanas dos EUA contíguos ($D^* = 386\,\text{hab/km}^2$, $\ell = 3\,\text{km}$). Pontos cheios: todas as manchas; círculos abertos: cauda ajustada ($x \geq 5\,061\,\text{hab}$, $n = 1\,780$); linha azul escura: máxima verossimilhança ($\alpha = 1{,}40 \pm 0{,}03$, isto é $\zeta = 0{,}72$, KS $= 0{,}014$, $p = 0{,}74$); tracejado: lei de Zipf ($\zeta = 1$). **(b)** Recorte costeiro do Texas (190 manchas; cauda com $n = 110$; $\alpha = 1{,}55 \pm 0{,}15$): a janela menor perde poder estatístico. **(c)** α sobe de 1,31 a 1,48 quando ℓ aumenta, com $x_{\min}$ fixo.

Filtro de fronteira. A caixa de recorte é geográfica, não política: inclui o norte do México e o sul de Ontário. Sem tratamento, Monterrey (8,7 M) e Toronto (7,1 M) apareceriam entre as dez maiores manchas do recorte. Manchas cujo centroide cai nessas duas regiões são descartadas (579 de 8 980, com $\ell = 3\,\text{km}$). O corte norte segue o Lago Ontário (43,35°N) e preserva Detroit, Buffalo, Rochester e Syracuse do lado americano.

Ajuste estatístico. Uma reta em escala logarítmica dupla é um estimador enviesado do expoente de uma lei de potência. Seguimos o procedimento de Clauset, Shalizi e Newman [9]: γ é estimado por máxima verossimilhança no ramo $x \geq x_{\min}$; $x_{\min}$ é escolhido de modo a minimizar a distância de Kolmogorov e Smirnov (KS) entre as distribuições acumuladas empírica e teórica, em vez de ser fixado no piso que o próprio D^* impõe, o que seria um corte artificial; a bondade do ajuste é medida por *bootstrap* semiparamétrico, em que p é a fração de amostras sintéticas de lei de Pareto cuja distância KS supera a observada. Nessa convenção, $p > 0{,}1$ significa que a hipótese **não é rejeitada**. O expoente α da Eq. (1) sai de γ pela Eq. (2).

3 Resultados e conclusões

O CCA identifica 8 401 manchas urbanas[1], que concentram 273,7 milhões de habitantes, 69% da população do recorte. As dez maiores correspondem, sem nenhuma lista de nomes fornecida ao algoritmo, às aglomerações esperadas: Nova York (29,6 M), Los Angeles (17,6 M), Chicago (9,3 M), Washington e Baltimore (8,1 M), Miami e Fort Lauderdale (7,2 M), Dallas e Fort Worth (7,0 M), São Francisco e San Jose (6,6 M), Houston (6,5 M), Tampa e Orlando (6,5 M) e Boston (5,8 M). Os centroides caem a 0,2° ou menos dos centros reais dessas cidades, o que valida o agrupamento. Várias delas são conurbações que o CCA funde numa única mancha, porque a ocupação densa é contínua entre os núcleos. É isso que separa esta definição das fronteiras administrativas.

O ajuste da Fig. 1a dá $\gamma = 1{,}716 \pm 0{,}017$, isto é,

$$\zeta = 0{,}716 \pm 0{,}017, \qquad \alpha = 1{,}40 \pm 0{,}03, \tag{3}$$

sobre uma cauda de $n = 1\,780$ manchas acima de $x_{\min} = 5\,061$ habitantes. A distância KS observada, 0,014, fica abaixo do valor crítico $1{,}36/\sqrt{n} = 0{,}032$, e o *bootstrap* devolve $p = 0{,}74$. A lei de Pareto descreve bem a cauda. A máxima verossimilhança e a regressão em escala logarítmica dupla concordam (1,40 e 1,39).

A lei ajustada é a de Pareto, com $\zeta \approx 0{,}72$. A lei de Zipf exigiria $\zeta = 1$. A barra $\pm 0{,}017$ é a incerteza do ajuste com (D^*, ℓ) fixos. A incerteza que vem da definição de cidade é maior. Com $x_{\min}$ fixo, para que a variação não venha do deslocamento da janela, a Fig. 1c mostra α subindo de 1,31 ($\ell = 1\,\text{km}$) a 1,48 ($\ell = 8\,\text{km}$), ou seja, ζ entre 0,68 e 0,76. Nenhum ponto dessa faixa chega a $\zeta = 1$. A incompatibilidade com Zipf se mantém em toda a varredura de (D^*, ℓ). Aumentar ℓ funde vizinhos numa mancha maior e encurta a cauda, de modo que o expoente é propriedade conjunta dos dados e da definição operacional de cidade. Relatar um expoente sem relatar (D^*, ℓ) deixa o resultado incompleto.

Com $\alpha = 1{,}40$, a mancha de posto 2 tem cerca de $2^{-1{,}40} \approx 38\%$ da população da de posto 1. Na lei de Zipf, essa razão seria a metade. A cauda com $\zeta < 1$ é mais pesada que a de Zipf, e as maiores manchas são mais dominantes. Rozenfeld *et al.* [3] já tinham observado o mesmo efeito: o expoente depende da definição de cidade, e a definição por densidade não recupera $\zeta = 1$.

[1] O *notebook* pode devolver 8 403: o filtro de fronteira usa o centroide da mancha, e o arredondamento desse centroide, inferior a um pixel, reclassifica duas manchas minúsculas junto à divisa. Nenhum valor ajustado muda.

Referências

[1] George K. Zipf. Human behavior and the principle of least effort. 1949.

[2] M. E. J. Newman. Power laws, Pareto distributions and Zipf's law. *Contemporary Physics*, 46(5):323–351, 2005.

[3] Hernán D. Rozenfeld, Diego Rybski, Xavier Gabaix, and Hernán A. Makse. The area and population of cities: New insights from a different perspective on cities. *American Economic Review*, 101(5):2205–2225, 2011.

[4] Hernán D. Rozenfeld, Diego Rybski, José S. Andrade, Michael Batty, H. Eugene Stanley, and Hernán A. Makse. Laws of population growth. *Proceedings of the National Academy of Sciences*, 105(48):18702–18707, 2008.

[5] Erneson A. Oliveira, José S. Andrade, and Hernán A. Makse. Large cities are less green. *Scientific Reports*, 4:4235, 2014.

[6] Carlos Caminha, Vasco Furtado, Tarcisio H. C. Pequeno, Caio Ponte, Hygor P. M. Melo, Erneson A. Oliveira, and José S. Andrade. Human mobility in large cities as a proxy for crime. *PLOS ONE*, 12(2):e0171609, 2017.

[7] Center for International Earth Science Information Network (CIESIN). Gridded population of the world, version 4 (gpwv4): Population count, revision 11. NASA Socioeconomic Data and Applications Center (SEDAC), 2018.

[8] U.S. Census Bureau. Urban area criteria for the 2020 census. Federal Register, v.87, n.57, p.16706–16715, 2022.

[9] Aaron Clauset, Cosma Rohilla Shalizi, and M. E. J. Newman. Power-law distributions in empirical data. *SIAM Review*, 51(4):661–703, 2009.