Universidade de Fortaleza (UNIFOR) · Centro de Ciências Tecnológicas
Programa de Pós-Graduação em Informática Aplicada (PPGIA)

A lei de Zipf nas manchas urbanas do Nordeste brasileiro

Cidades definidas pelo *City Clustering Algorithm* sobre o GPW v4, comparadas aos municípios

Thiago de Oliveira Sampaio
Mestrado em Informática Aplicada, pesquisa de dissertação

Resumo. A lei de Zipf estabelece que a população $S(r)$ da cidade de posto r decai como $S(r) \propto r^{-\alpha}$, com $\alpha = 1$. Testá-la com rigor exige definir os limites urbanos de forma contínua, sem depender de divisas político-administrativas arbitrárias. Neste trabalho, foi aplicado o *City Clustering Algorithm* (CCA) à grade de contagem populacional do *Gridded Population of the World* (GPW v4, rev. 11, ano-base 2020) em todo o Brasil. A densidade demográfica de cada célula é obtida dividindo sua população pela área geodésica exata na esfera terrestre, calculada pela composição de dois triângulos esféricos via Teorema de L'Huilier e fórmula de Haversine. Foi executada uma varredura de 15 000 pares (D^*,ℓ), limiar de densidade D^* e distância de conectividade ℓ, calibrando o modelo pela aderência a Zipf ($\alpha \approx 1$) no topo da hierarquia urbana (estimador de Hill e regressão linear com $R^2_{\mathrm{OLS}} \geq 0{,}80$). No par ótimo nacional ($D^* = 1\,450\,\mathrm{hab/km^2}$, $\ell = 1{,}8\,\mathrm{km}$), as 4 702 manchas do país seguem Zipf com notável exatidão: $\hat{\alpha}_{100} = 1{,}00$ ($R^2_{\mathrm{OLS}} = 0{,}99$) no topo e $\alpha_{\mathrm{CSN}} = 1{,}00 \pm 0{,}04$ na cauda ajustada por máxima verossimilhança ($p = 0{,}47$). Em contrapartida, os 5 570 municípios do Censo 2022 rejeitam a hipótese de lei de potência ($p = 0{,}045$). No Nordeste, sob a calibração nacional (1 729 manchas), a cauda obedece a Zipf ($\alpha = 0{,}92 \pm 0{,}05$, $p = 0{,}45$), mas o topo rompe a hierarquia ($\hat{\alpha}_{50} = 1{,}18$): as nove capitais estaduais concentram populações equiparáveis em um patamar policêntrico achatado. Evidencia-se que a lei de Zipf emerge na rede urbana nacional integrada, mas não se auto-organiza de forma isolada dentro dos subsistemas federativos.

Palavras-chave: lei de Zipf, *City Clustering Algorithm* (CCA), GPW v4, triângulos esféricos (L'Huilier), Nordeste, redes urbanas.

1 Qual é o problema?

Cidades reais não terminam nas placas de limite municipal. No Brasil, porém, os dados demográficos oficiais adotam o município como recorte básico, gerando duas distorções opostas. Por um lado, grandes metrópoles conurbadas, como a Região Metropolitana de Fortaleza e Recife, fragmentam-se em vários municípios muito próximos. De outro, municípios do interior somam uma pequena sede urbana a vastos territórios rurais. Assim, inferências estatísticas sobre o tamanho das cidades tornam-se reféns da divisão política adotada.

A **lei de Zipf** [1] ilustra bem essa sensibilidade. Ordenando as cidades da maior ($r = 1$) para a menor, a população $S(r)$ da cidade de posto (*rank*) r decai segundo:

$$S(r) \;\propto\; r^{-\alpha}, \qquad \alpha = 1, \tag{1}$$

equivalendo a uma densidade de probabilidade $p(x) \propto x^{-\gamma}$ e a uma cauda complementar de Pareto $P(X \geq x) \propto x^{-\zeta}$, com $\zeta = \gamma - 1 = 1/\alpha$. O expoente $\alpha = 1$ ($\gamma = 2$) caracteriza invariância de escala em redes complexas [2]. Em municípios brasileiros, Moura Jr. e Ribeiro [3] reportaram distorções atribuídas justamente às divisas legais.

Para superar limites administrativos, Rozenfeld *et al.* [4, 5] propuseram o *City Clustering Algorithm* (CCA), que delimita aglomerações diretamente sobre grades contínuas de densidade populacional. O método embasa análises alométricas de emissões de CO_2 [6], mobilidade e criminalidade [7] e fronteiras globais de cidades [8]. O CCA possui dois parâmetros livres: o limiar de densidade D^* (que define células urbanas) e o comprimento de enlace ℓ (que agrupa células urbanas próximas). Fixá-los arbitrariamente compromete a generalidade das conclusões.

Este artigo responde a três perguntas: **(i)** É possível calibrar (D^*,ℓ) a partir dos próprios dados demográficos para que as manchas do Brasil sigam Zipf, e quão estável é esse ajuste? **(ii)** Sob a calibração nacional ou regional, o Nordeste reproduz a lei de Zipf? **(iii)** Que distorções surgem ao confrontar manchas morfológicas do CCA e municípios do Censo 2022?

2 O que foi feito (Metodologia)

Dados em grade e malhas oficiais. Utilizamos o raster de contagem populacional do *Gridded Population of the World* v4 (rev. 11, ano-base 2020) [9], disponibilizado pelo CIESIN/NASA em grade regular de 30″ de arco ($\approx 0{,}93\,\mathrm{km}$ no equador). Os recortes do Brasil e das nove unidades federativas do Nordeste foram extraídos da API de malhas do IBGE [10], somando 215,8 milhões de habitantes no país e 59,5 milhões no Nordeste no GPW v4. Para a comparação administrativa, utilizamos a população residente dos 5 570 municípios (1 794 no Nordeste) do Censo Demográfico 2022 [11].

Área por triângulos esféricos (L'Huilier). Para eliminar distorções latitudinais ao longo do território nacional, a área exata A_i de cada célula (sítio i) na esfera terrestre ($R = 6\,378{,}137\,\mathrm{km}$) é calculada subdividindo o quadrilátero esférico do pixel em dois triângulos esféricos [12]. Os lados geodésicos (a, b, c) são obtidos pela fórmula de Haversine e a área de cada triângulo esférico é dada pelo **Teorema de L'Huilier** [12]:

$$A_{\triangle} = 4R^2 \arctan \sqrt{\tan\frac{s}{2}\,\tan\frac{s_a}{2}\,\tan\frac{s_b}{2}\,\tan\frac{s_c}{2}}, \tag{2}$$

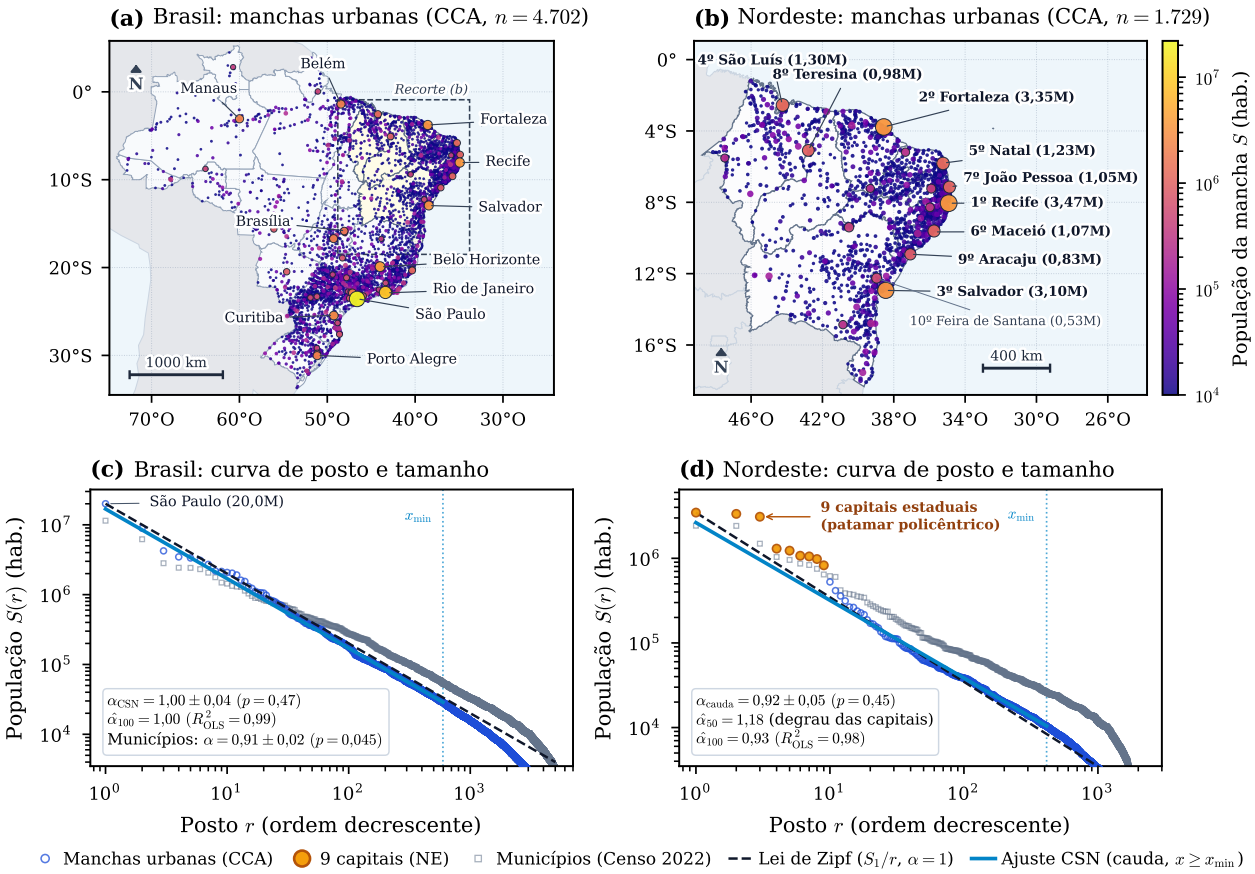


Figura 1: Manchas urbanas delimitadas pelo CCA e leis de escala no Brasil e no Nordeste. **(a)** Centroides ponderados por população das 4 702 manchas urbanas do Brasil no par calibrado ($D^* = 1\,450$ hab/km^2, $\ell = 1{,}8$ km), em escala logarítmica *plasma* e área proporcional à população; o quadro tracejado indica o recorte nordestino. **(b)** Recorte com as 1 729 manchas do Nordeste na mesma escala cromática, destacando as nove capitais estaduais (1° ao 9° posto) e a maior cidade do interior (10° Feira de Santana). **(c)** Curva de posto e tamanho para o Brasil: manchas do CCA (círculos azuis), municípios do Censo 2022 (quadrados cinzas), lei de Zipf (S_1/r, tracejado preto) e ajuste de cauda de Clauset–Shalizi–Newman (CSN, linha contínua azul, $x \geq 28\,777$ hab, $n = 596$). **(d)** Curva de posto e tamanho para o Nordeste: cauda em lei de potência ($\alpha_{\text{cauda}} = 0{,}92 \pm 0{,}05$, $p = 0{,}45$) e patamar policêntrico das nove capitais no topo (círculos âmbar, $\hat{\alpha}_{50} = 1{,}18$).

com $s = (a + b + c)/2$ e $s_k = s - k$. A densidade demográfica de cada célula é definida exatamente por $D_i = P_i/A_i$, onde P_i é a população do pixel.

Delimitação morfológica de cidades (CCA). Pelo *City Clustering Algorithm* [4, 6, 8], uma célula é ativada como urbana se $D_i > D^*$. Duas células urbanas pertencem à mesma mancha (*cluster*) quando a distância ortodrômica de Haversine entre seus centroides é estritamente menor que ℓ ($d_{ij} < \ell$), propagando-se a conectividade de forma transitiva (percolação por queima ou *burning*). A população de cada mancha é a soma conservativa de suas células ($S_k = \sum_{i \in k} P_i$) e sua posição é dada pelo centroide ponderado pela população. O CCA é executado sobre a malha contínua de todo o Brasil; uma mancha pertence ao Nordeste quando mais de 50% de sua população situa-se na região, evitando que divisas estaduais cortem conurbações.

Varredura paramétrica e calibração por Zipf. Seguindo o protocolo de calibração via lei de Zipf [8], varremos uma grade bidimensional de 15 000 pares: $D^* \in [10, 3\,000]$ hab/km^2 (passo de 10 hab/km^2) e $\ell \in [0{,}1, 5{,}0]$ km (passo de 0,1 km). Como as células ativas num limiar maior estão contidas nas de um limiar menor para ℓ fixo, ordenamos os pixels decrescentemente por densidade e atualizamos os aglomerados via estrutura *union-find* com compressão de caminho [13], processando os 300 limiares de D^* em uma única passagem por ℓ.

Para cada par (D^*,ℓ), avaliamos a aderência do topo à lei de Zipf combinando: **(a)** regressão linear ordinária (OLS) na relação $\log_{10} S(r) = \log_{10} S_1 - \alpha_{\text{OLS}} \log_{10} r$ para as 100 maiores manchas ($R^2_{\text{OLS}} \geq 0{,}80$); e **(b)** o estimador de máxima verossimilhança de Hill [14], $\hat{\alpha}_N = [\frac{1}{N-1} \sum_{i=1}^{N-1} \ln(S_i/S_N)]^{-1}$, nos recortes $N \in \{50, 100, 200\}$. Seleciona-se o par que minimiza o pior desvio $\Delta = \max_N |\hat{\alpha}_N - 1|$ sob a restrição geométrica $\ell \geq \ell_{\min} = 1{,}4$ km (acima da diagonal de $\approx 1{,}31$ km entre células vizinhas no equador, garantindo vizinhança-8). Avaliamos tanto o par nacional aplicado ao Nordeste quanto a calibração independente exclusiva da região.

3 Resultados e discussões

Brasil: Zipf nas manchas, rejeição nos municípios. A varredura revela uma ampla região compatível com Zipf: dos 11 100 pares com $\ell \geq 1{,}4$ km, 5 566 apresentam $\Delta < 0{,}10$ (D^* entre 90 e 3 000 hab/km^2). Pelas análises, par ótimo nacional é $D^* = 1\,450$ hab/km^2 e $\ell = 1{,}8$ km. As 4 702 manchas delimitadas no país (Fig. 1a) reúnem 151,0 milhões de habitantes (70,0% da população nacional).

Na curva nacional de posto e tamanho (Fig. 1c), o teste CSN confirma a distribuição livre de escala: para $x_{\min} = 28\,777$ hab ($n = 596$), obtém-se $\alpha_{\mathrm{CSN}} = 1{,}00 \pm 0{,}04$, com $\mathrm{KS} = 0{,}021 < 0{,}056$ e $p = 0{,}47$. A lei de potência supera amplamente a exponencial ($R = 4{,}54$, $p < 10^{-5}$) e é indistinguível da lognormal ($p = 0{,}99$) e da truncada ($p = 0{,}48$). As manchas de São Paulo (20,0 M) e Rio de Janeiro (8,9 M) exibem razão 0,45, próxima do valor teórico 0,50. Já os 5 570 municípios do Censo 2022 resultam em $\alpha = 0{,}91 \pm 0{,}02$ na cauda ($x_{\min} = 22\,393$ hab) com $p = 0{,}045 < 0{,}10$, o que **rejeita formalmente a lei de potência**, além de forte truncamento no topo ($\hat{\alpha}_{50} = 0{,}70$).

Nordeste: cauda livre de escala e topo policêntrico. No par calibrado nacionalmente, o Nordeste contém 1 729 manchas urbanas (35,5 milhões de pessoas, 59,8% da região, Fig. 1b). A cauda segue Zipf: o ajuste CSN identifica $x_{\min} = 10\,439$ hab ($n = 414$), resultando em $\alpha_{\mathrm{cauda}} = 0{,}92 \pm 0{,}05$ ($\mathrm{KS} = 0{,}026 < 0{,}067$, $p = 0{,}45$).

O topo da hierarquia nordestina, contudo, rompe a lei de Zipf (Fig. 1d, círculos âmbar). As nove maiores manchas são exatamente as nove capitais estaduais: Recife (3,47 M), Fortaleza (3,35 M) e Salvador (3,10 M) formam uma tríade metropolitana de populações quase iguais, seguidas por São Luís (1,30 M), Natal (1,23 M), Maceió (1,07 M), João Pessoa (1,05 M), Teresina (0,98 M) e Aracaju (0,83 M). Sob Zipf estrito (S_1/r), a segunda cidade deveria ter 1,74 M e a nona apenas 0,39 M (menos da metade de Aracaju). A maior cidade do interior, Feira de Santana (0,53 M), surge apenas em 10° lugar. Essa macrocefalia compartilhada pelas capitais gera um degrau no estimador de Hill ($\hat{\alpha}_{50} = 1{,}18$), que converge para a cauda quando inclui o interior ($\hat{\alpha}_{100} = 0{,}93$, $R^2_{\mathrm{OLS}} = 0{,}98$; $\hat{\alpha}_{200} = 0{,}95$). Calibrar ($D^*$,$\ell$) isoladamente para o Nordeste ($D^* = 110$ hab/km^2, $\ell = 3{,}4$ km) ainda mantém desvio $\Delta = 0{,}07$ e agrega 81% da população regional ao absorver zonas rurais densas.

Manchas morfológicas versus municípios. A diferença entre definições é decisiva nas metrópoles conurbadas. O município do Recife tem 1,49 milhão de habitantes (3° do Nordeste, atrás de Fortaleza e Salvador), mas sua mancha contínua — unindo Recife, Olinda, Jaboatão, Paulista e Camaragibe — soma 3,47 milhões, ocupando a 1ª posição regional. Na cauda, os 1 794 municípios nordestinos fornecem $\alpha = 0{,}74 \pm 0{,}03$, distorção causada pela soma de sedes pequenas com extensas zonas rurais.

Limitações e conclusão. Registram-se duas limitações: **(i)** o GPW v4 (2020) projeta contagens baseadas no Censo 2010, gerando diferença absoluta frente ao Censo 2022, mas preservando a hierarquia espacial relativa; e **(ii)** a resolução de 30″ impõe o corte físico $\ell_{\min} = 1{,}4$ km. Em conclusão, delimitadas morfologicamente pelo CCA com área esférica exata (L'Huilier), as manchas urbanas do Brasil obedecem à lei de Zipf ($\alpha = 1{,}00 \pm 0{,}04$), enquanto os municípios a rejeitam. No Nordeste, a cauda urbana segue Zipf, mas o topo é regido por nove capitais de porte equivalente — provando que a lei de Zipf é uma propriedade emergente do sistema nacional integrado, e não de suas sub-redes federativas isoladas.

Referências

[1] George K. Zipf. *Human Behavior and the Principle of Least Effort*. Addison-Wesley, 1949.

[2] M. E. J. Newman. Power laws, Pareto distributions and Zipf's law. *Contemporary Physics*, 46(5):323–351, 2005.

[3] Newton J. Moura, Jr. and Marcelo B. Ribeiro. Zipf law for Brazilian cities. *Physica A: Statistical Mechanics and its Applications*, 367:441–448, 2006.

[4] Hernán D. Rozenfeld, Diego Rybski, José S. Andrade, Jr., Michael Batty, H. Eugene Stanley, and Hernán A. Makse. Laws of population growth. *Proceedings of the National Academy of Sciences*, 105(48):18702–18707, 2008.

[5] Hernán D. Rozenfeld, Diego Rybski, Xavier Gabaix, and Hernán A. Makse. The area and population of cities: New insights from a different perspective on cities. *American Economic Review*, 101(5):2205–2225, 2011.

[6] Erneson A. Oliveira, José S. Andrade, Jr., and Hernán A. Makse. Large cities are less green. *Scientific Reports*, 4:4235, 2014.

[7] Carlos Caminha, Vasco Furtado, Tarcisio H. C. Pequeno, Caio Ponte, Hygor P. M. Melo, Erneson A. Oliveira, and José S. Andrade, Jr. Human mobility in large cities as a proxy for crime. *PLOS ONE*, 12(2):e0171609, 2017.

[8] Erneson A. Oliveira, Vasco Furtado, José S. Andrade, Jr., and Hernán A. Makse. A worldwide model for boundaries of urban settlements. *Royal Society Open Science*, 5(5):180468, 2018.

[9] Center for International Earth Science Information Network (CIESIN). Gridded population of the world, version 4 (gpwv4): Population count, revision 11. NASA Socioeconomic Data and Applications Center (SEDAC), 2018.

[10] Instituto Brasileiro de Geografia e Estatística (IBGE). API de malhas geográficas, versão 3. https://servicodados.ibge.gov.br/api/docs/malhas?versao=3, 2024.

[11] Instituto Brasileiro de Geografia e Estatística (IBGE). Censo demográfico 2022: população residente por município, tabela 4709 do SIDRA. https://sidra.ibge.gov.br/tabela/4709, 2023.

[12] Erneson A. Oliveira, R. S. Pires, R. S. Oliveira, Vasco Furtado, H. J. Herrmann, and José S. Andrade, Jr. A universal approach for drainage basins. *Scientific Reports*, 9:9845, 2019.

[13] Robert Endre Tarjan. Efficiency of a good but not linear set union algorithm. *Journal of the ACM*, 22(2):215–225, 1975.

[14] Bruce M. Hill. A simple general approach to inference about the tail of a distribution. *The Annals of Statistics*, 3(5):1163–1174, 1975.