UNIVERSIDADE DE FORTALEZA
CENTRO DE CIÊNCIAS TECNOLÓGICAS
PROGRAMA DE PÓS-GRADUAÇÃO EM INFORMÁTICA APLICADA
MESTRADO ACADÊMICO EM INFORMÁTICA APLICADA

THIAGO DE OLIVEIRA SAMPAIO

POPULAÇÃO DE BACIAS HIDROGRÁFICAS E MICROPLÁSTICO NAS FOZES: UMA ANÁLISE DE ESCALA NA AMÉRICA DO NORTE E CENTRAL

FORTALEZA – CEARÁ
2026

THIAGO DE OLIVEIRA SAMPAIO

POPULAÇÃO DE BACIAS HIDROGRÁFICAS E MICROPLÁSTICO NAS FOZES: UMA ANÁLISE DE ESCALA NA AMÉRICA DO NORTE E CENTRAL

Dissertação apresentada ao Curso de Mestrado Acadêmico em Informática Aplicada do Programa de Pós-Graduação em Informática Aplicada do Centro de Ciências Tecnológicas da Universidade de Fortaleza, como requisito parcial à obtenção do título de mestre em Informática Aplicada. Área de Concentração: Ciência da Computação

Orientador: Erneson Alves de Oliveira

FORTALEZA – CEARÁ

2026

THIAGO DE OLIVEIRA SAMPAIO

POPULAÇÃO DE BACIAS HIDROGRÁFICAS E MICROPLÁSTICO NAS FOZES: UMA ANÁLISE DE ESCALA NA AMÉRICA DO NORTE E CENTRAL

Dissertação apresentada ao Curso de Mestrado Acadêmico em Informática Aplicada do Programa de Pós-Graduação em Informática Aplicada do Centro de Ciências Tecnológicas da Universidade de Fortaleza, como requisito parcial à obtenção do título de mestre em Informática Aplicada. Área de Concentração: Ciência da Computação

Aprovada em: _____ de _____ de 2026

BANCA EXAMINADORA

Erneson Alves de Oliveira (Orientador)
Universidade de Fortaleza - UNIFOR

Prof. Dr. Membro Interno
Universidade de Fortaleza - UNIFOR

Prof. Dr. Membro Externo
Instituição - SIGLA

À minha família.

AGRADECIMENTOS

Ao meu orientador, Prof. Dr. Erneson Alves de Oliveira, pela orientação, pelas discussões sobre percolação, leis de escala e cidades, e por disponibilizar o código do IPBA.

Aos professores e colegas do Programa de Pós-Graduação em Informática Aplicada da Universidade de Fortaleza, pelas aulas, sugestões e conversas ao longo do mestrado.

Aos voluntários do *Nurdle Patrol* e às equipes do GEBCO, do CIESIN/SEDAC e do NCEI/NOAA, que coletam, organizam e publicam gratuitamente os dados sem os quais este trabalho não existiria.

À minha família e aos meus amigos, pelo apoio durante toda esta etapa.

“Ninguém pode entrar duas vezes no mesmo rio, pois quando nele se entra novamente, não se encontra as mesmas águas, e o próprio ser já se modificou.”

(Heráclito de Éfeso)

RESUMO

Rios são a principal via pela qual o plástico descartado em terra chega ao oceano. Se isso é verdade, a quantidade de plástico na foz de um rio deveria crescer com o número de pessoas que vivem na bacia que o alimenta. Esta dissertação testa essa hipótese na América do Norte e Central, dos Estados Unidos e sul do Canadá até o Canal do Panamá, cruzando três bases independentes: o relevo global GEBCO 2024, a grade de população GPW v4 (2020) e as amostras de *pellets* plásticos do programa *Nurdle Patrol* no banco de microplásticos marinhos da NOAA. As bacias hidrográficas são delineadas pelo algoritmo baseado em percolação invasiva (IPBA), tomando como saída cada pixel de terra vizinho ao oceano; as 138 maiores bacias, que cobrem 90% da área de terra, formam a amostra. As cidades são definidas sem fronteiras administrativas pelo *City Clustering Algorithm* (CCA), cujos dois parâmetros, o limiar de densidade D^* e a distância de ligação ℓ, foram calibrados pela lei de Zipf numa varredura de 300×50 combinações, resolvida em tempo quase linear por uma estrutura de união e busca que ativa os pixels em ordem decrescente de densidade. O critério escolhido, que exige expoente próximo de 1 simultaneamente para as 50, 100 e 200 maiores manchas, resultou em $D^* = 1010$ hab/km^2 e $\ell = 1{,}7$ km, com 12.185 manchas urbanas e expoentes de Hill entre 0,93 e 1,08. Manchas que cruzam divisores de água são repartidas entre as bacias. Cada bacia recebe o ponto de coleta mais próximo da sua foz, e o raio de aceitação é varrido de 1 em 1 km até 50 km. Com o raio de 38 km, que reúne a maioria dos pontos de coleta, 52 bacias têm medição, 29 delas com contagem positiva. Nessas 29, a concentração de *pellets* cresce de forma sublinear com a população, com expoente $\beta = 0{,}28$ (IC 95%: 0,11 a 0,54; $r = 0{,}37$; $p = 0{,}05$), e o indicador de quantidade, concentração vezes área, cresce com $\beta = 0{,}85$ ($r = 0{,}66$). A associação é fraca e frágil: incluindo as bacias com contagem zero, a correlação de postos cai para $\rho_s = 0{,}25$ ($p = 0{,}07$), e boa parte do expoente do indicador de quantidade vem da correlação entre população e área das bacias. Com raio de 1 km apenas três bacias têm medição. Conclui-se que os dados públicos atuais sustentam, no máximo, uma relação sublinear e fraca entre população da bacia e microplástico na foz, e que a principal limitação é a cobertura espacial das coletas, concentrada no Golfo do México. A dissertação contribui com um *pipeline* reprodutível que integra percolação invasiva, agrupamento urbano calibrado por Zipf e alometria por bacia.

Palavras-chave: microplástico; bacias hidrográficas; percolação invasiva; lei de Zipf; alometria urbana.

ABSTRACT

Rivers are the main pathway through which plastic discarded on land reaches the ocean. If so, the amount of plastic at a river mouth should grow with the number of people living in the basin that feeds it. This dissertation tests that hypothesis in North and Central America, from the United States and southern Canada down to the Panama Canal, by combining three independent datasets: the GEBCO 2024 global relief grid, the GPW v4 (2020) population grid, and the plastic pellet samples of the Nurdle Patrol program in the NOAA marine microplastics database. Drainage basins are delineated with the Invasion Percolation Based Algorithm (IPBA), taking every land pixel adjacent to the ocean as an outlet; the 138 largest basins, which cover 90% of the land area, form the sample. Cities are defined without administrative boundaries by the City Clustering Algorithm (CCA), whose two parameters, the density threshold D^* and the linking distance ℓ, were calibrated by Zipf's law over a 300×50 parameter sweep, solved in near-linear time by a union-find structure that activates pixels in decreasing order of density. The chosen criterion, which requires an exponent close to 1 simultaneously for the 50, 100 and 200 largest clusters, yields $D^* = 1010$ inhabitants/km^2 and $\ell = 1.7$ km, with 12,185 urban clusters and Hill exponents between 0.93 and 1.08. Clusters that cross drainage divides are split among basins. Each basin is assigned the sampling site nearest to its mouth, and the acceptance radius is swept in 1 km steps up to 50 km. At 38 km, the radius that contains most sampling sites, 52 basins have a measurement, 29 of them with a positive count. In those 29 basins, pellet concentration grows sublinearly with population, with exponent $\beta = 0.28$ (95% CI: 0.11 to 0.54; $r = 0.37$; $p = 0.05$), and the quantity proxy, concentration times area, grows with $\beta = 0.85$ ($r = 0.66$). The association is weak and fragile: when basins with zero counts are included, the rank correlation drops to $\rho_s = 0.25$ ($p = 0.07$), and much of the exponent of the quantity proxy comes from the correlation between basin population and area. With a 1 km radius only three basins have a measurement. We conclude that current public data support, at most, a weak sublinear relation between basin population and microplastic at the mouth, and that the main limitation is the spatial coverage of the samples, concentrated in the Gulf of Mexico. The dissertation contributes a reproducible pipeline that integrates invasion percolation, Zipf-calibrated urban clustering and basin-level allometry.

Keywords: microplastics; drainage basins; invasion percolation; Zipf's law; urban scaling.

LISTA DE ILUSTRAÇÕES

Figura 1 – Relevo (GEBCO 2024) e densidade populacional (GPW v4, 2020) no mundo, em baixa resolução, e ampliados na região de estudo 33
Figura 2 – Amostras do banco de microplásticos marinhos da NOAA no mundo e sítios do *Nurdle Patrol* na região de estudo 34
Figura 3 – As 138 bacias principais, que cobrem 90% da área de terra da região de estudo 44
Figura 4 – Expoente de Zipf e desvio Δ na grade de parâmetros do CCA 45
Figura 5 – Distribuição *rank-size* das 12.185 manchas urbanas 48
Figura 6 – As dez maiores manchas urbanas e as fozes das bacias principais em que se dividem 49
Figura 7 – Bacias principais, manchas urbanas, sítios de coleta e fozes 50
Figura 8 – Efeito do raio de aceitação entre a foz e o sítio de coleta 51
Figura 9 – População das bacias versus microplástico na foz 53
Figura 10 – Variação do coeficiente r ao remover cada bacia do ajuste da concentração ($R = 38$ km) 54
Figura 11 – Distribuições complementares acumuladas das áreas e populações das bacias e das populações das manchas urbanas 55

LISTA DE TABELAS

Tabela 1 – Bases de dados usadas no trabalho 32
Tabela 2 – As dez bacias principais mais populosas 44
Tabela 3 – Melhor D^* para cada ℓ admitido pelo critério Δ 46
Tabela 4 – As dez maiores manchas urbanas ($D^* = 1.010$ hab/km^2, $\ell = 1.700$ m) . 47
Tabela 5 – Leis de escala entre população e microplástico em função do raio de aceitação 51
Tabela 6 – Leis de escala entre população da bacia e microplástico na foz ($R = 38$ km) 52
Tabela 7 – Ajustes de cauda pelo método CSN 55
Tabela 8 – Parâmetros do *pipeline* 67
Tabela 9 – Bacias principais com sítio a até 38 km da foz 68

LISTA DE ALGORITMOS

Algoritmo 1 – Delineamento de bacias por percolação invasiva (IPBA) 22

Algoritmo 2 – Varredura do CCA em D^* para um ℓ fixo 37

LISTA DE ABREVIATURAS E SIGLAS

CCA	*City Clustering Algorithm*
CIESIN	*Center for International Earth Science Information Network*
COG	*Cloud Optimized GeoTIFF*
CSN	Clauset, Shalizi e Newman
EMV	Estimador de Máxima Verossimilhança
EUA	Estados Unidos da América
GEBCO	*General Bathymetric Chart of the Oceans*
GPW	*Gridded Population of the World*
IC	Intervalo de Confiança
IPBA	*Invasion Percolation Based Algorithm*
KS	Kolmogorov–Smirnov
MDE	Modelo Digital de Elevação
MQO	Mínimos Quadrados Ordinários
NCEI	*National Centers for Environmental Information*
NOAA	*National Oceanic and Atmospheric Administration*
PPGIA	Programa de Pós-Graduação em Informática Aplicada
SEDAC	*Socioeconomic Data and Applications Center*
UNIFOR	Universidade de Fortaleza

LISTA DE SÍMBOLOS

A	Área de uma bacia hidrográfica (km^2)
c	Pré-fator de uma lei de escala $y = c\,x^{\beta}$
D^*	Limiar de densidade populacional do CCA (hab/km^2)
N	Número de maiores manchas usadas no estimador de Hill
n	Tamanho de uma amostra
P	Fração da área de terra coberta pelas bacias principais
p	Valor-p de um teste de hipótese
$p(x)$	Densidade de probabilidade do tamanho x
R	Raio de aceitação entre a foz e o ponto de coleta (km)
R_{maioria}	Menor raio que contém ao menos metade dos pontos de coleta
r	Posto (*rank*) de uma mancha urbana; coeficiente de correlação de Pearson
$S(r)$	População da mancha urbana de posto r
$x_{\min}$	Limite inferior da cauda ajustada por lei de potência
α	Expoente de Zipf na forma *rank-size*, $S(r) \propto r^{-\alpha}$
α_N	Expoente de Zipf estimado por Hill sobre as N maiores manchas
β	Expoente de uma lei de escala (alometria)
γ	Expoente da densidade de uma lei de potência, $p(x) \propto x^{-\gamma}$
Δ	Desvio máximo $\max_N \lvert\alpha_N - 1\rvert$ usado na calibração
ℓ	Distância máxima de ligação entre pixels do CCA (m)
$\ell_{\min}$	Menor ℓ admitido na calibração (m)
ρ_s	Coeficiente de correlação de postos de Spearman
ζ	Expoente de cauda estimado por Hill, $\zeta = 1/\alpha$

SUMÁRIO

1 INTRODUÇÃO 16
1.1 Objetivos 17
1.2 Contribuições 17
1.3 Organização do texto 18
2 FUNDAMENTAÇÃO TEÓRICA 19
2.1 Plástico e microplástico no ambiente 19
2.1.1 Origem, fragmentação e definição 19
2.1.2 Rios como vetores de plástico para o oceano 19
2.1.3 Medição de microplástico e o *Nurdle Patrol* 20
2.2 Bacias hidrográficas e o seu delineamento 21
2.2.1 Bacias a partir de modelos digitais de elevação 21
2.2.2 Percolação invasiva 21
2.3 Definição de cidades pela densidade: o *City Clustering Algorithm* 23
2.4 Leis de potência e a lei de Zipf 24
2.4.1 Leis de potência 24
2.4.2 A lei de Zipf 24
2.4.3 Estimação do expoente 25
2.5 Leis de escala urbana 26
2.5.1 Ajuste e inferência 26
3 TRABALHOS RELACIONADOS 28
3.1 Plástico, rios e população 28
3.2 Cidades definidas a partir de dados em grade 29
3.3 Leis de escala em fenômenos urbanos 29
3.4 Posicionamento deste trabalho 30
4 METODOLOGIA 31
4.1 Visão geral 31
4.2 Dados 31
4.3 Recorte da região de estudo 32
4.4 Bacias hidrográficas 35
4.4.1 Resolução do relevo 35
4.4.2 Oceano e *sinks* 35

4.4.3 Delineamento e bacias principais 35
4.5 Manchas urbanas 36
4.5.1 Aplicação do CCA à grade do GPW 36
4.5.2 Calibração de D^* e ℓ pela lei de Zipf 36
4.5.3 Identificação das manchas 39
4.6 População por bacia 39
4.7 Microplástico por bacia 40
4.7.1 Sítios de coleta 40
4.7.2 O sítio mais próximo da foz 40
4.8 Raio de aceitação 40
4.9 Alometria por bacia 41
4.10 Verificações das distribuições 41
4.11 Implementação 42
5 RESULTADOS E DISCUSSÃO 43
5.1 Bacias hidrográficas 43
5.2 Calibração do CCA e manchas urbanas 45
5.2.1 Matriz de expoentes 45
5.2.2 Manchas urbanas 46
5.2.3 Distribuição *rank-size* 47
5.3 Repartição das manchas entre as bacias 48
5.4 Microplástico nas fozes e raio de aceitação 50
5.5 Leis de escala entre população e microplástico 52
5.6 Distribuições de tamanho 54
5.7 Discussão 55
5.7.1 O que os resultados dizem sobre a hipótese 55
5.7.2 O papel das escolhas metodológicas 56
6 CONCLUSÃO 58
6.1 Síntese dos resultados 58
6.2 Resposta à pergunta de pesquisa 59
6.3 Contribuições 59
6.4 Trabalhos futuros 60
REFERÊNCIAS 61
GLOSSÁRIO 65

APÊNDICE A – Reprodutibilidade 66
A.1 Ordem de execução 66
A.2 Dados e código de terceiros 66
A.3 Parâmetros 66
A.4 Saídas 66
APÊNDICE B – Bacias principais com sítio de coleta a até 38 km da foz 68

1 INTRODUÇÃO

A produção mundial de plásticos passou de cerca de 2 milhões de toneladas por ano em 1950 para 380 milhões de toneladas em 2015, e estima-se que 79% de todos os resíduos plásticos já gerados tenham se acumulado em aterros ou no ambiente (GEYER; JAMBECK; LAW, 2017). Uma fração desse material chega ao mar: Jambeck *et al.* (2015) estimaram que, apenas em 2010, entre 4,8 e 12,7 milhões de toneladas de resíduos plásticos gerados em áreas costeiras entraram no oceano. Uma vez no ambiente, o plástico se fragmenta em partículas cada vez menores sem se degradar por completo (BARNES *et al.*, 2009; ANDRADY, 2011). As partículas menores que 5 mm, chamadas de microplásticos (FRIAS; NASH, 2019), já foram encontradas em sedimentos, praias e na coluna d'água de todos os oceanos (THOMPSON *et al.*, 2004; ERIKSEN *et al.*, 2014).

A maior parte desse plástico não é descartada diretamente no mar. Ele é gerado em terra, onde as pessoas vivem, e é levado ao oceano principalmente pelos rios (LEBRETON *et al.*, 2017; SCHMIDT; KRAUTH; WAGNER, 2017; MEIJER *et al.*, 2021). Um rio integra tudo o que acontece na sua bacia hidrográfica: a chuva que cai sobre uma cidade escoa para os córregos, os córregos para o rio principal, e o rio desemboca na foz. Se o plástico que chega à foz vem das pessoas que vivem a montante, é natural esperar que a quantidade de plástico na foz cresça com a população da bacia. Essa expectativa está implícita nos principais modelos globais de emissão de plástico por rios, que usam a densidade populacional e a gestão de resíduos da bacia como variáveis explicativas (LEBRETON *et al.*, 2017; MEIJER *et al.*, 2021).

Testar essa relação diretamente, com medições de campo e não com modelos, exige responder a três perguntas que parecem simples mas não são. A primeira é **onde fica cada bacia**. As bacias precisam ser delineadas a partir do relevo, e isso exige um algoritmo que, dado um mapa de altitudes, atribua cada ponto de terra à saída no oceano para onde a água dali escoaria. A segunda é **quanta gente mora em cada bacia**, e em particular como tratar as cidades, que muitas vezes ficam sobre divisores de água e drenam para mais de uma bacia. Isso exige uma definição de cidade que não dependa de fronteiras administrativas, traçadas por motivos históricos e políticos e não pela forma da ocupação humana (ROZENFELD *et al.*, 2008; ROZENFELD *et al.*, 2011). A terceira é **quanto plástico chega à foz de cada bacia**. As medições de microplástico são pontuais, feitas em praias e estuários escolhidos por conveniência logística, e raramente coincidem com a foz de um rio.

1.1 Objetivos

O objetivo geral desta dissertação é testar se a população residente numa bacia hidrográfica está associada à concentração de microplástico medida na foz dessa bacia, e medir a forma dessa associação como uma lei de escala (alometria) na América do Norte e Central, dos Estados Unidos e sul do Canadá até o Canal do Panamá.

Os objetivos específicos são:

1. delinear as bacias hidrográficas costeiras da região a partir do relevo global *General Bathymetric Chart of the Oceans* (GEBCO), usando o algoritmo baseado em percolação invasiva (IPBA) com todas as saídas possíveis para o oceano;
2. definir as manchas urbanas a partir da grade de população *Gridded Population of the World* (GPW) com o *City Clustering Algorithm* (CCA), calibrando os seus dois parâmetros pela lei de Zipf de forma independente da variável de resposta;
3. calcular a população de cada bacia, repartindo entre as bacias as manchas urbanas que cruzam divisores de água;
4. associar a cada bacia uma medição de microplástico na sua foz a partir do banco de microplásticos marinhos da *National Oceanic and Atmospheric Administration* (NOAA), avaliando de forma explícita como a distância aceita entre a foz e o ponto de coleta afeta o resultado;
5. ajustar leis de escala entre população e microplástico por bacia, com intervalos de confiança e testes de significância que não dependam de suposições de normalidade.

1.2 Contribuições

As contribuições deste trabalho são as seguintes.

- **Um *pipeline* reprodutível** que integra três bases públicas e independentes (relevo, população e microplástico) numa análise por bacia. Todo o processamento é feito em dois *notebooks* executáveis, que baixam os dados e o código de terceiros em tempo de execução.
- **Delineamento de bacias sem lista manual de rios.** Todo pixel de terra vizinho ao oceano é tratado como saída (*sink*), e as bacias de rio emergem naturalmente como as que acumulam mais área. As bacias principais são escolhidas por um critério de cobertura de área, sem limiar arbitrário de área mínima.
- **Calibração do CCA pela lei de Zipf com um algoritmo eficiente.** Uma varredura de 15 mil combinações de parâmetros, que exigiria 15 mil execuções do CCA, é resolvida com

uma estrutura de união e busca que ativa os pixels em ordem decrescente de densidade. O resultado é idêntico ao do CCA em cada combinação e o custo é de algumas dezenas de execuções. O critério de escolha exige que o expoente fique próximo de 1 em vários tamanhos de amostra e impõe um piso físico à distância de ligação, o que evita soluções degeneradas.

- **Repartição de manchas urbanas entre bacias**, de modo que cada parte da cidade conte para a bacia para onde de fato drena.
- **Uma análise explícita da sensibilidade ao raio de aceitação** entre a foz e o ponto de coleta, que mostra quantas bacias ficam disponíveis em cada distância e como os expoentes e correlações variam com ela.
- **Uma avaliação honesta do resultado.** A dissertação mostra que a relação entre população e microplástico, embora positiva, é fraca e frágil com os dados atuais, e identifica as causas: a cobertura espacial das coletas, as contagens zero e a correlação entre população e área das bacias.

1.3 Organização do texto

O Capítulo 2 apresenta os conceitos usados no trabalho: microplásticos e o seu transporte por rios, delineamento de bacias por percolação invasiva, a definição de cidades pelo CCA, a lei de Zipf, leis de potência e leis de escala urbana. O Capítulo 3 discute os trabalhos que relacionam plástico e população, os que definem cidades a partir de dados em grade e os que aplicam leis de escala a fenômenos urbanos. O Capítulo 4 descreve os dados, o recorte da região e cada etapa do *pipeline*. O Capítulo 5 apresenta e discute os resultados, e o Capítulo 6 resume as conclusões, as limitações e os trabalhos futuros. O Apêndice A descreve como reproduzir a análise, e o Apêndice B lista as bacias usadas nos ajustes.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos em que o trabalho se apoia. A Seção 2.1 trata do microplástico e do seu caminho da terra até o mar. A Seção 2.2 discute o delineamento de bacias hidrográficas a partir do relevo e o algoritmo de percolação invasiva usado aqui. A Seção 2.3 define cidades a partir da densidade populacional. A Seção 2.4 apresenta as leis de potência, a lei de Zipf e os métodos estatísticos para estimá-las, e a Seção 2.5 trata das leis de escala urbana, que dão a forma da relação testada nesta dissertação.

2.1 Plástico e microplástico no ambiente

2.1.1 Origem, fragmentação e definição

Plásticos são polímeros sintéticos de baixo custo, leves e duráveis. A durabilidade que os torna úteis é também o que os torna um problema ambiental: expostos à radiação ultravioleta, à abrasão e às variações de temperatura, os objetos plásticos se fragmentam em pedaços cada vez menores, mas a mineralização completa do polímero leva de décadas a séculos (BARNES *et al.*, 2009; ANDRADY, 2011). O resultado é um acúmulo contínuo de fragmentos no ambiente. Thompson *et al.* (2004) mostraram que fragmentos microscópicos de polímeros comuns já eram abundantes em sedimentos e na coluna d'água das costas do Reino Unido nos anos 1960 e que a sua abundância cresceu nas décadas seguintes.

Não há uma definição única de microplástico, mas o limite superior de 5 mm é o mais usado (FRIAS; NASH, 2019). Costuma-se distinguir os microplásticos **secundários**, que resultam da fragmentação de objetos maiores, dos **primários**, fabricados já nesse tamanho. Entre os primários estão os *pellets* de resina pré-produção, conhecidos em inglês como *nurdles*: grânulos de 2 a 5 mm que são a matéria-prima da indústria de transformação de plásticos. Os *pellets* são perdidos durante a produção, o transporte e o manuseio, e chegam ao mar pelos sistemas de drenagem e pelos rios (KARLSSON *et al.*, 2018). Além de serem poluentes em si, eles adsorvem compostos orgânicos persistentes da água, concentrando-os em até seis ordens de grandeza (MATO *et al.*, 2001).

2.1.2 Rios como vetores de plástico para o oceano

A maior parte do plástico encontrado no mar tem origem terrestre. Jambeck *et al.* (2015) combinaram dados de geração de resíduos, população costeira e gestão de resíduos de

192 países para estimar que entre 4,8 e 12,7 milhões de toneladas de plástico entraram no oceano em 2010. Os rios são a principal via desse transporte. Lebreton *et al.* (2017) desenvolveram um modelo global de emissão de plástico por rios em que a entrada de plástico em cada bacia é função da população, da geração de resíduos mal geridos e do escoamento superficial; o modelo estimou entre 1,15 e 2,41 milhões de toneladas por ano e concentrou a maior parte das emissões em poucos rios asiáticos. Schmidt, Krauth e Wagner (2017) chegaram a uma conclusão semelhante ao ajustar uma regressão entre a carga de plástico medida em dezenas de rios e a quantidade de resíduos mal geridos nas suas bacias. Meijer *et al.* (2021) refinaram esse tipo de modelo com uma representação probabilística do transporte dentro da bacia, que leva em conta a distância até o rio, o uso do solo, a declividade e a precipitação, e concluíram que mais de mil rios respondem por 80% das emissões globais, com um peso muito maior de rios pequenos e urbanos do que o estimado antes.

Esses modelos têm em comum a hipótese de que **a população da bacia é uma variável explicativa central** da carga de plástico que chega à foz. Medições de campo que testem essa hipótese diretamente, bacia a bacia e numa escala continental, são escassas. As evidências empíricas mais diretas vêm de estudos locais, discutidos no Capítulo 3.

2.1.3 Medição de microplástico e o *Nurdle Patrol*

Os métodos de amostragem de microplástico variam muito: redes de arrasto na superfície do mar (com resultados em partículas por m^3 ou por km^2), testemunhos e amostras de sedimento (em partículas por kg de sedimento seco) e coletas em praias (em partículas por área ou por tempo de busca) (HIDALGO-RUZ *et al.*, 2012). Resultados obtidos com métodos diferentes não são diretamente comparáveis, e por isso uma análise quantitativa precisa se restringir a um único método.

O *Nurdle Patrol* é um programa de ciência cidadã coordenado pelo Mission-Aransas National Estuarine Research Reserve, da Universidade do Texas, em que voluntários contam os *pellets* que encontram numa praia durante 10 minutos de busca (TUNNELL *et al.*, 2020). A unidade resultante, *pellets* por 10 minutos, é uma medida padronizada de esforço: o mesmo protocolo é seguido em todos os pontos, o que torna as contagens comparáveis entre si. Em compensação, a cobertura espacial depende de onde há voluntários, o que concentra as coletas na costa do Golfo do México (TUNNELL *et al.*, 2020). As contagens do programa estão incluídas no banco de microplásticos marinhos do *National Centers for Environmental Information*

(NCEI), da NOAA, que reúne amostras de diversos métodos e fontes com as respectivas unidades (NYADJRO *et al.*, 2023).

2.2 Bacias hidrográficas e o seu delineamento

2.2.1 Bacias a partir de modelos digitais de elevação

Uma bacia hidrográfica é a região cujo escoamento superficial converge para uma mesma saída. Em termos computacionais, o problema de delineamento de bacias consiste em, dado um Modelo Digital de Elevação (MDE) representado como uma grade de altitudes, atribuir cada célula da grade à saída para onde a água que cai nela escoaria.

A abordagem clássica é a das **direções de fluxo**. No método D8, cada célula drena para a vizinha, entre as oito, com maior declividade descendente (O'CALLAGHAN; MARK, 1984); variações como o D∞ distribuem o fluxo entre duas vizinhas (TARBOTON, 1997). Acumulando o fluxo ao longo dessas direções obtém-se a área de drenagem de cada célula, e a rede de drenagem é definida pelas células cuja área acumulada passa de um limiar. Essa abordagem tem duas dificuldades para o problema desta dissertação. Primeiro, os MDEs reais têm depressões e platôs em que a direção de fluxo não é definida, e é preciso preenchê-los antes, com algoritmos próprios. Segundo, o resultado natural é uma rede de drenagem, não um conjunto de bacias associadas a saídas no oceano, e a escolha do limiar de área crítica é arbitrária.

Redes fluviais têm estrutura estatística própria: a área das bacias, o comprimento dos rios e a sua ramificação seguem leis de potência com expoentes aproximadamente universais (RODRÍGUEZ-ITURBE; RINALDO, 1997; MARITAN *et al.*, 1996). Essa observação é usada no Capítulo 5 para verificar se as bacias delineadas têm a distribuição de tamanhos esperada.

2.2.2 Percolação invasiva

A percolação invasiva foi proposta por Wilkinson e Willemsen (1983) para modelar o deslocamento de um fluido por outro num meio poroso. Cada sítio do meio tem uma resistência aleatória; a partir de um sítio inicial, o fluido invasor avança sempre pelo sítio de **menor resistência** da fronteira da região já invadida. Aplicada a um relevo, a resistência de um sítio é a sua altitude: a água que parte de um ponto avança pelo ponto mais baixo ao seu redor, enche as depressões que encontra até transbordar pelo ponto mais baixo da borda e continua descendo. É exatamente o comportamento de uma gota que escoa sobre o terreno, incluindo a travessia de

lagos e depressões, sem necessidade de preenchimento prévio.

Fehr *et al.* (2009) usaram essa ideia para construir um algoritmo de delineamento de bacias, o IPBA. Dado um conjunto de saídas rotuladas (*sinks*), o algoritmo percorre as células da grade e, para cada célula ainda sem bacia, executa uma percolação invasiva a partir dela. A percolação para quando atinge um *sink* ou uma célula que já pertence a uma bacia; todas as células invadidas nessa execução recebem então o rótulo da bacia atingida. O Algoritmo 1 resume o procedimento. A fronteira da região invadida é mantida num *heap* binário de mínimo ordenado pela altitude, de modo que cada passo de invasão custa $O(\log m)$, em que m é o tamanho da fronteira. Como cada célula é rotulada uma única vez e as percolações param ao encontrar células já rotuladas, o custo total cresce aproximadamente como $O(n \log n)$ para uma grade de n células.

Algoritmo 1: Delineamento de bacias por percolação invasiva (IPBA)

Entrada: grade de altitudes h; rótulos $\lambda(s) > 0$ para os *sinks*; vizinhança de 4 células
Saída: rótulo de bacia $b(k)$ para cada célula de terra k
início
  para cada *célula de terra k ainda sem bacia* **faça**
    $H \leftarrow$ *heap* de mínimo com $(h(k), k)$; $I \leftarrow \emptyset$;
    enquanto *H não estiver vazio* **faça**
      $t \leftarrow$ célula de menor altitude extraída de H; $I \leftarrow I \cup \{t\}$;
      se *t é um sink ou t já tem bacia* **então**
        $w \leftarrow$ bacia de t (ou o próprio rótulo, se *sink*);
        interrompe;
      fim
      insere em H os vizinhos de t ainda não visitados, com as suas altitudes;
    fim
    para cada $i \in I$ **faça**
      $b(i) \leftarrow w$;
    fim
  fim
fim

O IPBA tem duas propriedades úteis para esta dissertação. A primeira é que ele aceita **qualquer conjunto de saídas**: se todas as células de terra vizinhas ao oceano forem declaradas *sinks*, o algoritmo produz uma partição completa do continente em bacias costeiras,

sem que seja preciso saber de antemão onde ficam os rios. As bacias dos rios grandes emergem sozinhas, porque todas as células a montante escoam até a célula da foz. A segunda é que ele trata depressões e platôs sem pré-processamento. Fehr *et al.* (2011) usaram o mesmo arcabouço para estudar a geometria dos divisores de água, que são fractais.

2.3 Definição de cidades pela densidade: o *City Clustering Algorithm*

Os dados oficiais de população são agregados por unidades administrativas, como municípios e setores censitários. As fronteiras dessas unidades foram traçadas por motivos históricos e políticos, e uma região metropolitana contínua pode estar repartida em dezenas de municípios, enquanto um município grande pode conter vasta área rural. Qualquer estatística sobre o tamanho de cidades depende, portanto, de uma escolha prévia do que é uma cidade (ROZENFELD *et al.*, 2011; ARCAUTE *et al.*, 2015).

O CCA foi proposto por Rozenfeld *et al.* (2008) como uma definição de cidade construída de baixo para cima, a partir da distribuição espacial da população. Sobre uma grade de células com população conhecida, o algoritmo tem dois parâmetros:

- o **limiar de densidade** D^*: uma célula é *ativa* (urbana) se a sua densidade populacional for maior que D^*;
- a **distância de ligação** ℓ: duas células ativas pertencem à mesma mancha se estiverem a menos de ℓ uma da outra, direta ou indiretamente, por uma cadeia de células ativas.

Formalmente, seja $V = \{k : \rho_k > D^*\}$ o conjunto de células ativas, com ρ_k a densidade da célula k, e seja G_ℓ o grafo sobre V com uma aresta entre j e k sempre que a distância geodésica $d(j,k)$ entre os centros das células for menor que ℓ. As manchas urbanas são as componentes conexas de G_ℓ, e a população e a área de uma mancha são as somas das populações e áreas das suas células. O CCA é, portanto, um problema de percolação contínua: D^* controla a ocupação dos sítios e ℓ controla o alcance das ligações (ROZENFELD *et al.*, 2008; ROZENFELD *et al.*, 2011).

A escolha de D^* e ℓ muda o resultado. Com D^* baixo e ℓ alto, regiões inteiras se fundem numa única mancha; com D^* alto e ℓ baixo, as cidades se fragmentam em bairros. Rozenfeld *et al.* (2011) mostraram que, para uma ampla faixa de parâmetros, as manchas dos Estados Unidos e do Reino Unido seguem a lei de Zipf, mas que o expoente medido depende dos valores escolhidos. Oliveira, Andrade Jr. e Makse (2014) usaram o CCA para estudar a relação entre o tamanho das cidades e as suas emissões de CO_2. Nesta dissertação, D^* e ℓ são escolhidos

pela própria lei de Zipf, como descrito no Capítulo 4.

2.4 Leis de potência e a lei de Zipf

2.4.1 Leis de potência

Uma variável aleatória contínua x segue uma lei de potência, a partir de um valor mínimo $x_{\min}$, quando a sua densidade de probabilidade é

$$p(x) = \frac{\gamma - 1}{x_{\min}} \left(\frac{x}{x_{\min}} \right)^{-\gamma}, \qquad x \geq x_{\min}, \tag{2.1}$$

com $\gamma > 1$. A função de distribuição complementar é $P(X \geq x) = (x/x_{\min})^{-(\gamma-1)}$, uma reta de inclinação $-(\gamma - 1)$ num gráfico log-log. Leis de potência aparecem no tamanho de cidades, na frequência de palavras, na intensidade de terremotos e na área de bacias hidrográficas, entre muitos outros fenômenos (NEWMAN, 2005). Elas não têm escala característica: a razão entre a frequência de eventos de tamanho $2x$ e de tamanho x é a mesma para qualquer x.

2.4.2 A lei de Zipf

A lei de Zipf afirma que, ordenando as cidades de um país da maior para a menor, a população S da cidade de posto r segue

$$S(r) \propto r^{-\alpha}, \qquad \alpha \approx 1, \tag{2.2}$$

ou seja, a segunda maior cidade tem cerca de metade da população da maior, a terceira cerca de um terço, e assim por diante (ZIPF, 1949). A forma *rank-size* da Equação 2.2 é equivalente a uma lei de potência na distribuição dos tamanhos. Numa amostra de n cidades, o posto da cidade de tamanho S é aproximadamente $r \approx n P(X \geq S) \propto S^{-(\gamma-1)}$; invertendo, $S \propto r^{-1/(\gamma-1)}$, e portanto

$$\alpha = \frac{1}{\gamma - 1}, \qquad \text{de modo que} \qquad \alpha = 1 \iff \gamma = 2. \tag{2.3}$$

Gabaix (1999) mostrou que a lei de Zipf emerge se as cidades crescem de forma proporcional, com taxas de crescimento independentes do tamanho (lei de Gibrat), e há uma barreira refletora para as cidades pequenas. A validade da lei, porém, é debatida. Soo (2005) testou 73 países e rejeitou $\alpha = 1$ na maioria deles. Eeckhout (2004) mostrou que, quando se usam todos os lugares povoados dos Estados Unidos e não apenas as maiores cidades, a distribuição é mais bem descrita por uma lognormal, e que a lei de Zipf vale apenas para a cauda superior.

Jiang e Jia (2011) encontraram a lei de Zipf nas “cidades naturais” dos Estados Unidos, definidas pela densidade de cruzamentos de ruas, o que reforça que a definição de cidade importa tanto quanto os dados.

2.4.3 Estimação do expoente

Ajustar uma reta ao gráfico log-log por mínimos quadrados é a forma mais comum de estimar expoentes de leis de potência, mas é um estimador enviesado e os seus erros-padrão não são válidos, porque os pontos do gráfico não são independentes (CLAUSET; SHALIZI; NEWMAN, 2009). Dois estimadores são usados nesta dissertação.

Método de Clauset, Shalizi e Newman. Clauset, Shalizi e Newman (2009) propuseram um procedimento em três passos, que se tornou o padrão para dados empíricos. Primeiro, para um $x_{\min}$ fixo, o expoente é estimado por máxima verossimilhança,

$$\hat{\gamma} = 1 + n\left[\sum_{i=1}^{n} \ln \frac{x_i}{x_{\min}}\right]^{-1}, \qquad \sigma_{\hat{\gamma}} = \frac{\hat{\gamma}-1}{\sqrt{n}}, \tag{2.4}$$

em que a soma percorre as n observações com $x_i \geq x_{\min}$. Segundo, $x_{\min}$ é escolhido como o valor que minimiza a distância de Kolmogorov–Smirnov (KS) entre a distribuição acumulada empírica da cauda e a do modelo ajustado. Terceiro, a plausibilidade da lei de potência é avaliada por *bootstrap* semiparamétrico: geram-se amostras sintéticas do modelo ajustado, repete-se todo o procedimento em cada uma, e o valor-p é a fração das amostras sintéticas com distância KS maior que a observada. Por convenção, a lei de potência é rejeitada se $p < 0{,}1$. Para comparar a lei de potência com distribuições alternativas, como a lognormal ou a exponencial, usa-se a razão de verossimilhança normalizada de Vuong (1989), cujo sinal indica o modelo favorecido e cujo valor-p indica se a diferença é significativa. O pacote `powerlaw` implementa esse procedimento em Python (ALSTOTT; BULLMORE; PLENZ, 2014).

Estimador de Hill. O estimador de Hill (1975) usa apenas as N maiores observações $S_1 \geq S_2 \geq \cdots \geq S_N$. Para a forma *rank-size*, ele fornece diretamente

$$\hat{\alpha}_N = \frac{1}{N-1}\sum_{i=1}^{N-1} \ln \frac{S_i}{S_N}, \qquad \hat{\zeta}_N = \frac{1}{\hat{\alpha}_N}, \tag{2.5}$$

em que $\zeta = \gamma - 1$ é o expoente da distribuição complementar. O estimador de Hill é, essencialmente, o Estimador de Máxima Verossimilhança (EMV) da Equação 2.4 com $x_{\min} = S_N$, com $N-1$ no denominador em vez de N. A sua vantagem neste trabalho é a estabilidade: com N fixo, o estimador sempre usa o mesmo número de observações, enquanto o $x_{\min}$ do método CSN pode

saltar de forma descontínua entre amostras muito parecidas. A desvantagem é que o resultado depende de N, e por isso a dissertação o calcula para vários valores de N.

2.5 Leis de escala urbana

Bettencourt *et al.* (2007) mostraram que muitos indicadores urbanos Y variam com a população X das cidades segundo leis de escala

$$Y = cX^{\beta}, \tag{2.6}$$

com expoentes que se agrupam em três regimes. Indicadores de infraestrutura, como a extensão de ruas e de redes elétricas, têm $\beta < 1$ (**sublinear**): cidades maiores precisam de menos infraestrutura por habitante. Necessidades individuais, como moradia e consumo de água, têm $\beta \approx 1$ (**linear**). Indicadores de interação social, como produção econômica, patentes e crimes, têm $\beta > 1$ (**superlinear**). Bettencourt (2013) propôs uma explicação para esses regimes a partir do equilíbrio entre os custos de deslocamento e os benefícios das interações numa rede urbana. Relações do mesmo tipo foram encontradas para emissões de CO_2 (OLIVEIRA; ANDRADE JR.; MAKSE, 2014), suicídios (MELO *et al.*, 2014) e crimes contra o patrimônio em função da população flutuante (CAMINHA *et al.*, 2017).

Os expoentes de escala também dependem da definição de cidade. Arcaute *et al.* (2015) mostraram que, no Reino Unido, o mesmo indicador pode parecer superlinear, linear ou sublinear conforme os limiares de densidade e de deslocamento usados para delimitar as cidades, e Cottineau *et al.* (2017) chegaram a conclusão semelhante para a França. Esse resultado motiva, nesta dissertação, a escolha dos parâmetros do CCA por um critério externo, a lei de Zipf, e não pela qualidade do ajuste entre população e plástico.

2.5.1 Ajuste e inferência

A Equação 2.6 é linear em escala logarítmica, $\log_{10} Y = \log_{10} c + \beta \log_{10} X$, e β é tradicionalmente estimado por Mínimos Quadrados Ordinários (MQO) sobre os logaritmos (BETTENCOURT *et al.*, 2007). Com poucas observações e resíduos que não seguem uma distribuição normal, os intervalos de confiança analíticos do MQO não são confiáveis. Duas técnicas de reamostragem contornam esse problema. O *bootstrap* de pares (EFRON, 1979) sorteia, com reposição, n pares (X_i, Y_i) da amostra original, reajusta β em cada amostra e usa os percentis 2,5 e 97,5 da distribuição resultante como Intervalo de Confiança (IC) de 95%. O teste

de permutação (GOOD, 2005) avalia a hipótese nula $\beta = 0$: embaralhando os valores de Y entre as observações, destrói-se qualquer associação com X, e o valor-p é a fração das permutações com $|\beta|$ maior ou igual ao observado. Como medidas de associação, usam-se o coeficiente de correlação de Pearson r entre os logaritmos, que mede a qualidade do ajuste linear em escala log-log, e o coeficiente de Spearman ρ_s, que mede a associação monotônica entre os postos e não depende da transformação logarítmica.

3 TRABALHOS RELACIONADOS

Esta dissertação fica na interseção de três linhas de pesquisa: a que relaciona a poluição por plástico à população humana (Seção 3.1), a que define cidades a partir de dados em grade e estuda a sua distribuição de tamanhos (Seção 3.2) e a que aplica leis de escala a fenômenos urbanos (Seção 3.3). A Seção 3.4 resume as diferenças entre este trabalho e os anteriores.

3.1 Plástico, rios e população

Evidência de campo. Browne *et al.* (2011) amostraram sedimentos de 18 praias em seis continentes e encontraram mais microplástico nas praias de regiões densamente povoadas; a maior parte das partículas eram fibras, compatíveis com a descarga de efluentes de máquinas de lavar. Yonkos *et al.* (2014) mediram microplástico na superfície de quatro rios estuarinos da Baía de Chesapeake, nos Estados Unidos, e encontraram concentrações positivamente correlacionadas com a densidade populacional e com a proporção de área urbana e suburbana das bacias. Esses dois estudos são as evidências de campo mais diretas de que mais gente significa mais microplástico, mas têm alcance limitado: o primeiro compara praias sem delimitar a área que drena para cada uma, e o segundo compara apenas quatro bacias vizinhas.

***Pellets* plásticos.** Tunnell *et al.* (2020) apresentaram os primeiros resultados do *Nurdle Patrol*, com coletas de voluntários em praias de todo o Golfo do México. As maiores contagens ficaram na costa do Texas, região que concentra a indústria petroquímica e de produção de resinas, o que indica que, para os *pellets*, a proximidade de fontes industriais pode pesar tanto quanto a população. Karlsson *et al.* (2018) chegaram a conclusão semelhante ao medir a perda de *pellets* ao redor de uma fábrica de polietileno na Suécia e estimar que milhões de grânulos por ano escapavam para o ambiente a partir de um único sítio industrial.

Modelos de emissão por rios. Os modelos globais de Jambeck *et al.* (2015), Lebreton *et al.* (2017) e Meijer *et al.* (2021), descritos na Seção 2.1, partem da população e da gestão de resíduos para estimar a carga de plástico de cada país ou bacia. Schmidt, Krauth e Wagner (2017) calibraram um modelo desse tipo com medições de carga fluvial e concluíram que os dez rios com maior carga respondem pela maior parte do plástico exportado ao mar. Nesses trabalhos, a população entra como variável explicativa, e as medições servem para calibrar os coeficientes. Esta dissertação faz o caminho inverso: parte de medições independentes e pergunta se elas se organizam segundo a população das bacias.

3.2 Cidades definidas a partir de dados em grade

Rozenfeld *et al.* (2008) introduziram o CCA e o aplicaram a dados de população em grade dos Estados Unidos, do Reino Unido e da África, mostrando que a taxa média de crescimento populacional das manchas urbanas não depende do tamanho, como prevê a lei de Gibrat, mas que a dispersão dessas taxas decai com o tamanho segundo uma lei de potência. Rozenfeld *et al.* (2011) usaram o CCA com dados de alta resolução dos Estados Unidos e do Reino Unido para mostrar que tanto a população quanto a área das manchas seguem a lei de Zipf acima de um tamanho mínimo, em contraste com o resultado de Eeckhout (2004), que encontrou uma distribuição lognormal usando lugares censitários. A diferença entre os dois resultados vem justamente da definição de cidade: os lugares censitários incluem muitas unidades pequenas que o CCA agruparia ou descartaria. Jiang e Jia (2011) chegaram à lei de Zipf nos Estados Unidos por outro caminho, definindo "cidades naturais" a partir da densidade de cruzamentos da malha viária.

Nesses trabalhos, os parâmetros do CCA são fixados a partir de valores típicos ou de critérios externos, como o limiar de área urbana do censo, e a lei de Zipf é o resultado a ser verificado. Aqui a lógica é inversa: a lei de Zipf é usada como critério para escolher os parâmetros, e o resultado de interesse é outro, a relação entre população e plástico. Essa inversão só é legítima porque a lei de Zipf é uma propriedade das cidades, independente do plástico, e porque o critério é definido antes de olhar para a variável de resposta.

3.3 Leis de escala em fenômenos urbanos

Bettencourt *et al.* (2007) estabeleceram o arcabouço de leis de escala urbana descrito na Seção 2.5. Oliveira, Andrade Jr. e Makse (2014) aplicaram o CCA aos Estados Unidos e encontraram uma relação superlinear entre a população das manchas urbanas e as suas emissões de CO_2, com $\beta \approx 1{,}46$, concluindo que cidades grandes são menos eficientes em emissões por habitante. Melo *et al.* (2014) encontraram relações de escala entre população e suicídios nos municípios brasileiros, e Caminha *et al.* (2017) mostraram que, dentro de uma cidade, os crimes contra o patrimônio escalam de forma superlinear com a população flutuante e não com a residente. Este último resultado é relevante aqui por um motivo metodológico: a escolha de qual população medir (residente, flutuante, da cidade, da bacia) muda a relação encontrada.

Arcaute *et al.* (2015) e Cottineau *et al.* (2017) mostraram que os expoentes de escala são sensíveis à definição das unidades urbanas e alertaram para o risco de escolher a definição que

produz o resultado esperado. Nesta dissertação, a unidade de análise não é a cidade, mas a bacia hidrográfica, que é definida pelo relevo e não pela população. Mesmo assim, as manchas urbanas entram na análise, e por isso os seus parâmetros são fixados por um critério independente.

3.4 Posicionamento deste trabalho

O Quadro 1 compara esta dissertação com os trabalhos mais próximos. Nenhum dos trabalhos encontrados combina, numa mesma análise, (i) bacias delineadas a partir do relevo com todas as saídas costeiras, (ii) cidades definidas sem fronteiras administrativas e com parâmetros calibrados de forma independente, e (iii) medições de campo de microplástico associadas à foz de cada bacia, numa escala continental.

Quadro 1 – Comparação entre este trabalho e os trabalhos relacionados mais próximos

Trabalho	**Unidade de análise**	**Medida de população**	**Medida de plástico**
Browne *et al.* (2011)	Praias (18)	Densidade populacional do entorno	Microplástico no sedimento (campo)
Yonkos *et al.* (2014)	Bacias estuarinas (4)	Densidade populacional e uso do solo	Microplástico na superfície (campo)
Lebreton *et al.* (2017)	Bacias globais	População e resíduos mal geridos	Carga modelada, calibrada com medições
Meijer *et al.* (2021)	Bacias globais	População, resíduos, uso do solo	Carga modelada, calibrada com medições
Tunnell *et al.* (2020)	Praias do Golfo do México	Não usa	*Pellets* por 10 min (campo)
Oliveira, Andrade Jr. e Makse (2014)	Manchas urbanas (CCA)	População das manchas	Não se aplica (CO_2)
Esta dissertação	Bacias costeiras (IPBA), 138 principais	População da bacia, com manchas urbanas (CCA) repartidas	*Pellets* por 10 min na foz (campo)

Fonte: elaborado pelo autor.

4 METODOLOGIA

Este capítulo descreve os dados e cada etapa do processamento. A pergunta de pesquisa é se a população de uma bacia hidrográfica está associada ao microplástico medido na sua foz. Respondê-la exige cruzar três bases de dados independentes, que não foram feitas para ser usadas juntas, e por isso cada decisão de processamento é justificada ao longo do texto. A Seção 4.1 dá uma visão geral do *pipeline*; as seções seguintes detalham cada etapa na ordem em que são executadas.

4.1 Visão geral

O processamento é dividido em dois *notebooks*. O primeiro calibra os parâmetros do CCA pela lei de Zipf e grava os valores escolhidos num arquivo; o segundo lê esses valores e executa o restante da análise. A separação garante que os parâmetros das manchas urbanas sejam definidos sem nenhum contato com os dados de plástico. As etapas são:

1. **Recorte** da região de estudo nas três bases (Seção 4.3).
2. **Bacias hidrográficas**: definição do oceano e dos *sinks* costeiros, delineamento das bacias pelo IPBA e seleção das bacias principais (Seção 4.4).
3. **Manchas urbanas**: calibração de D^* e ℓ pela lei de Zipf e aplicação do CCA (Seção 4.5).
4. **População por bacia**, com a repartição das manchas que cruzam divisores de água (Seção 4.6).
5. **Microplástico por bacia**: associação de cada foz ao ponto de coleta mais próximo (Seção 4.7) e varredura do raio de aceitação (Seção 4.8).
6. **Alometria por bacia**: ajuste das leis de escala entre população e microplástico (Seção 4.9).
7. **Verificações**: distribuição de tamanhos das bacias e das manchas (Seção 4.10).

4.2 Dados

A Tabela 1 resume as três bases usadas. Todas são públicas e globais, e nenhuma depende das outras.

Relevo. O GEBCO 2024 é uma grade global de altitudes e profundidades com resolução de 15 segundos de arco (GEBCO Compilation Group, 2024). Ele foi escolhido por cobrir terra e oceano de forma contínua, o que permite definir a linha de costa pelo próprio relevo. A grade é lida diretamente de uma cópia em formato *Cloud Optimized GeoTIFF* (COG)

Tabela 1 – Bases de dados usadas no trabalho

Base	Conteúdo	Resolução	Papel na análise
GEBCO 2024	Altitude do relevo e profundidade do oceano	$15''$ ($\approx$ 460 m), reamostrado para $2'$ ($\approx$ 3,7 km)	Oceano, *sinks* costeiros e bacias hidrográficas
GPW v4.11	Contagem de pessoas por célula, ano 2020	$30''$ ($\approx$ 0,93 km no equador)	Manchas urbanas e população das bacias
NOAA NCEI *Marine Microplastics*	Amostras de microplástico com método e unidade	Pontos (coordenadas das coletas)	Microplástico na foz; só *Nurdle Patrol*, em *pellets* por 10 min

Fonte**:** elaborado pelo autor a partir de GEBCO Compilation Group (2024), Center for International Earth Science Information Network (CIESIN) (2018) e Nyadjro *et al.* (2023).

hospedada em nuvem, o que permite baixar apenas a região de interesse ou uma versão de baixa resolução do mundo inteiro.

População. O GPW versão 4, revisão 11, distribui as contagens populacionais dos censos nacionais sobre uma grade regular de 30 segundos de arco, com estimativas para o ano de 2020 (Center for International Earth Science Information Network (CIESIN), 2018). Por ser uma grade de contagens, e não de densidades, a soma dos valores das células de uma região dá a sua população. O GPW foi escolhido porque redistribui os censos sem usar variáveis auxiliares como luzes noturnas ou uso do solo, o que evita que a população seja estimada a partir de indicadores correlacionados com a atividade econômica e, portanto, com a geração de resíduos.

Microplástico. O banco de microplásticos marinhos do NCEI reúne 22.530 amostras de diferentes métodos e fontes (NYADJRO *et al.*, 2023). Na versão usada, 16.205 amostras estão em partículas por m^3 (arrastos de rede), 508 em partículas por kg de sedimento seco e 5.817 em *pellets* por 10 minutos, o protocolo do *Nurdle Patrol* (TUNNELL *et al.*, 2020). Como unidades diferentes não se comparam, a análise usa apenas as amostras do *Nurdle Patrol*. A escolha tem duas vantagens: o protocolo é o mesmo em todos os pontos, e as coletas são feitas em praias, perto de onde os rios desembocam, e não em mar aberto.

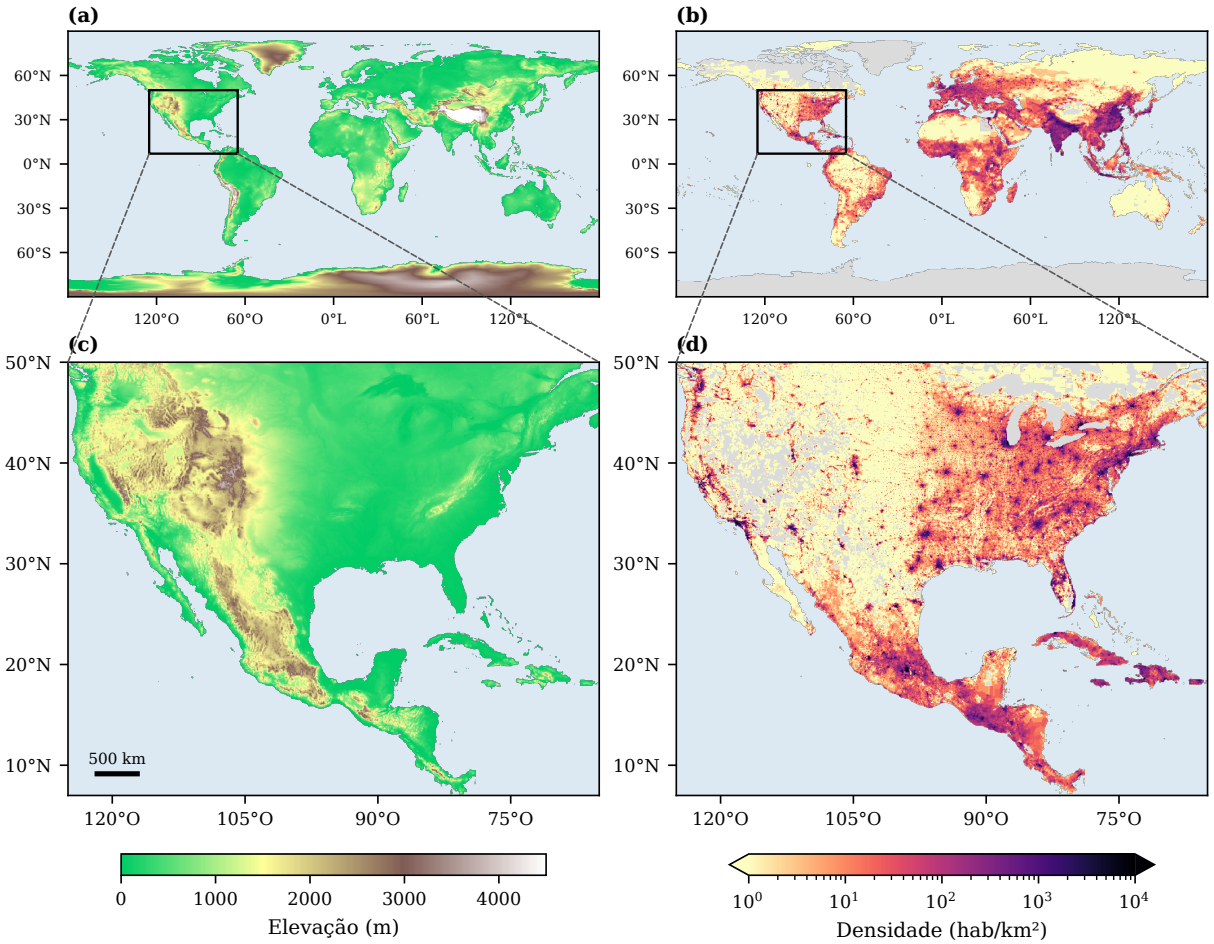
4.3 Recorte da região de estudo

A região de estudo é a caixa de longitude $-125°$ a $-65°$ e latitude 7°N a 50°N, que cobre os Estados Unidos contíguos, o sul do Canadá, o México, a América Central e o Caribe (Figura 1). A parte da caixa que pertence à América do Sul, a leste de 79°W e ao sul de 12,6°N, é tratada como oceano no relevo e tem a população zerada; o meridiano de 79°W fica logo a

leste do Canal do Panamá, para que a mancha urbana da Cidade do Panamá não seja partida. O limite norte de 50°N inclui a bacia do Mississippi–Missouri inteira e a maior parte da bacia do São Lourenço, cujas cabeceiras nos Grandes Lagos ficam dentro da caixa.

O recorte foi escolhido por três motivos. Primeiro, é a região com a maior densidade de coletas do *Nurdle Patrol* (Figura 2). Segundo, contém bacias que vão de alguns milhares a mais de três milhões de km^2 e de alguns milhares a dezenas de milhões de habitantes, o que dá amplitude para ajustar leis de escala. Terceiro, uma versão anterior deste trabalho, restrita à costa do Texas, cortava bacias grandes como a do Rio Grande, cujas cabeceiras ficavam fora da caixa; o recorte continental elimina esse problema para quase todas as bacias.

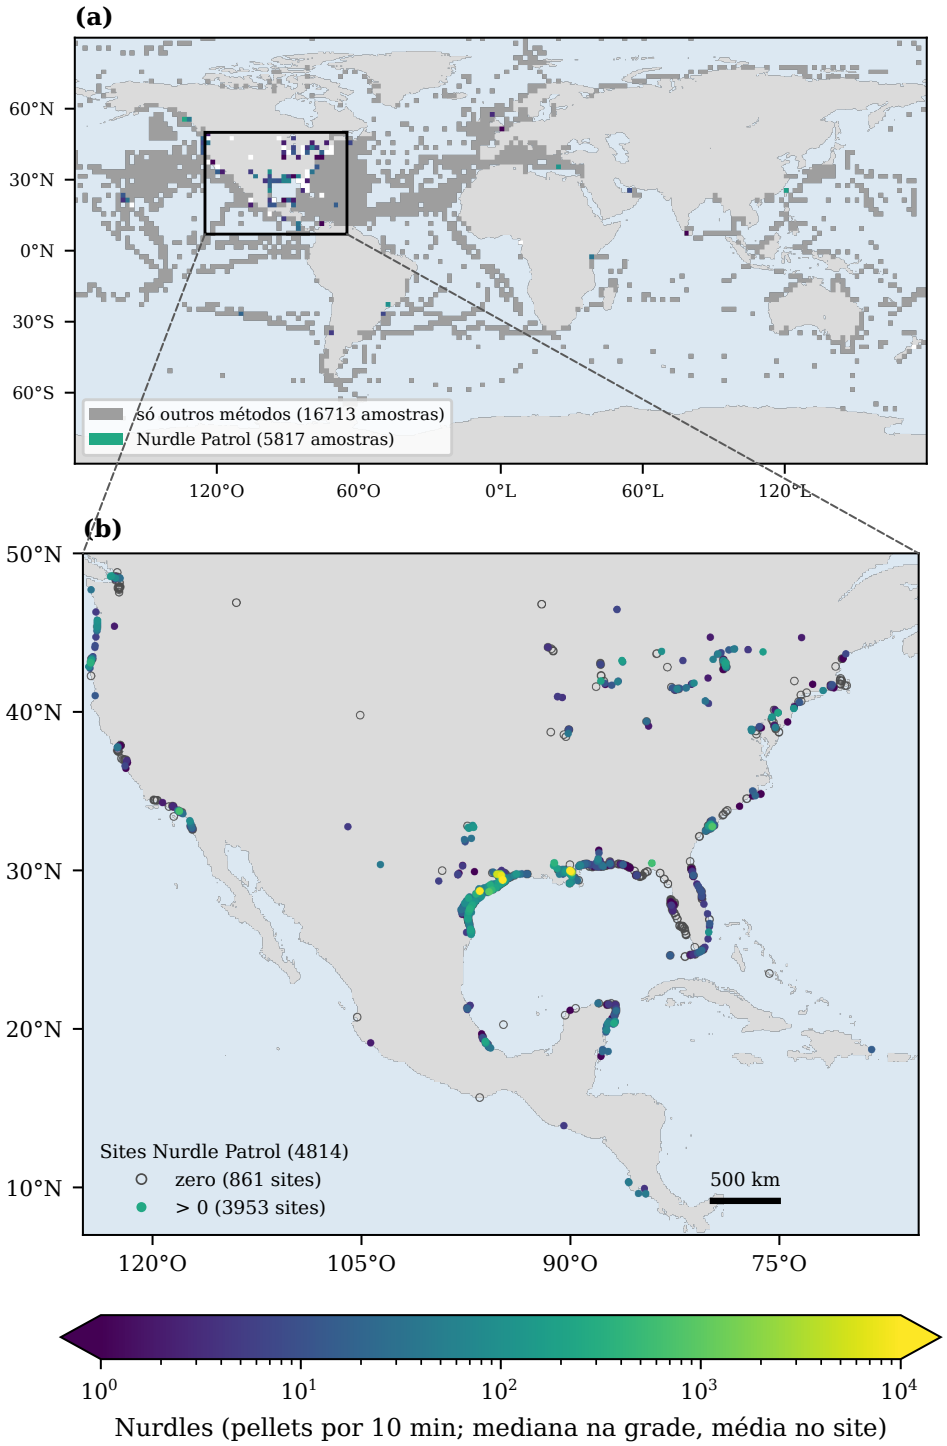
Figura 1 – Relevo (GEBCO 2024) e densidade populacional (GPW v4, 2020) no mundo, em baixa resolução, e ampliados na região de estudo



Fonte**:** elaborado pelo autor a partir de GEBCO Compilation Group (2024) e Center for International Earth Science Information Network (CIESIN) (2018).

Nota**:** (a) e (b): mundo, com o GEBCO lido de uma versão reduzida e o GPW somado em blocos de 40×40 células. (c) e (d): região de estudo. No painel (c) o oceano está em azul-claro; no painel (d), as células sem população estão em cinza.

Figura 2 – Amostras do banco de microplásticos marinhos da NOAA no mundo e sítios do *Nurdle Patrol* na região de estudo



Fonte**:** elaborado pelo autor a partir de Nyadjro *et al.* (2023).

Nota**:** (a) Grade de 2°: em cor, a mediana das amostras do *Nurdle Patrol* em cada célula; em cinza, células que só têm amostras de outros métodos. (b) Cada sítio do *Nurdle Patrol* na região de estudo, com a média das suas amostras; círculos vazios indicam contagem zero.

4.4 Bacias hidrográficas

4.4.1 Resolução do relevo

O IPBA disponível (OLIVEIRA, 2024) é implementado em Python puro: cada célula da grade é um objeto e os rótulos das bacias são gravados como inteiros sem sinal de 16 bits, o que limita o número de *sinks* a 65.535. Com a resolução nativa do GEBCO, a região de estudo teria cerca de 150 milhões de células e centenas de milhares de *sinks* costeiros. Por isso o relevo é reamostrado pela média em blocos de 8×8 células, passando para 2 minutos de arco ($\approx 3{,}7$ km). A grade resultante tem $1290 \times 1800 = 2{,}32$ milhões de células. A perda de resolução afeta sobretudo as bacias costeiras muito pequenas, que não entram na análise, e a posição exata das fozes, que passa a ser conhecida com precisão de um pixel.

4.4.2 Oceano e *sinks*

O oceano é definido como o conjunto de células com altitude menor ou igual a zero **conectadas à borda da caixa**. A condição de conexão é importante: depressões interiores abaixo do nível do mar, como o Salton Sea e o Vale da Morte, na Califórnia, e o fundo dos Grandes Lagos, continuam sendo terra, porque não são fozes. Na região de estudo, 7.643 células abaixo de zero ficam no interior e são mantidas como terra.

Todo pixel de terra 4-vizinho de um pixel de oceano é declarado um *sink*, com um rótulo próprio. O resultado são 11.851 *sinks*, abaixo do limite de 65.535 do IPBA. Essa regra dispensa qualquer lista de rios ou de fozes: a bacia de um rio grande emerge sozinha, porque todas as células a montante escoam até o *sink* da foz, enquanto os *sinks* da costa entre duas fozes recebem apenas micro-bacias de encosta. O oceano entra no IPBA como ausência de dado, para que a percolação não atravesse o mar de uma bacia para outra.

4.4.3 Delineamento e bacias principais

O IPBA (Algoritmo 1) é executado sobre o relevo reamostrado com os *sinks* costeiros e vizinhança de 4 células, sem condições de contorno periódicas. Cada célula de terra recebe o rótulo do *sink* para o qual escoa, e cada *sink* define uma bacia.

Como cada pixel de costa é um *sink*, a maioria das bacias são micro-bacias de praia com poucas células. Para ficar apenas com as bacias de rio, as bacias são ordenadas por área, da maior para a menor, e são mantidas as de maior área até que a soma das áreas atinja uma

fração P da área de terra total; a bacia que cruza o limiar também é incluída. Com $P = 0{,}90$, esse critério seleciona as bacias principais sem nenhum limiar de área mínima. A área de cada célula é calculada em km^2 a partir das suas dimensões em graus, com o fator $\cos(\text{latitude})$ para a largura.

As bacias principais que tocam a borda da caixa ou o corte do Canal do Panamá são marcadas como **truncadas**, porque parte da sua área e da sua população pode estar fora do recorte. Elas não são excluídas da análise, mas são identificadas nos resultados.

4.5 Manchas urbanas

4.5.1 Aplicação do CCA à grade do GPW

Cada célula do GPW é um sítio do CCA localizado no seu centro. A densidade de cada célula é a sua população dividida pela sua área em km^2, calculada como na seção anterior. Uma célula é ativa se a sua densidade for maior que D^*, e duas células ativas estão ligadas se a distância entre os seus centros, calculada pela fórmula do haversine sobre uma esfera de raio 6.378,137 km, for menor que ℓ. A implementação usada é a função `cca_grid` do pacote CCA do grupo de pesquisa, que busca os vizinhos com uma árvore k-d sobre a esfera.

4.5.2 Calibração de D^* e ℓ pela lei de Zipf

Os valores de D^* e ℓ determinam quais regiões contam como cidades, e valores tomados de outros contextos não servem para esta região. Os valores usados numa versão anterior deste trabalho, calibrados para o semiárido brasileiro (30 hab/km^2 e 2 km), tornavam 98% da população americana "urbana". O limiar de área urbana do censo americano, 1.000 hab/milha^2 ($\approx$ 386 hab/km^2) (U.S. Census Bureau, 2022), foi definido para os Estados Unidos e não necessariamente vale para o México e a América Central.

Por isso os dois parâmetros são escolhidos pela lei de Zipf, uma propriedade das cidades conhecida e independente do plástico. O procedimento tem quatro partes.

Grade de parâmetros. D^* varia de 10 a 3.000 hab/km^2 em passos de 10, e ℓ varia de 100 a 5.000 m em passos de 100, num total de $300 \times 50 = 15.000$ combinações. Em cada combinação, calcula-se o expoente de Zipf das manchas resultantes.

Varredura por união e busca. Executar o CCA 15 mil vezes sobre uma grade de 37 milhões de células seria proibitivo. A varredura explora uma propriedade de monotonicidade:

para um ℓ fixo, o conjunto de células ativas com limiar D_1^* contém o conjunto ativo com qualquer limiar $D_2^* > D_1^*$. Assim, se as células forem ativadas em ordem **decrescente** de densidade e cada célula nova for unida aos vizinhos já ativos a menos de ℓ, as manchas presentes no momento em que a densidade cruza um valor D^* da grade são exatamente as manchas do CCA com esse D^*. As uniões são feitas com uma estrutura de conjuntos disjuntos (*union-find*) com união por tamanho e compressão de caminho (TARJAN, 1975), a mesma ideia usada para rotular aglomerados em percolação (HOSHEN; KOPELMAN, 1976; NEWMAN; ZIFF, 2000). O Algoritmo 2 descreve o procedimento para um ℓ.

Algoritmo 2: Varredura do CCA em D^* para um ℓ fixo

Entrada: densidades ρ_k e populações x_k das células; valores $D_1^* > D_2^* > \ldots > D_m^*$; deslocamentos de vizinhança $\mathscr{V}_\ell$ válidos em cada linha da grade

Saída: populações das manchas para cada D_j^*

```
início
    ordena as células com ρ_k > D*_m em ordem decrescente de ρ_k;
    pos ← 1;
    para j ← 1 até m faça
        enquanto ρ_{k_pos} > D*_j faça
            k ← k_pos;    ativa k como um conjunto unitário de população x_k;
            para cada deslocamento (δ_i, δ_j) ∈ V_ℓ válido na linha de k faça
                q ← k + (δ_i, δ_j);
                se q está ativa e raiz(q) ≠ raiz(k) então
                    une os dois conjuntos, somando as populações;
                fim
            fim
            pos ← pos + 1;
        fim
        registra as populações das raízes: são as manchas do CCA com D*_j;
    fim
fim
```

Os deslocamentos $\mathscr{V}_\ell$ são os pares (δ_i, δ_j) de linhas e colunas cuja distância haversine é menor que ℓ. Como a largura de uma célula em km diminui com a latitude, a validade de cada deslocamento é pré-calculada para cada linha da grade. Com isso, cada ℓ exige uma única passagem pelas células, e toda a coluna de 300 valores de D^* sai dessa passagem. Valores

de ℓ que não mudam o conjunto de deslocamentos válidos, por exemplo os menores que o espaçamento entre células, repetem o resultado anterior sem nova passagem. O algoritmo foi implementado com compilação just-in-time pelo Numba (LAM; PITROU; SEIBERT, 2015), e a varredura completa leva cerca de 2 minutos e meio. A equivalência com o CCA foi verificada de duas formas: num raster de teste, a varredura reproduziu o `cca_grid` em 600 combinações de parâmetros; e na região de estudo, o número de manchas e a população da maior mancha coincidem nos parâmetros escolhidos.

Estimador do expoente. Em cada combinação, o expoente de Zipf é estimado pelo estimador de Hill (Equação 2.5) sobre as N maiores manchas, com $N = 50$, 100 e 200. Uma primeira versão usava o método CSN completo em cada combinação, com $x_{\min}$ escolhido pela distância KS, mas o $x_{\min}$ saltava de forma descontínua entre combinações vizinhas e o critério acabava escolhendo combinações degeneradas. O estimador de Hill com N fixo é estável e mede exatamente o que a lei de Zipf descreve: a inclinação do topo do *ranking*.

Critério de escolha. Os pares com $\alpha = 1$ formam uma curva no plano (D^*, ℓ), e não um ponto; é preciso um critério para escolher um par sobre ela. O critério adotado tem duas partes:

1. **Piso físico para ℓ.** São admitidos apenas valores $\ell \geq \ell_{\min} = 1.400$ m. A distância entre os centros de duas células do GPW vizinhas na diagonal chega a 1.307 m perto do equador. Com ℓ menor que isso, células vizinhas na diagonal não se ligam, e as manchas se fragmentam em faixas leste–oeste que não correspondem a cidades. Essas combinações podem produzir $\alpha \approx 1$ por acaso e precisam ser excluídas.
2. **Zipf em vários tamanhos de amostra.** Entre as combinações admitidas, escolhe-se a que minimiza

$$\Delta(D^*, \ell) = \max_{N \in \{50, 100, 200\}} \left| \hat{\alpha}_N(D^*, \ell) - 1 \right|, \tag{4.1}$$

ou seja, a combinação em que o expoente fica mais próximo de 1 simultaneamente no topo do *ranking* (50 maiores manchas) e mais abaixo nele (200 maiores).

O par escolhido é verificado aplicando o `cca_grid` com esses parâmetros e comparando as manchas com as da varredura. Como verificação independente, a distribuição completa das populações das manchas é ajustada pelo método CSN (Subseção 2.4.3), com $x_{\min}$ escolhido pela distância KS, *bootstrap* semiparamétrico com 200 réplicas para o valor-p e comparação com as distribuições lognormal, exponencial e lei de potência truncada pela razão de Vuong.

A curva completa de pares com $\alpha_{100} \approx 1$ é exportada junto com o par escolhido, para

que outros critérios possam ser comparados. Um princípio orientou todo o procedimento: os parâmetros do CCA **nunca** são ajustados para melhorar a correlação entre população e plástico, que só é calculada no segundo *notebook*, depois de os parâmetros estarem fixados.

4.5.3 Identificação das manchas

Para inspeção dos resultados, as maiores manchas recebem o nome da cidade de referência mais próxima do seu centroide, calculado com a população como peso, a partir de uma lista de coordenadas de cerca de 30 metrópoles da região. O nome é usado apenas nas tabelas e figuras e não entra em nenhum cálculo.

4.6 População por bacia

A população de uma bacia é a soma das populações das células do GPW dentro dela. Para fazer essa soma, o raster de bacias é levado para a grade do GPW pelo vizinho mais próximo, e não o contrário. A escolha da direção importa: o GPW é uma grade de **contagens**, e reamostrar contagens para uma grade mais grossa ou deslocada inventa ou duplica pessoas, enquanto o rótulo de bacia é uma variável categórica, que pode ser reamostrada sem perda de consistência.

Como a grade das bacias ($2'$) é mais grossa que a do GPW ($30''$), algumas células habitadas da linha de costa caem sobre um pixel que o relevo reamostrado classifica como oceano. Essas células são atribuídas à bacia de terra mais próxima, desde que ela esteja a no máximo 8 células do GPW (≈ 7 km). A população realocada e a que fica fora de qualquer bacia são reportadas nos resultados.

Repartição das manchas urbanas. Uma mancha urbana pode ficar sobre um divisor de águas, com parte da cidade drenando para uma bacia e parte para outra. Nesse caso a mancha é **dividida**: cada pedaço conta para a bacia em que está, porque é para lá que escoa a água, e com ela o lixo, que cai sobre ele. Uma versão anterior deste trabalho atribuía a mancha inteira à bacia que continha a maior parte da sua área, o que transferia populações inteiras para bacias vizinhas. A tabela de pedaços registra, para cada par (mancha, bacia), a população, a área e a fração da mancha naquela bacia. A população total de uma bacia não depende das manchas; elas servem para calcular a sua população urbana e para identificar quais cidades drenam para cada foz.

4.7 Microplástico por bacia

4.7.1 Sítios de coleta

São usadas as amostras do *Nurdle Patrol* com contagem definida dentro da caixa de estudo ampliada por uma margem de 50 km (o maior raio de aceitação testado), excluída a parte sul-americana. Amostras repetidas no mesmo par de coordenadas são agrupadas num **sítio**, cuja concentração é a média das contagens. O agrupamento evita que um ponto muito amostrado pese mais que os outros na associação com as bacias.

4.7.2 O sítio mais próximo da foz

A foz de cada bacia principal é o seu pixel-*sink*, uma célula de $2' \times 2'$ na linha de costa. A distância entre a foz e cada sítio é calculada pelo haversine até o ponto do pixel mais próximo do sítio, e não até o centro do pixel: uma amostra coletada dentro do pixel da foz está a 0 km dela. Cada bacia principal recebe **o sítio mais próximo da sua foz** e dois valores de microplástico:

- a **concentração**, em *pellets* por 10 minutos, no sítio mais próximo;
- o **indicador de quantidade**, dado pela concentração multiplicada pela área da bacia (*pellets*/10 min $\times$ km^2), que dá mais peso às bacias grandes, que drenam mais território.

Uma versão anterior deste trabalho atribuía a cada bacia a média de todas as amostras num círculo de 50 km ao redor da foz. Esse procedimento misturava fontes diferentes e fazia bacias vizinhas compartilharem as mesmas amostras, criando dependência artificial entre as observações. O sítio mais próximo, junto com a varredura do raio descrita a seguir, torna explícito o compromisso entre a proximidade da medição e o número de bacias.

4.8 Raio de aceitação

Uma bacia só tem microplástico "medido" se o seu sítio estiver perto da foz; um sítio a 100 km pode refletir outra bacia. Em vez de fixar um raio, o raio de aceitação R é varrido de 1 a 50 km em passos de 1 km. Para cada R são registrados:

- a fração dos sítios que estão a até R de alguma foz principal;
- o número de bacias com sítio a até R e o número de sítios distintos entre elas, já que duas bacias vizinhas podem ter o mesmo sítio mais próximo;
- o expoente β, o seu IC de 95% e o coeficiente r das leis de escala da Seção 4.9, para a

concentração e para o indicador de quantidade.

Dois raios são destacados. O primeiro é $R = 1$ km, que corresponde a uma **medição garantida**: o sítio está no pixel da foz ou encostado nele. O segundo é R_{maioria}, o **menor raio que contém a maioria** ($\geq 50\%$) dos sítios de coleta, que aproveita a maior parte da informação disponível sem aceitar distâncias arbitrariamente grandes.

4.9 Alometria por bacia

Para cada raio, a lei de escala da Equação 2.6 é ajustada entre a população X da bacia e o microplástico Y na foz, com cada bacia como uma observação. Os ajustes são feitos para as duas variáveis de resposta, concentração e indicador de quantidade, e seguem os passos abaixo.

1. Entram as bacias com sítio a até R da foz, população positiva e $Y > 0$. As contagens zero precisam sair do ajuste em escala log-log e são tratadas à parte, na discussão dos resultados.
2. O expoente β e o pré-fator $\log_{10} c$ são estimados por MQO sobre $\log_{10} X$ e $\log_{10} Y$.
3. O IC de 95% de β e a banda de confiança da reta são obtidos por *bootstrap* de pares com 10.000 reamostragens (EFRON, 1979).
4. A significância é avaliada por um teste de permutação com 10.000 permutações dos valores de Y, com hipótese nula $\beta = 0$ (GOOD, 2005).
5. São reportados o coeficiente de Pearson r entre os logaritmos e o coeficiente de Spearman ρ_s, com os respectivos valores-p.
6. A influência de bacias individuais é avaliada por um teste *leave-one-out*: o ajuste é refeito removendo uma bacia de cada vez, e registra-se a variação de r e de β.

O ajuste só é feito quando há pelo menos 5 bacias e 3 valores distintos de Y; abaixo disso, o resultado é reportado como dados insuficientes. A mesma bacia não entra duas vezes, mas duas bacias podem compartilhar o mesmo sítio; o número de sítios distintos é reportado junto com cada ajuste.

4.10 Verificações das distribuições

Como verificação da consistência do *pipeline*, três distribuições são ajustadas pelo método CSN com o pacote `powerlaw` (ALSTOTT; BULLMORE; PLENZ, 2014): a área de todas as bacias delineadas que não tocam a borda, a população de todas as bacias e a população de todas as manchas urbanas. Redes fluviais têm distribuições de área em lei de potência com

expoente γ próximo de 1,4 a 1,5 para bacias aninhadas (RODRÍGUEZ-ITURBE; RINALDO, 1997; MARITAN *et al.*, 1996), e as manchas urbanas devem seguir aproximadamente a lei de Zipf ($\gamma \approx 2$). Em cada caso, a lei de potência é comparada com a lognormal e com a exponencial pela razão de Vuong.

4.11 Implementação

Todo o processamento foi implementado em Python, com NumPy (HARRIS *et al.*, 2020), SciPy (VIRTANEN *et al.*, 2020), pandas, xarray/rioxarray e rasterio para os dados em grade, Numba (LAM; PITROU; SEIBERT, 2015) para a varredura do CCA, `powerlaw` (ALSTOTT; BULLMORE; PLENZ, 2014) para os ajustes de cauda e Matplotlib (HUNTER, 2007) para as figuras. O IPBA (OLIVEIRA, 2024) e o pacote CCA são clonados dos seus repositórios em tempo de execução. Os *notebooks* foram desenvolvidos para o Google Colab, e todos os dados são baixados automaticamente. O Apêndice A lista os arquivos, os parâmetros e as saídas de cada etapa.

5 RESULTADOS E DISCUSSÃO

Este capítulo apresenta os resultados na ordem do *pipeline*: as bacias hidrográficas (Seção 5.1), a calibração do CCA e as manchas urbanas (Seção 5.2), a repartição das manchas entre as bacias (Seção 5.3), o microplástico associado às fozes e o efeito do raio de aceitação (Seção 5.4), as leis de escala entre população e microplástico (Seção 5.5) e as verificações das distribuições (Seção 5.6). A Seção 5.7 discute o conjunto dos resultados e as suas limitações.

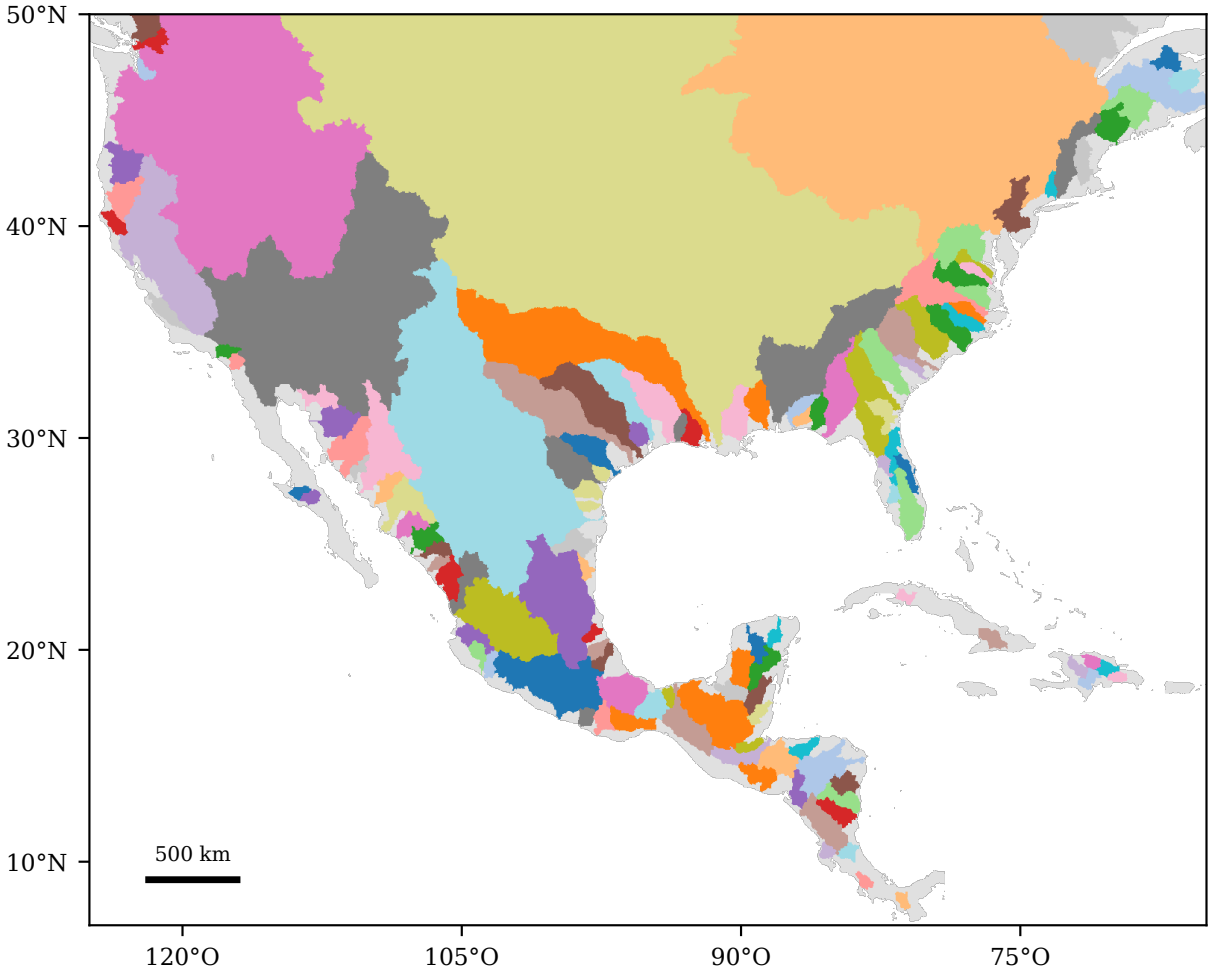
5.1 Bacias hidrográficas

O relevo reamostrado tem 11.851 *sinks* costeiros, e o IPBA produziu o mesmo número de bacias, uma por *sink*. Ordenadas por área, as 138 maiores cobrem 90,0% da área de terra da região de estudo (Figura 3); as outras 11.713 são, na grande maioria, micro-bacias de encosta com poucas células. As bacias principais têm área mediana de 13.572 km^2, e a menor delas tem 4.897 km^2. Seis bacias principais tocam a borda da caixa ou o corte do Canal do Panamá e estão marcadas como truncadas; entre elas estão as duas maiores, a do Mississippi e a do São Lourenço, cujas cabeceiras mais ao norte ficam acima de 50°N.

As bacias delineadas reproduzem as grandes bacias conhecidas do continente sem nenhuma informação além do relevo e da linha de costa. A bacia do Mississippi–Missouri ocupa o centro dos Estados Unidos, do oeste de Montana aos Apalaches; a do São Lourenço inclui os Grandes Lagos; a do Colorado drena o sudoeste até o Golfo da Califórnia; e a do Columbia drena o noroeste. No México aparecem as bacias do Rio Bravo (Rio Grande), do Pánuco, do Lerma–Santiago e do Balsas. A Tabela 2 lista as dez bacias principais mais populosas. Os nomes foram atribuídos a partir da coordenada da foz e não entram em nenhum cálculo.

A população somada das 138 bacias principais é de 450,4 milhões de habitantes, 74% dos 606,6 milhões da região de estudo; o restante vive nas bacias costeiras menores, que concentram cidades litorâneas como Nova York e boa parte da Flórida. Na passagem das bacias para a grade do GPW, 8,5 milhões de habitantes de células da linha de costa foram realocados para a bacia de terra mais próxima, e apenas 168.498 habitantes ficaram fora de qualquer bacia.

Figura 3 – As 138 bacias principais, que cobrem 90% da área de terra da região de estudo



Fonte**:** elaborado pelo autor.

Nota**:** Cada bacia principal tem uma cor (as cores se repetem); as bacias costeiras menores estão em cinza-claro.

Tabela 2 – As dez bacias principais mais populosas

Bacia	Foz (lon, lat)	Área (km^2)	População (mi)	% urbana	Sítio (km)
Mississippi–Atchafalaya*	−91,18; 29,58	3.150.557	70,20	45	37,8
São Lourenço*	−70,88; 46,92	1.374.739	61,10	60	316,9
Pánuco	−97,85; 22,35	166.272	31,50	84	114,5
Rio Bravo (Rio Grande)	−97,32; 26,28	849.584	24,24	84	9,7
Lerma–Santiago	−105,38; 21,58	133.470	22,60	75	92,3
Balsas	−102,18; 17,95	117.024	16,55	65	260,9
Colorado	−114,82; 31,85	809.665	15,87	73	229,9
Columbia*	−123,58; 46,22	1.012.275	12,86	64	35,7
Sacramento–San Joaquin	−122,25; 38,08	177.542	9,85	75	21,3
Mobile	−87,98; 30,72	171.579	8,62	18	2,0

Fonte**:** elaborado pelo autor.

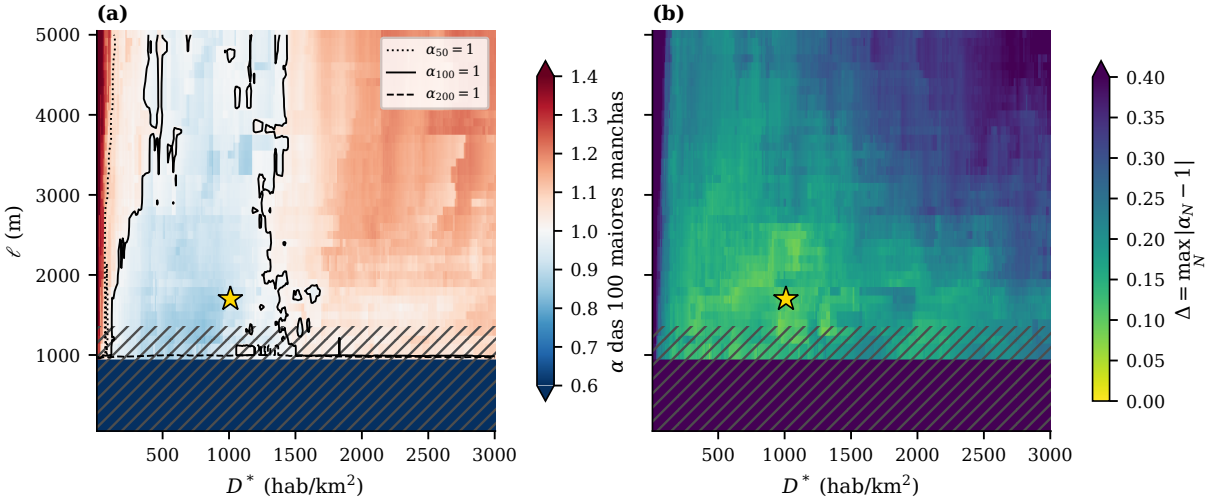
Nota**:** * bacia truncada pela borda da caixa. “% urbana” é a fração da população da bacia que vive em manchas urbanas do CCA. “Sítio” é a distância da foz ao sítio do *Nurdle Patrol* mais próximo.

5.2 Calibração do CCA e manchas urbanas

5.2.1 Matriz de expoentes

A Figura 4 mostra o expoente $\hat{\alpha}_{100}$ nas 15.000 combinações de (D^*, ℓ) e o desvio Δ da Equação 4.1. Abaixo de cerca de 1.000 m, ℓ é menor que o espaçamento entre células na mesma coluna (≈ 927 m), e só se ligam células vizinhas na mesma linha em latitudes altas, onde as células são mais estreitas; quase toda célula ativa é uma mancha, e o expoente fica entre 0,3 e 0,6, refletindo sobretudo a distribuição das densidades das células. Entre 1.000 e 1.300 m, as células se ligam na horizontal e na vertical, mas perto do equador ainda não na diagonal, e aparecem as manchas degeneradas descritas na Subseção 4.5.2. A partir de $\ell_{\min} = 1.400$ m, a curva $\hat{\alpha}_{100} = 1$ atravessa a matriz em valores de D^* entre cerca de 400 e 1.100 hab/km^2.

Figura 4 – Expoente de Zipf e desvio Δ na grade de parâmetros do CCA



Fonte**:** elaborado pelo autor.

Nota**:** (a) $\hat{\alpha}_{100}$ em cada combinação de D^* e ℓ, com as curvas $\hat{\alpha}_N = 1$ para $N = 50$, 100 e 200. (b) Desvio $\Delta = \max_N |\hat{\alpha}_N - 1|$. A faixa hachurada, $\ell < \ell_{\min} = 1.400$ m, é excluída da escolha; a estrela marca o par escolhido.

A Tabela 3 mostra, para cada ℓ entre 1.400 e 2.600 m, o D^* que minimiza Δ. O mínimo global ocorre em $\ell = 1.700$ m e $D^* = 1.010$ hab/km^2, com $\Delta = 0{,}081$. O mínimo é raso: todos os valores de ℓ entre 1.400 e 2.400 m têm um D^* com $\Delta < 0{,}10$, e o D^* ótimo fica entre 820 e 1.110 hab/km^2 em quase todos eles. Em todas as linhas da tabela, $\hat{\alpha}_{200}$ é maior que 1 e é ele que determina Δ; os expoentes do topo, $\hat{\alpha}_{50}$ e $\hat{\alpha}_{100}$, ficam entre 0,90 e 0,97. Esse padrão, em que o expoente cresce com N, é discutido na Subseção 5.2.3.

O par escolhido tem uma interpretação física razoável. O limiar de 1.010 hab/km^2

Tabela 3 – Melhor D^* para cada ℓ admitido pelo critério Δ

ℓ (m)	D^* (hab/km^2)	Δ	$\hat{\alpha}_{50}$	$\hat{\alpha}_{100}$	$\hat{\alpha}_{200}$
1.400	960	0,081	0,919	0,926	1,053
1.500	970	0,088	0,917	0,912	1,079
1.600	1.040	0,098	0,903	0,917	1,098
1.700	**1.010**	**0,081**	**0,925**	**0,939**	**1,081**
1.800	630	0,090	0,910	0,915	1,088
1.900	820	0,091	0,959	0,909	1,089
2.000	850	0,097	0,942	0,903	1,096
2.100	1.110	0,090	0,936	0,945	1,090
2.200	1.100	0,093	0,963	0,950	1,093
2.300	1.110	0,083	0,965	0,942	1,083
2.400	1.110	0,085	0,952	0,947	1,085
2.500	1.110	0,100	0,962	0,959	1,100
2.600	1.110	0,108	0,961	0,965	1,108

Fonte**:** elaborado pelo autor.

Nota**:** Em negrito, o par escolhido. Para $\ell > 2.600$ m, o menor Δ passa de 0,13.

é cerca de 2,6 vezes o limiar de área urbana do censo americano (386 hab/km^2) (U.S. Census Bureau, 2022), o que é esperado, já que o GPW distribui a população de cada unidade censitária de forma homogênea e suaviza os picos de densidade. A distância de 1,7 km é pouco maior que a diagonal entre células vizinhas, o que significa que as manchas são praticamente conjuntos de células ativas contíguas, com tolerância para vãos de uma célula.

5.2.2 Manchas urbanas

Com $D^* = 1.010$ hab/km^2 e $\ell = 1.700$ m, o CCA identifica 12.185 manchas urbanas, que somam 349,5 milhões de habitantes, 58% da população da região. O `cca_grid` aplicado com esses parâmetros produziu exatamente o mesmo número de manchas e a mesma população da maior mancha que a varredura (20.602.596 habitantes), confirmando a equivalência entre os dois procedimentos. A Tabela 4 lista as dez maiores manchas. Sem nenhuma lista de cidades fornecida ao algoritmo, elas correspondem às grandes metrópoles da região, com os centroides a poucos quilômetros dos centros urbanos.

A tabela tem duas particularidades. A primeira é que as manchas mexicanas e caribenhas são mais densas que as americanas: Cidade do México, Guadalajara e Monterrey têm mais de 7.800 hab/km^2, contra 2.400 a 4.700 hab/km^2 nas metrópoles dos Estados Unidos, o que reflete a forma mais compacta dessas cidades. A segunda é um artefato do GPW em Monterrey: cerca de 3 milhões de pessoas estão concentradas em uns 20 pixels, com densidades de até 810

Tabela 4 – As dez maiores manchas urbanas ($D^* = 1.010$ hab/km^2, $\ell = 1.700$ m)

Posto	Mancha	População	Área (km^2)	Densidade (hab/km^2)	Centroide (lon, lat)
1	Cidade do México	20.602.596	2.204	9.349	−99,10; 19,45
2	Nova York	15.482.384	3.316	4.669	−73,92; 40,75
3	Los Angeles	14.240.127	4.017	3.545	−118,03; 33,98
4	Chicago	6.335.092	2.253	2.812	−87,83; 41,85
5	Toronto	6.029.628	1.372	4.394	−79,49; 43,71
6	Miami	5.329.254	2.073	2.570	−80,24; 26,05
7	Guadalajara	5.073.091	594	8.547	−103,35; 20,63
8	Monterrey	4.971.276	637	7.800	−100,28; 25,72
9	Houston	4.814.175	1.982	2.429	−95,46; 29,76
10	Santo Domingo	4.737.554	947	5.004	−69,92; 18,50

Fonte**:** elaborado pelo autor a partir de Center for International Earth Science Information Network (CIESIN) (2018).

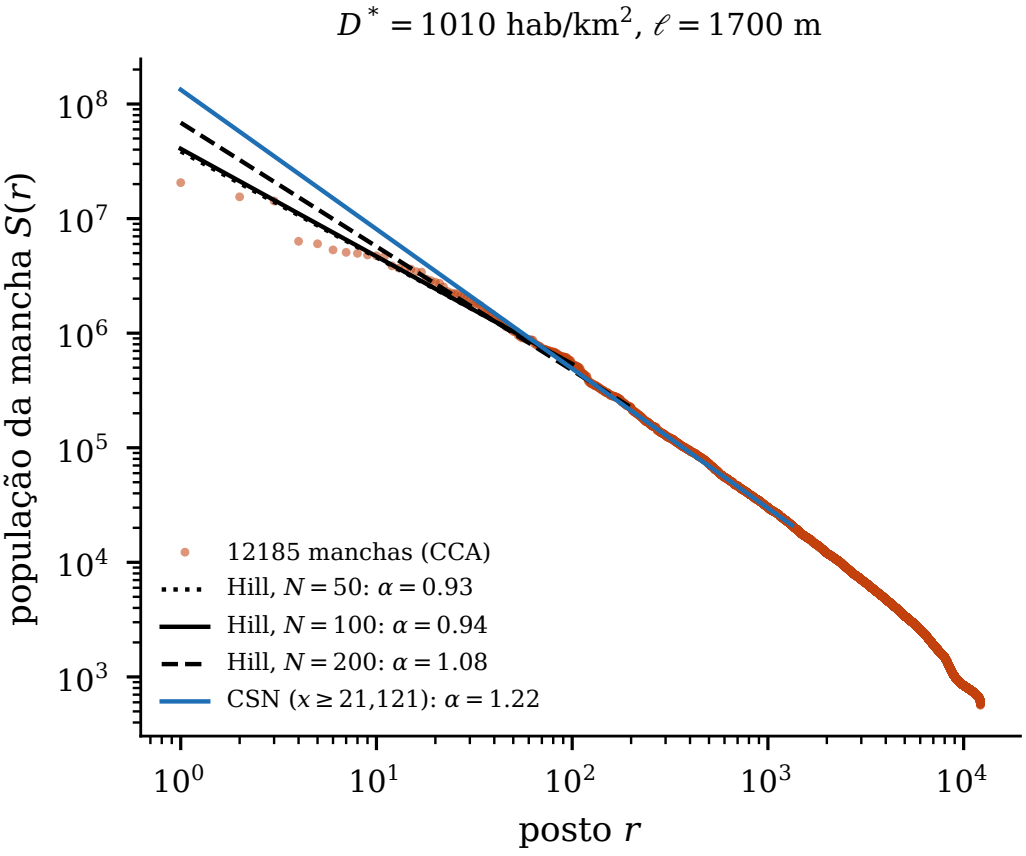
mil hab/km^2, fisicamente impossíveis. O artefato provavelmente vem de uma unidade censitária muito pequena que recebeu uma população grande. Ele não muda a mancha, porque todas essas células já estão acima de D^* e a população total é a mesma, mas mostra que valores de densidade de células individuais do GPW precisam ser lidos com cautela. O dado não foi alterado.

5.2.3 Distribuição *rank-size*

A Figura 5 mostra a distribuição *rank-size* das manchas. No topo do *ranking*, a distribuição segue de perto a lei de Zipf: os estimadores de Hill dão $\hat{\alpha}_{50} = 0{,}925$, $\hat{\alpha}_{100} = 0{,}939$ e $\hat{\alpha}_{200} = 1{,}081$. Mais abaixo no *ranking*, a curva fica mais íngreme. O ajuste CSN sobre a cauda escolhe $x_{\min} = 21.121$ habitantes, com 1.325 manchas na cauda, e dá $\hat{\gamma} = 1{,}822 \pm 0{,}023$, ou seja, $\hat{\alpha} = 1{,}217 \pm 0{,}033$. A distância KS é 0,017, abaixo do valor crítico de 0,037, e o *bootstrap* dá $p = 0{,}08$, próximo do limiar convencional de 0,1. A regressão log-log sobre a mesma cauda dá $\alpha = 1{,}16$ ($R^2 = 0{,}994$).

A distribuição é, portanto, **côncava** no gráfico log-log: o expoente cresce à medida que se incluem manchas menores. A comparação pela razão de Vuong confirma essa leitura. A lei de potência é fortemente preferida à exponencial ($R = 8{,}64$, $p < 10^{-17}$), não se distingue da lognormal ($R = -1{,}29$, $p = 0{,}20$) e perde para a lei de potência truncada ($R = -2{,}52$, $p = 0{,}004$), que tem exatamente essa curvatura. O resultado concorda com a literatura: Eeckhout (2004) mostrou que a distribuição completa das cidades americanas é lognormal e que a lei de Zipf vale apenas na cauda superior, e Rozenfeld *et al.* (2011) encontraram a lei de Zipf nas manchas do CCA acima de um tamanho mínimo. A conclusão prática é que a calibração garante a lei de Zipf para as maiores manchas, que são as que mais pesam na população das bacias, mas não para a

Figura 5 – Distribuição *rank-size* das 12.185 manchas urbanas



Fonte**:** elaborado pelo autor.

Nota**:** Retas de Hill para as 50, 100 e 200 maiores manchas e reta do ajuste CSN sobre a cauda ($x \geq x_{\min}$).

distribuição inteira.

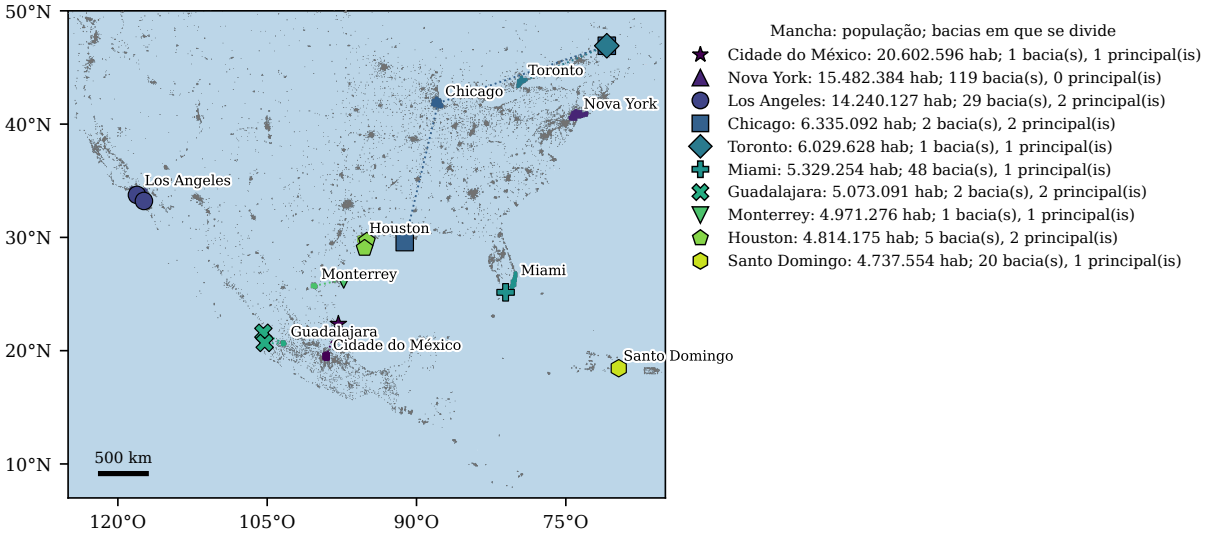
5.3 Repartição das manchas entre as bacias

Das 12.185 manchas, 618 cruzam divisores de água e foram divididas entre duas ou mais bacias. São poucas em número, mas grandes: somam 41% da população urbana, o que mostra que a repartição não é um detalhe. A Figura 6 mostra as dez maiores manchas e as fozes das bacias principais que recebem pedaços delas, e a Figura 7 sobrepõe as bacias, as manchas e os sítios de coleta.

Os casos das maiores manchas ilustram os três comportamentos possíveis.

- **Mancha inteira numa bacia principal.** A Cidade do México está 100% na bacia do Pánuco, que deságua no Golfo do México perto de Tampico, a mais de 300 km da cidade; o mesmo vale para Guadalajara (Lerma–Santiago), Monterrey (Rio Bravo) e Toronto (São Lourenço). São casos em que o método atribui a população a uma foz distante, que uma

Figura 6 – As dez maiores manchas urbanas e as fozes das bacias principais em que se dividem



Fonte**:** elaborado pelo autor.

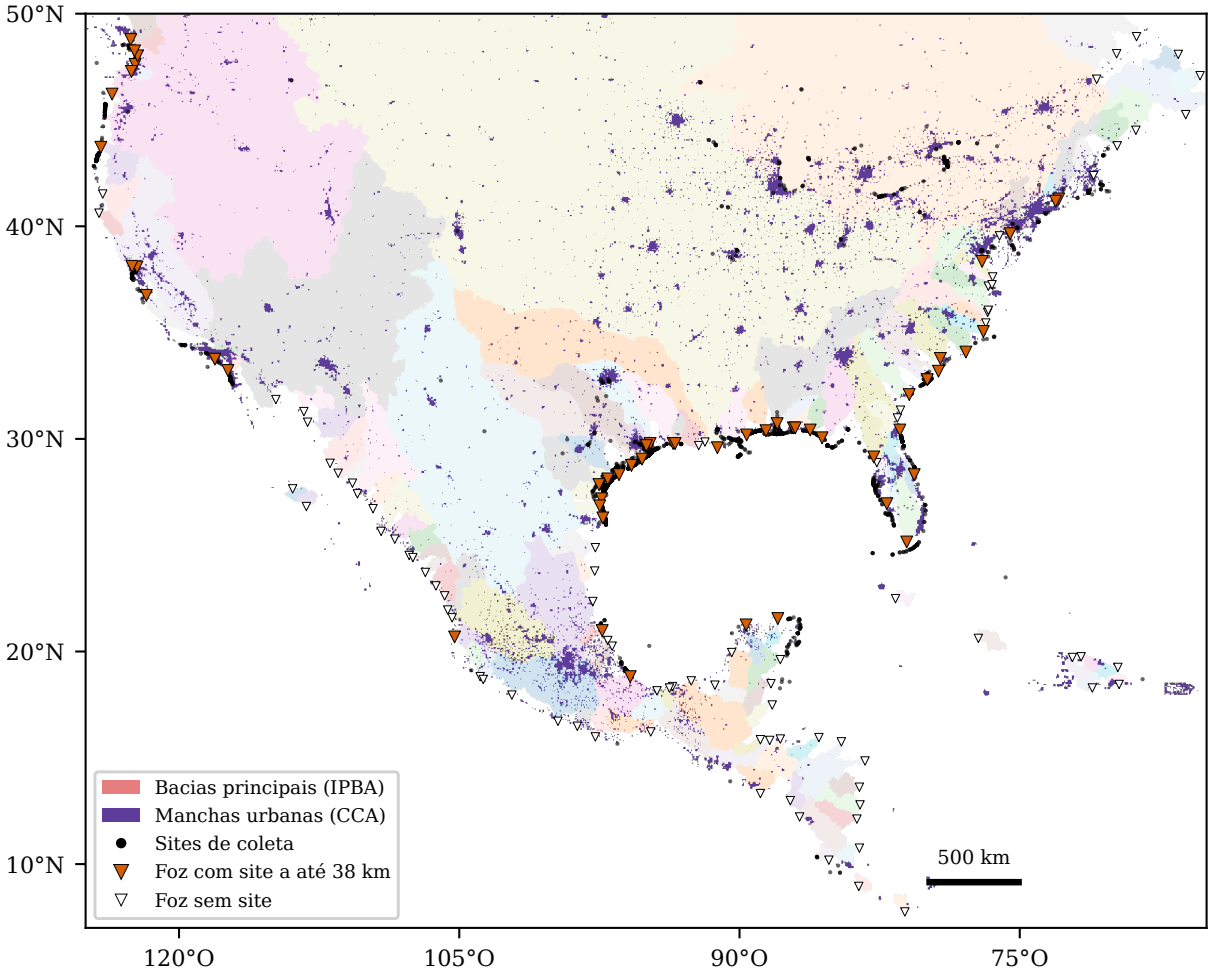
Nota**:** Cada mancha tem uma cor e um símbolo; o símbolo marca a foz de cada bacia principal que recebe um pedaço da mancha, ligada ao centroide por uma linha pontilhada. Na exibição, as dez manchas foram dilatadas em cerca de 11 km para ficarem visíveis na escala continental. As demais manchas estão em cinza.

análise baseada em proximidade costeira não encontraria.

- **Mancha dividida entre bacias principais.** Chicago fica sobre o divisor entre o Lago Michigan e o rio Illinois: 83% da mancha drena para o São Lourenço e 17% para o Mississippi. Houston se divide entre cinco bacias, duas delas principais.
- **Mancha em bacias costeiras pequenas.** Nova York se divide entre 119 bacias, nenhuma delas principal; o maior pedaço tem 10% da mancha. Com um *sink* por pixel de costa, a Baía de Nova York e a foz do Hudson se fragmentam em muitas micro-bacias na grade de $2'$, e a cidade não é associada a nenhuma bacia de rio. Los Angeles e Miami têm comportamento semelhante: cerca de 40% e 56% das manchas, respectivamente, ficam em bacias principais, e o restante se espalha por dezenas de bacias costeiras.

O último caso é uma limitação importante. Grandes cidades litorâneas que ficam em estuários fragmentados, como Nova York, são justamente as que mais poderiam contribuir com plástico para o mar e ficam fora das bacias principais. Uma solução seria agrupar os *sinks* de uma mesma baía ou estuário antes de rodar o IPBA, o que é discutido como trabalho futuro no Capítulo 6.

Figura 7 – Bacias principais, manchas urbanas, sítios de coleta e fozes



Fonte**:** elaborado pelo autor.

Nota**:** Triângulos cheios: fozes com sítio do *Nurdle Patrol* a até $R_{\text{maioria}} = 38$ km; triângulos vazios: fozes sem sítio nesse raio.

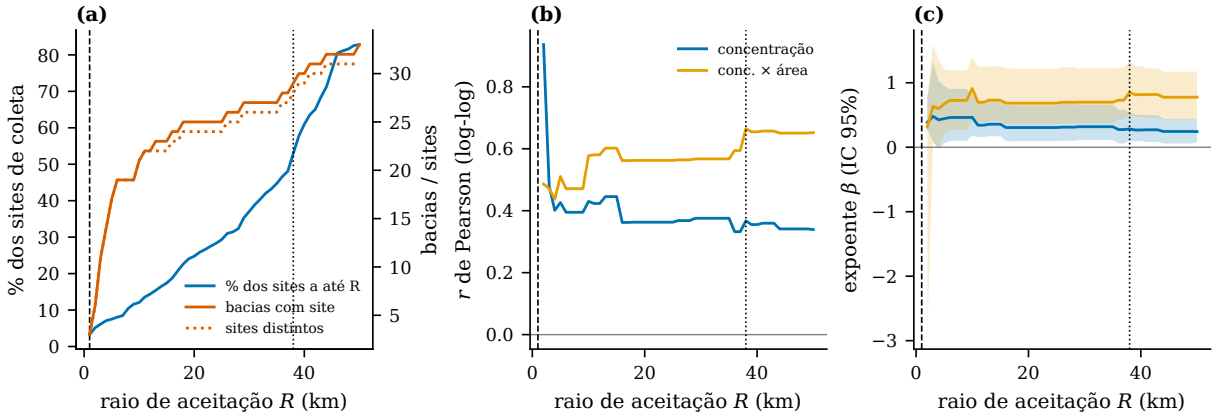
5.4 Microplástico nas fozes e raio de aceitação

Dentro da caixa ampliada pela margem de 50 km há 5.783 amostras do *Nurdle Patrol* em 4.814 sítios distintos, dos quais 861 têm contagem média zero. A distribuição espacial é muito desigual (Figura 2): a maior parte dos sítios está na costa do Golfo do México, do Texas à Flórida, com grupos menores na costa atlântica, na costa do Pacífico e nos Grandes Lagos, e poucos sítios no México, na América Central e no Caribe. A distância mediana entre a foz de uma bacia principal e o sítio mais próximo é de 88,1 km, e apenas 6 das 138 fozes têm um sítio a até 1 km.

A Figura 8 e a Tabela 5 mostram o efeito do raio de aceitação. A fração dos sítios a até R de alguma foz principal cresce devagar até cerca de 30 km e acelera depois disso; o menor raio que contém a maioria dos sítios é $R_{\text{maioria}} = 38$ km, com 53% deles. O número de

bacias com sítio e contagem positiva cresce rápido nos primeiros 10 km, chegando a 21, e depois devagar, até 33 em 50 km.

Figura 8 – Efeito do raio de aceitação entre a foz e o sítio de coleta



Fonte**:** elaborado pelo autor.

Nota**:** (a) Fração dos sítios a até R de uma foz principal, número de bacias com sítio e número de sítios distintos. (b) Coeficiente de Pearson r entre os logaritmos da população e do microplástico. (c) Expoente β com IC de 95%. Linha tracejada: $R = 1$ km; linha pontilhada: $R_{\text{maioria}} = 38$ km. Só entram as bacias com contagem positiva.

Tabela 5 – Leis de escala entre população e microplástico em função do raio de aceitação

				Concentração			Conc. × área	
R (km)	% sítios	Bacias	Sítios	β	r	p	β	r
1	3,3	3	3	–	–	–	–	–
2	5,2	6	6	0,386	0,936	0,006	0,313	0,486
5	7,5	17	17	0,443	0,427	0,088	0,672	0,511
10	12,1	21	21	0,464	0,430	0,052	0,912	0,578
20	24,8	25	24	0,306	0,363	0,075	0,683	0,562
30	37,1	27	26	0,318	0,376	0,054	0,699	0,567
38	**53,0**	**29**	**28**	**0,283**	**0,367**	**0,050**	**0,849**	**0,665**
40	61,0	30	29	0,267	0,355	0,054	0,816	0,655
50	82,8	33	31	0,243	0,339	0,054	0,778	0,652

Fonte**:** elaborado pelo autor.

Nota**:** “Bacias”: bacias principais com sítio a até R e contagem positiva; “Sítios”: sítios distintos entre elas. p é o valor-p do coeficiente de Pearson. Com $R = 1$ km há apenas 3 bacias com contagem positiva, insuficientes para o ajuste.

Medição garantida ($R = 1$ km). Seis bacias principais têm um sítio a até 1 km da foz, mas três delas têm contagem zero, e restam apenas três com contagem positiva: as de Los Angeles (San Gabriel), a de Galveston–Houston e uma pequena bacia do sul do Texas. Com três pontos não é possível ajustar uma lei de escala nem avaliar a sua significância. O painel (a) da Figura 9 mostra esses pontos apenas para referência.

Raios pequenos. Com $R = 2$ km, as seis bacias com contagem positiva dão $r = 0{,}94$ ($p = 0{,}006$) para a concentração. O valor é alto, mas se apoia em seis pontos e cai para cerca de 0,43 já em $R = 5$ km, com 17 bacias. Ele é um exemplo do risco de escolher o raio pelo resultado: a varredura mostra que valores altos de r em raios pequenos são flutuações de amostras minúsculas.

Estabilidade a partir de 10 km. De 10 a 50 km, o r da concentração fica entre 0,34 e 0,45 e o β entre 0,24 e 0,47, com valores-p entre 0,05 e 0,09. Para o indicador de quantidade, r fica entre 0,56 e 0,67 e β entre 0,68 e 0,91. A relação é, portanto, estável em relação ao raio, mas fraca e no limite da significância estatística convencional para a concentração.

5.5 Leis de escala entre população e microplástico

A Figura 9 mostra as relações entre a população das bacias e o microplástico nas fozes, e a Tabela 6 resume os ajustes para $R_{\text{maioria}} = 38$ km. As 29 bacias com contagem positiva usam 28 sítios distintos.

Tabela 6 – Leis de escala entre população da bacia e microplástico na foz ($R = 38$ km)

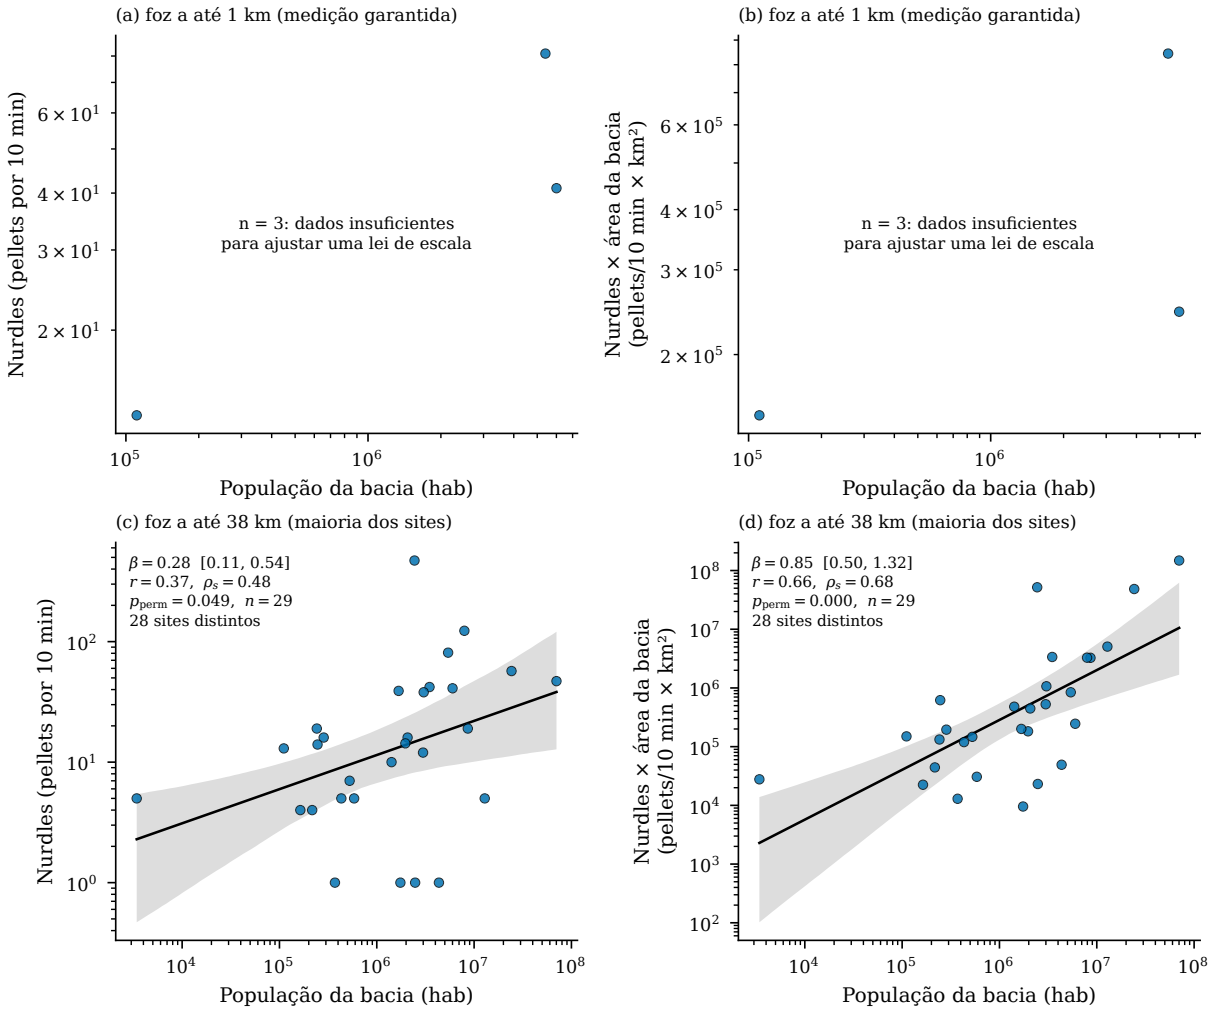
Variável	n	β	IC 95%	p_{perm}	r	ρ_s	R^2
Concentração	29	0,283	[0,108; 0,539]	0,049	0,367	0,480	0,135
Concentração × área	29	0,849	[0,503; 1,321]	$< 0{,}001$	0,665	0,684	0,442

Fonte**:** elaborado pelo autor.
Nota**:** IC por *bootstrap* de pares (10.000 reamostragens); p_{perm} por permutação (10.000 permutações).

Concentração. A concentração de *pellets* na foz cresce com a população da bacia segundo um expoente $\beta = 0{,}28$, com IC de 95% de 0,11 a 0,54, que exclui o zero, e $p_{\text{perm}} = 0{,}049$. A relação é fortemente **sublinear**: dobrar a população da bacia está associado a um aumento de apenas $2^{0{,}28} - 1 \approx 21\%$ na concentração. A dispersão é grande: $r = 0{,}37$ e $R^2 = 0{,}13$, ou seja, a população explica cerca de 13% da variância do logaritmo da concentração. A correlação de postos é um pouco maior, $\rho_s = 0{,}48$ ($p = 0{,}008$), o que indica que parte da fraqueza do ajuste linear vem de pontos extremos, como a bacia com 471 *pellets* por 10 minutos na costa central do Texas.

Indicador de quantidade. Multiplicando a concentração pela área da bacia, o expoente sobe para $\beta = 0{,}85$ (IC de 0,50 a 1,32), com $r = 0{,}66$ e $p_{\text{perm}} < 0{,}001$. O resultado parece muito mais forte, mas a maior parte dele vem da área, e não do plástico. Como $\log(\text{concentração} \times A) = \log(\text{concentração}) + \log A$, e o MQO é linear, o expoente do indicador

Figura 9 – População das bacias versus microplástico na foz



Fonte**:** elaborado pelo autor.

Nota**:** (a) e (b): bacias com sítio a até 1 km da foz. (c) e (d): bacias com sítio a até $R_{\text{maioria}} = 38$ km. Em (a) e (c), concentração de *pellets*; em (b) e (d), concentração multiplicada pela área da bacia. Retas: MQO em log-log; faixas: banda de confiança de 95% por *bootstrap*.

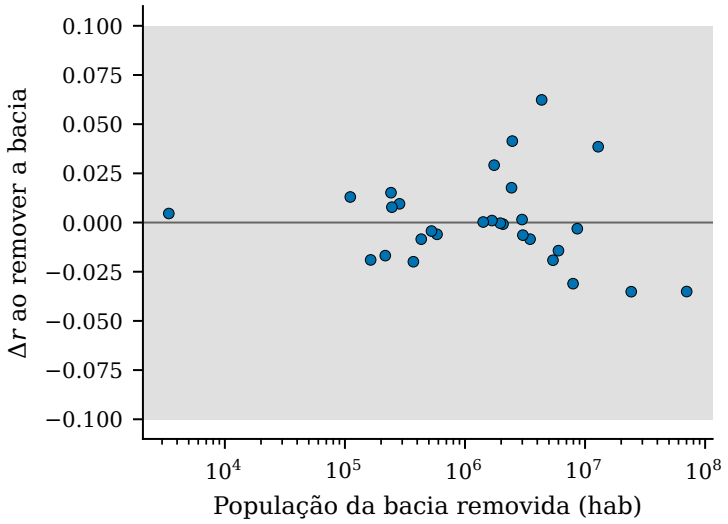
de quantidade é a soma do expoente da concentração com o expoente da área em função da população: $0{,}85 = 0{,}28 + 0{,}57$. Nas bacias com sítio, a área e a população estão fortemente correlacionadas ($\rho_s = 0{,}67$, $p < 10^{-7}$), porque bacias maiores tendem a ter mais gente. O indicador de quantidade herda essa correlação, que existiria mesmo que a concentração de plástico fosse aleatória. Ele não deve, portanto, ser lido como evidência independente de que a população determina o plástico.

Contagens zero. Das 52 bacias principais com sítio a até 38 km, 23 têm contagem zero e ficam fora dos ajustes em log-log. A exclusão não é neutra: se as bacias com zero fossem sistematicamente menos populosas, excluí-las aumentaria artificialmente a inclinação. Os dados não indicam esse viés: a população mediana das bacias com zero é de 1,10 milhão de habitantes, contra 1,97 milhão nas bacias com contagem positiva, diferença que não é significativa (teste

de Mann–Whitney, $p = 0{,}50$). Mas a inclusão dos zeros enfraquece a associação. Com as 52 bacias, a correlação de postos entre população e concentração cai para $\rho_s = 0{,}25$ ($p = 0{,}07$), e entre população e indicador de quantidade para $\rho_s = 0{,}32$ ($p = 0{,}02$).

Influência de bacias individuais. O teste *leave-one-out* (Figura 10) mostra que nenhuma bacia isolada determina o resultado da concentração: removendo uma bacia de cada vez, r varia de 0,33 a 0,43 e β de 0,25 a 0,35. As bacias de maior influência são as mais populosas, Mississippi e Rio Bravo, cuja remoção reduz r em cerca de 0,035, e uma bacia do noroeste da Flórida, com foz perto de Panama City, cuja remoção aumenta r em 0,06.

Figura 10 – Variação do coeficiente r ao remover cada bacia do ajuste da concentração ($R = 38$ km)



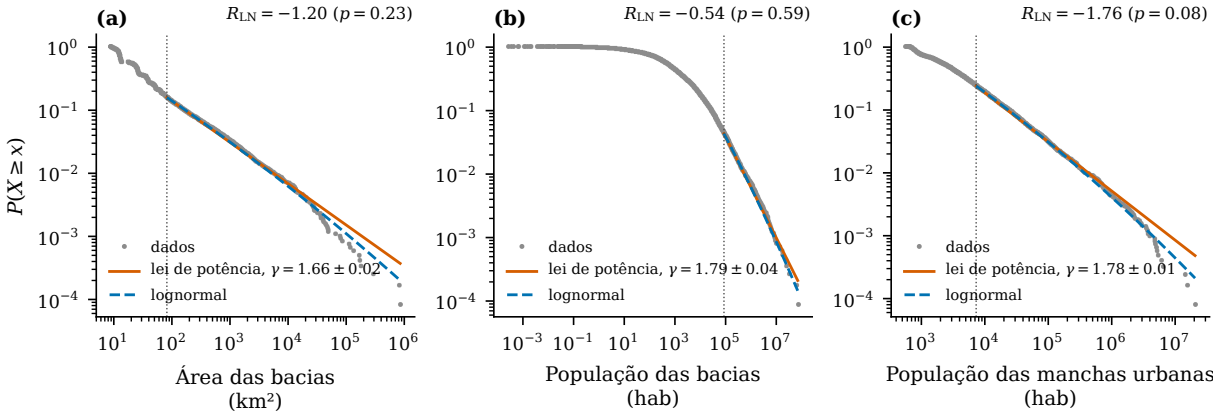
Fonte**:** elaborado pelo autor.
Nota**:** A faixa cinza marca $|\Delta r| \leq 0{,}1$.

5.6 Distribuições de tamanho

A Figura 11 e a Tabela 7 mostram os ajustes de cauda das áreas das bacias, das populações das bacias e das populações das manchas urbanas. As três distribuições têm cauda pesada, e em todas a lei de potência é fortemente preferida à exponencial.

A área das bacias segue uma lei de potência com $\hat{\gamma} = 1{,}66$ a partir de 82 km^2, indistinguível da lognormal. O expoente é maior que os valores de 1,4 a 1,5 típicos da distribuição de áreas de sub-bacias aninhadas numa rede fluvial (RODRÍGUEZ-ITURBE; RINALDO, 1997; MARITAN *et al.*, 1996), o que é esperado: aqui as bacias não são aninhadas, mas uma partição do continente em bacias costeiras disjuntas, e as bacias grandes “roubam” área das vizinhas. A

Figura 11 – Distribuições complementares acumuladas das áreas e populações das bacias e das populações das manchas urbanas



Fonte**:** elaborado pelo autor.

Nota**:** Linhas: lei de potência (contínua) e lognormal (tracejada) ajustadas acima de $x_{\min}$ (linha vertical pontilhada). R_{LN} é a razão de verossimilhança normalizada entre a lei de potência e a lognormal.

Tabela 7 – Ajustes de cauda pelo método CSN

Distribuição	n	$x_{\min}$	**Cauda**	$\hat{\gamma}$	R_{LN} (p)	R_{exp} (p)
Área das bacias (km^2)	11.794	82	1.877	$1{,}655 \pm 0{,}015$	$-1{,}20$ (0,23)	8,19 ($< 10^{-15}$)
População das bacias	11.134	86.142	482	$1{,}795 \pm 0{,}036$	$-0{,}54$ (0,59)	5,93 ($< 10^{-8}$)
População das manchas	12.185	7.301	2.939	$1{,}782 \pm 0{,}014$	$-1{,}76$ (0,08)	10,99 ($< 10^{-27}$)

Fonte**:** elaborado pelo autor.

Nota**:** Área das bacias: apenas as que não tocam a borda. R_{LN} e R_{exp}: razões de verossimilhança normalizadas entre a lei de potência e a lognormal e a exponencial; valores positivos favorecem a lei de potência.

população das bacias tem cauda com $\hat{\gamma} = 1{,}80$, também indistinguível da lognormal. A população das manchas urbanas, com $x_{\min}$ mais baixo que no ajuste do primeiro *notebook*, dá $\hat{\gamma} = 1{,}78$, ou seja, $\alpha = 1/(\hat{\gamma} - 1) \approx 1{,}28$, coerente com a concavidade discutida na Subseção 5.2.3; nesse caso, a lognormal é marginalmente preferida ($p = 0{,}08$).

5.7 Discussão

5.7.1 O que os resultados dizem sobre a hipótese

A hipótese de trabalho era que a quantidade de microplástico na foz cresce com a população da bacia. Os resultados a sustentam apenas em parte. A associação entre população e concentração de *pellets* é positiva em todos os raios testados, estável entre 10 e 50 km e com IC que exclui o zero em R_{maioria}. Mas é fraca, com a população explicando cerca de 13% da variância, fica no limite da significância estatística e enfraquece quando as contagens zero são

incluídas. O indicador de quantidade dá uma relação mais forte, mas herda a correlação entre população e área e não constitui evidência independente.

O expoente sublinear da concentração, $\beta \approx 0{,}28$, tem pelo menos quatro explicações possíveis, que não se excluem.

1. **Diluição.** Bacias mais populosas tendem a ser maiores e a ter vazões maiores. Se a carga de plástico cresce com a população, mas a vazão cresce com a área, a concentração na foz cresce menos que a carga. A concentração numa praia não é uma carga, e uma relação linear entre população e carga é compatível com uma relação sublinear entre população e concentração.
2. **Fonte industrial.** Os *pellets* são um microplástico primário cuja perda está ligada à produção e ao transporte de resinas, e não ao consumo (KARLSSON *et al.*, 2018). As maiores contagens estão na costa do Texas (TUNNELL *et al.*, 2020), onde se concentra a indústria petroquímica, e não necessariamente nas bacias mais populosas. A população da bacia é, nesse caso, um indicador indireto da atividade industrial.
3. **Transporte costeiro.** Uma vez no mar, os *pellets* são redistribuídos por correntes e pela deriva litorânea e depositados em praias que podem estar a dezenas de quilômetros da foz de origem. O sítio mais próximo pode refletir a soma de várias fozes.
4. **Ruído amostral.** A maioria dos sítios associados às bacias tem uma única amostra, feita num único dia, e as contagens de *pellets* variam muito com o tempo, as marés e as tempestades.

5.7.2 O papel das escolhas metodológicas

Algumas escolhas feitas ao longo do trabalho protegem os resultados de interpretações otimistas. Os parâmetros do CCA foram fixados pela lei de Zipf antes de qualquer contato com os dados de plástico, e a varredura mostrou que o critério escolhe uma região estável da matriz de parâmetros e não um ponto isolado. O raio de aceitação não foi escolhido pelo resultado, mas por um critério de cobertura dos sítios, e a varredura completa mostra que o resultado não depende criticamente dele. O $r = 0{,}94$ obtido com $R = 2$ km, que seria o resultado mais "favorável", foi reportado como o que é: uma flutuação de seis pontos. As contagens zero, que precisam sair do ajuste em log-log, foram analisadas à parte com uma medida de postos.

Outras escolhas limitam o alcance dos resultados:

- **Resolução do relevo.** A reamostragem para $2'$, imposta pela implementação em Python

puro do IPBA, faz com que a foz seja conhecida com precisão de cerca de 3,7 km e fragmenta estuários complexos, como o de Nova York, em muitas micro-bacias. Um “sítio a até 1 km” significa a até 1 km desse pixel.

- **Bacias truncadas.** A caixa corta as cabeceiras mais ao norte das bacias do Mississippi e do São Lourenço e as bacias que drenam para a Baía de Hudson; o IPBA atribui as partes dentro da caixa às bacias vizinhas.
- **Cobertura das coletas.** O *Nurdle Patrol* concentra-se no Golfo do México. Das 138 bacias principais, apenas 52 têm sítio a até 38 km, e o México, a América Central e o Caribe contribuem com poucas delas. As bacias com medição não são uma amostra aleatória das bacias do continente.
- **Tipo de microplástico.** Os *pellets* são um tipo específico de microplástico primário, e os resultados não se estendem automaticamente aos microplásticos secundários, como fibras e fragmentos, que têm fontes difusas e mais diretamente ligadas ao consumo.
- **Concentração versus carga.** A contagem por 10 minutos de busca numa praia é uma medida de concentração local, não da carga transportada pelo rio. Um teste mais direto da hipótese exigiria medições de carga fluvial, que não estão disponíveis numa escala continental.

6 CONCLUSÃO

Esta dissertação testou se a população que vive numa bacia hidrográfica está associada ao microplástico medido na foz dessa bacia, na América do Norte e Central, dos Estados Unidos e sul do Canadá até o Canal do Panamá. Para isso, construiu um *pipeline* que cruza três bases públicas e independentes: o relevo do GEBCO 2024, a população do GPW v4 e as contagens de *pellets* plásticos do *Nurdle Patrol* no banco de microplásticos marinhos da NOAA.

6.1 Síntese dos resultados

Bacias. O IPBA, com todos os pixels de terra vizinhos ao oceano como saídas, particionou o continente em 11.851 bacias costeiras sem nenhuma lista de rios. As 138 maiores cobrem 90% da área de terra e reproduzem as grandes bacias conhecidas, do Mississippi ao Balsas, e somam 74% da população da região.

Manchas urbanas. A calibração do CCA pela lei de Zipf, feita numa grade de 15 mil combinações de parâmetros por um algoritmo de união e busca que reproduz o CCA exatamente, escolheu $D^{*} = 1.010$ hab/km^2 e $\ell = 1{,}7$ km. Com esses valores, as 12.185 manchas urbanas seguem a lei de Zipf no topo do *ranking* ($\hat{\alpha}$ entre 0,93 e 1,08 para as 50, 100 e 200 maiores), mas a distribuição completa é côncava, com $\alpha \approx 1{,}22$ na cauda ajustada pelo método CSN. O piso físico para ℓ mostrou-se necessário para evitar soluções degeneradas.

Repartição. As 618 manchas que cruzam divisores de água somam 41% da população urbana, e a sua repartição entre as bacias muda substancialmente a população atribuída a cada foz. O método atribuiu corretamente cidades interiores, como a Cidade do México, Guadalajara e Monterrey, a fozes distantes centenas de quilômetros, mas deixou grandes cidades litorâneas em estuários fragmentados, como Nova York, fora das bacias principais.

Microplástico e população. Com o raio de aceitação que contém a maioria dos sítios de coleta ($R = 38$ km), 52 bacias têm medição, 29 com contagem positiva. Nessas 29, a concentração de *pellets* cresce de forma sublinear com a população, com $\beta = 0{,}28$ (IC de 95%: 0,11 a 0,54) e $r = 0{,}37$. A relação é estável entre 10 e 50 km, não depende de nenhuma bacia isolada, mas é fraca: a população explica cerca de 13% da variância, e a correlação de postos cai para $\rho_s = 0{,}25$ ($p = 0{,}07$) quando as contagens zero são incluídas. O indicador de quantidade (concentração $\times$ área) dá $\beta = 0{,}85$ e $r = 0{,}66$, mas dois terços desse expoente vêm da correlação entre população e área das bacias. Com medição garantida, a até 1 km da foz, só três bacias estão disponíveis.

6.2 Resposta à pergunta de pesquisa

Os dados públicos disponíveis sustentam, no máximo, uma associação **positiva, sublinear e fraca** entre a população de uma bacia e a concentração de *pellets* plásticos na sua foz. Eles não permitem afirmar que a população determina o microplástico que chega ao mar, nem estimar com precisão o expoente dessa relação. A principal limitação não está nos métodos, mas nos dados de plástico: as coletas se concentram no Golfo do México, raramente coincidem com fozes, têm em geral uma única amostra por sítio e medem um tipo de microplástico, os *pellets*, cuja fonte é mais industrial do que populacional.

Esse resultado é, em si, relevante. Os modelos globais de emissão de plástico por rios usam a população da bacia como variável explicativa central (LEBRETON *et al.*, 2017; MEIJER *et al.*, 2021). A fraqueza da associação encontrada aqui com medições de campo independentes sugere cautela na extrapolação desses modelos e reforça a necessidade de medições sistemáticas nas fozes.

6.3 Contribuições

As contribuições do trabalho são:

- um *pipeline* reprodutível e aberto que integra relevo, população e microplástico numa análise por bacia, executável a partir de dois *notebooks*;
- o uso do IPBA com todos os *sinks* costeiros e de um critério de cobertura de área para selecionar as bacias principais sem listas manuais nem limiares de área;
- um algoritmo de varredura do CCA em tempo quase linear por valor de ℓ, exato em relação ao CCA, que torna viável explorar milhares de combinações de parâmetros sobre grades de dezenas de milhões de células;
- um critério de calibração do CCA pela lei de Zipf robusto a variações do tamanho da amostra e com um piso físico para a distância de ligação;
- a repartição das manchas urbanas entre bacias e a demonstração de que ela afeta quase metade da população urbana;
- uma análise explícita da sensibilidade ao raio de aceitação, que evita escolher o raio pelo resultado.

6.4 Trabalhos futuros

Os resultados sugerem as seguintes extensões.

- **Agrupar *sinks* de estuários.** Unir os *sinks* de uma mesma baía ou estuário antes do IPBA, por exemplo agrupando pixels de costa separados por menos de alguns quilômetros de água, permitiria associar cidades como Nova York a uma única foz.
- **Relevo em resolução maior.** Uma implementação compilada do IPBA, com rótulos de 32 bits, permitiria usar o GEBCO na resolução nativa de 15″, localizando as fozes com precisão de algumas centenas de metros e aumentando o número de bacias com medição garantida.
- **Outras medidas de plástico.** Aplicar o mesmo *pipeline* a medições de microplástico secundário na água ou no sedimento de estuários, ou a medições de carga fluvial, que testariam a hipótese de forma mais direta.
- **Modelos para as contagens.** Tratar as contagens zero com modelos de contagem, como regressões binomiais negativas com inflação de zeros, em vez de excluí-las do ajuste em log-log.
- **Covariáveis industriais.** Incluir a localização de fábricas de resina e terminais portuários como covariável, para separar o efeito da população do efeito da indústria no caso dos *pellets*.
- **Transporte costeiro.** Ponderar os sítios por um modelo simples de deriva litorânea, em vez de usar apenas o sítio mais próximo da foz.
- **Outras regiões.** Aplicar o *pipeline* a outras regiões com boa cobertura de coletas, como a Europa ou o litoral brasileiro, onde há programas de monitoramento de *pellets* em praias.

REFERÊNCIAS

ALSTOTT, J.; BULLMORE, E.; PLENZ, D. powerlaw: a Python package for analysis of heavy-tailed distributions. **PLoS ONE**, v. 9, n. 1, p. e85777, 2014.

ANDRADY, A. L. Microplastics in the marine environment. **Marine Pollution Bulletin**, v. 62, n. 8, p. 1596–1605, 2011.

ARCAUTE, E.; HATNA, E.; FERGUSON, P.; YOUN, H.; JOHANSSON, A.; BATTY, M. Constructing cities, deconstructing scaling laws. **Journal of the Royal Society Interface**, v. 12, n. 102, p. 20140745, 2015.

BARNES, D. K. A.; GALGANI, F.; THOMPSON, R. C.; BARLAZ, M. Accumulation and fragmentation of plastic debris in global environments. **Philosophical Transactions of the Royal Society B: Biological Sciences**, v. 364, n. 1526, p. 1985–1998, 2009.

BETTENCOURT, L. M. A. The origins of scaling in cities. **Science**, v. 340, n. 6139, p. 1438–1441, 2013.

BETTENCOURT, L. M. A.; LOBO, J.; HELBING, D.; KÜHNERT, C.; WEST, G. B. Growth, innovation, scaling, and the pace of life in cities. **Proceedings of the National Academy of Sciences**, v. 104, n. 17, p. 7301–7306, 2007.

BROWNE, M. A.; CRUMP, P.; NIVEN, S. J.; TEUTEN, E.; TONKIN, A.; GALLOWAY, T.; THOMPSON, R. Accumulation of microplastic on shorelines worldwide: sources and sinks. **Environmental Science & Technology**, v. 45, n. 21, p. 9175–9179, 2011.

CAMINHA, C.; FURTADO, V.; PEQUENO, T. H. C.; PONTE, C.; MELO, H. P. M.; OLIVEIRA, E. A.; ANDRADE JR., J. S. Human mobility in large cities as a proxy for crime. **PLoS ONE**, v. 12, n. 2, p. e0171609, 2017.

Center for International Earth Science Information Network (CIESIN). **Gridded Population of the World, Version 4 (GPWv4): Population Count, Revision 11**. Palisades, NY: [s.n.], 2018. NASA Socioeconomic Data and Applications Center (SEDAC).

CLAUSET, A.; SHALIZI, C. R.; NEWMAN, M. E. J. Power-law distributions in empirical data. **SIAM Review**, v. 51, n. 4, p. 661–703, 2009.

COTTINEAU, C.; HATNA, E.; ARCAUTE, E.; BATTY, M. Diverse cities or the systematic paradox of urban scaling laws. **Computers, Environment and Urban Systems**, v. 63, p. 80–94, 2017.

EECKHOUT, J. Gibrat's law for (all) cities. **American Economic Review**, v. 94, n. 5, p. 1429–1451, 2004.

EFRON, B. Bootstrap methods: another look at the jackknife. **The Annals of Statistics**, v. 7, n. 1, p. 1–26, 1979.

ERIKSEN, M.; LEBRETON, L. C. M.; CARSON, H. S.; THIEL, M.; MOORE, C. J.; BORERRO, J. C.; GALGANI, F.; RYAN, P. G.; REISSER, J. Plastic pollution in the world's oceans: more than 5 trillion plastic pieces weighing over 250,000 tons afloat at sea. **PLoS ONE**, v. 9, n. 12, p. e111913, 2014.

FEHR, E.; ANDRADE JR., J. S.; CUNHA, S. D. da; SILVA, L. R. da; HERRMANN, H. J.; KADAU, D.; MOUKARZEL, C. F.; OLIVEIRA, E. A. New efficient methods for calculating watersheds. **Journal of Statistical Mechanics: Theory and Experiment**, v. 2009, p. P09007, 2009.

FEHR, E.; KADAU, D.; ARAÚJO, N. A. M.; ANDRADE JR., J. S.; HERRMANN, H. J. Scaling relations for watersheds. **Physical Review E**, v. 84, n. 3, p. 036116, 2011.

FRIAS, J. P. G. L.; NASH, R. Microplastics: finding a consensus on the definition. **Marine Pollution Bulletin**, v. 138, p. 145–147, 2019.

GABAIX, X. Zipf's law for cities: an explanation. **The Quarterly Journal of Economics**, v. 114, n. 3, p. 739–767, 1999.

GEBCO Compilation Group. **GEBCO 2024 Grid**. 2024. British Oceanographic Data Centre (NERC EDS).

GEYER, R.; JAMBECK, J. R.; LAW, K. L. Production, use, and fate of all plastics ever made. **Science Advances**, v. 3, n. 7, p. e1700782, 2017.

GOOD, P. I. **Permutation, Parametric and Bootstrap Tests of Hypotheses**. 3. ed. New York: Springer, 2005.

HARRIS, C. R.; MILLMAN, K. J.; WALT, S. J. van der *et al.* Array programming with NumPy. **Nature**, v. 585, p. 357–362, 2020.

HIDALGO-RUZ, V.; GUTOW, L.; THOMPSON, R. C.; THIEL, M. Microplastics in the marine environment: a review of the methods used for identification and quantification. **Environmental Science & Technology**, v. 46, n. 6, p. 3060–3075, 2012.

HILL, B. M. A simple general approach to inference about the tail of a distribution. **The Annals of Statistics**, v. 3, n. 5, p. 1163–1174, 1975.

HOSHEN, J.; KOPELMAN, R. Percolation and cluster distribution. I. Cluster multiple labeling technique and critical concentration algorithm. **Physical Review B**, v. 14, n. 8, p. 3438–3445, 1976.

HUNTER, J. D. Matplotlib: a 2D graphics environment. **Computing in Science & Engineering**, v. 9, n. 3, p. 90–95, 2007.

JAMBECK, J. R.; GEYER, R.; WILCOX, C.; SIEGLER, T. R.; PERRYMAN, M.; ANDRADY, A.; NARAYAN, R.; LAW, K. L. Plastic waste inputs from land into the ocean. **Science**, v. 347, n. 6223, p. 768–771, 2015.

JIANG, B.; JIA, T. Zipf's law for all the natural cities in the United States: a geospatial perspective. **International Journal of Geographical Information Science**, v. 25, n. 8, p. 1269–1281, 2011.

KARLSSON, T. M.; ARNEBORG, L.; BROSTRÖM, G.; ALMROTH, B. C.; GIPPERTH, L.; HASSELLÖV, M. The unaccountability case of plastic pellet pollution. **Marine Pollution Bulletin**, v. 129, n. 1, p. 52–60, 2018.

LAM, S. K.; PITROU, A.; SEIBERT, S. Numba: a LLVM-based Python JIT compiler. In: **Proceedings of the Second Workshop on the LLVM Compiler Infrastructure in HPC**. New York: ACM, 2015.

LEBRETON, L. C. M.; ZWET, J. van der; DAMSTEEG, J.-W.; SLAT, B.; ANDRADY, A.; REISSER, J. River plastic emissions to the world's oceans. **Nature Communications**, v. 8, p. 15611, 2017.

MARITAN, A.; RINALDO, A.; RIGON, R.; GIACOMETTI, A.; RODRÍGUEZ-ITURBE, I. Scaling laws for river networks. **Physical Review E**, v. 53, n. 2, p. 1510–1515, 1996.

MATO, Y.; ISOBE, T.; TAKADA, H.; KANEHIRO, H.; OHTAKE, C.; KAMINUMA, T. Plastic resin pellets as a transport medium for toxic chemicals in the marine environment. **Environmental Science & Technology**, v. 35, n. 2, p. 318–324, 2001.

MEIJER, L. J. J.; EMMERIK, T. van; ENT, R. van der; SCHMIDT, C.; LEBRETON, L. More than 1000 rivers account for 80% of global riverine plastic emissions into the ocean. **Science Advances**, v. 7, n. 18, p. eaaz5803, 2021.

MELO, H. P. M.; MOREIRA, A. A.; BATISTA, É.; MAKSE, H. A.; ANDRADE JR., J. S. Statistical signs of social influence on suicides. **Scientific Reports**, v. 4, p. 6239, 2014.

NEWMAN, M. E. J. Power laws, Pareto distributions and Zipf's law. **Contemporary Physics**, v. 46, n. 5, p. 323–351, 2005.

NEWMAN, M. E. J.; ZIFF, R. M. Efficient Monte Carlo algorithm and high-precision results for percolation. **Physical Review Letters**, v. 85, n. 19, p. 4104–4107, 2000.

NYADJRO, E. S.; WEBSTER, J. A. B.; BOYER, T. P. *et al.* The NOAA NCEI marine microplastics database. **Scientific Data**, v. 10, p. 726, 2023.

O'CALLAGHAN, J. F.; MARK, D. M. The extraction of drainage networks from digital elevation data. **Computer Vision, Graphics, and Image Processing**, v. 28, n. 3, p. 323–344, 1984.

OLIVEIRA, E. A. **IPBA: Invasion Percolation Based Algorithm in Python**. 2024. Repositório de código. Disponível em: https://github.com/erneson/IPBA.

OLIVEIRA, E. A.; ANDRADE JR., J. S.; MAKSE, H. A. Large cities are less green. **Scientific Reports**, v. 4, p. 4235, 2014.

RODRÍGUEZ-ITURBE, I.; RINALDO, A. **Fractal River Basins: Chance and Self-Organization**. Cambridge: Cambridge University Press, 1997.

ROZENFELD, H. D.; RYBSKI, D.; ANDRADE JR., J. S.; BATTY, M.; STANLEY, H. E.; MAKSE, H. A. Laws of population growth. **Proceedings of the National Academy of Sciences**, v. 105, n. 48, p. 18702–18707, 2008.

ROZENFELD, H. D.; RYBSKI, D.; GABAIX, X.; MAKSE, H. A. The area and population of cities: new insights from a different perspective on cities. **American Economic Review**, v. 101, n. 5, p. 2205–2225, 2011.

SCHMIDT, C.; KRAUTH, T.; WAGNER, S. Export of plastic debris by rivers into the sea. **Environmental Science & Technology**, v. 51, n. 21, p. 12246–12253, 2017.

SOO, K. T. Zipf's law for cities: a cross-country investigation. **Regional Science and Urban Economics**, v. 35, n. 3, p. 239–263, 2005.

TARBOTON, D. G. A new method for the determination of flow directions and upslope areas in grid digital elevation models. **Water Resources Research**, v. 33, n. 2, p. 309–319, 1997.

TARJAN, R. E. Efficiency of a good but not linear set union algorithm. **Journal of the ACM**, v. 22, n. 2, p. 215–225, 1975.

THOMPSON, R. C.; OLSEN, Y.; MITCHELL, R. P.; DAVIS, A.; ROWLAND, S. J.; JOHN, A. W. G.; MCGONIGLE, D.; RUSSELL, A. E. Lost at sea: where is all the plastic? **Science**, v. 304, n. 5672, p. 838, 2004.

TUNNELL, J. W.; DUNNING, K. H.; SCHEEF, L. P.; SWANSON, K. M. Measuring plastic pellet (nurdle) abundance on shorelines throughout the Gulf of Mexico using citizen scientists: establishing a platform for policy-relevant research. **Marine Pollution Bulletin**, v. 151, p. 110794, 2020.

U.S. Census Bureau. **Urban Area Criteria for the 2020 Census—Final Criteria**. 2022. Federal Register, v. 87, n. 57, p. 16706–16715.

VIRTANEN, P.; GOMMERS, R.; OLIPHANT, T. E. *et al.* SciPy 1.0: fundamental algorithms for scientific computing in Python. **Nature Methods**, v. 17, p. 261–272, 2020.

VUONG, Q. H. Likelihood ratio tests for model selection and non-nested hypotheses. **Econometrica**, v. 57, n. 2, p. 307–333, 1989.

WILKINSON, D.; WILLEMSEN, J. F. Invasion percolation: a new form of percolation theory. **Journal of Physics A: Mathematical and General**, v. 16, n. 14, p. 3365–3376, 1983.

YONKOS, L. T.; FRIEDEL, E. A.; PEREZ-REYES, A. C.; GHOSAL, S.; ARTHUR, C. D. Microplastics in four estuarine rivers in the Chesapeake Bay, U.S.A. **Environmental Science & Technology**, v. 48, n. 24, p. 14195–14202, 2014.

ZIPF, G. K. **Human Behavior and the Principle of Least Effort**. Cambridge, MA: Addison-Wesley, 1949.

GLOSSÁRIO

A

Alometria: relação de escala entre duas grandezas de um sistema na forma de lei de potência, $y = c\,x^{\beta}$; é linear se $\beta = 1$, sublinear se $\beta < 1$ e superlinear se $\beta > 1$.

B

Bacia hidrográfica: região cujo escoamento superficial converge para uma mesma saída; neste trabalho, o conjunto de pixels de terra que drenam para um mesmo *sink* costeiro.

F

Foz: ponto em que uma bacia hidrográfica deságua no oceano; aqui, o pixel-*sink* da bacia na grade de relevo.

L

Lei de Zipf: regularidade empírica segundo a qual a população da r-ésima maior cidade decai como r^{-1}.

M

Mancha urbana: aglomerado de pixels densamente povoados e próximos entre si, definido pelo CCA sem recorrer a fronteiras administrativas.

N

***Nurdle*:** *pellet* de resina plástica pré-produção, com alguns milímetros de diâmetro, usado como matéria-prima da indústria de transformação de plásticos.

P

Percolação invasiva: processo em que um fluido invade um meio sempre pelo ponto de menor resistência da fronteira já invadida; no relevo, a resistência é a altitude.

S

***Sink*:** pixel de saída de uma bacia na percolação; todo pixel de terra vizinho ao oceano é um *sink*.

APÊNDICE A – Reprodutibilidade

Todo o processamento desta dissertação está em dois *notebooks* Jupyter, desenvolvidos para o Google Colab, que baixam os dados e o código de terceiros em tempo de execução. Este apêndice lista os arquivos, os parâmetros e as saídas de cada etapa.

A.1 Ordem de execução

1. `01_Zipf_calibracao_CCA.ipynb`: lê o GPW v4, executa a varredura de (D^*, ℓ), escolhe o par pelo critério Δ, verifica o resultado com o `cca_grid`, ajusta a distribuição das manchas pelo método CSN e grava `results/cca_calibracao.json`.
2. `02_Micro_Plastic.ipynb`: lê os parâmetros do CCA do arquivo anterior e executa o recorte, o IPBA, a seleção das bacias principais, o CCA, a repartição das manchas, a associação do microplástico às fozes, a varredura do raio e os ajustes de escala. O IPBA, em Python puro, é a etapa mais lenta.

A.2 Dados e código de terceiros

- GEBCO 2024: lido diretamente da cópia em formato COG em https://data.source.coop/alexgleith/gebco-2024/GEBCO_2024.tif (GEBCO Compilation Group, 2024).
- GPW v4.11, contagem de população de 2020, 30 segundos de arco (Center for International Earth Science Information Network (CIESIN), 2018).
- Banco de microplásticos marinhos do NCEI/NOAA, exportado em CSV (NYADJRO *et al.*, 2023).
- IPBA: https://github.com/erneson/IPBA (OLIVEIRA, 2024).
- Pacote CCA com a função `cca_grid`: https://github.com/skaduhs5232/CCA.

A.3 Parâmetros

A Tabela 8 lista todos os parâmetros do *pipeline* e a origem de cada valor. Nenhum deles foi ajustado a partir da relação entre população e microplástico.

A.4 Saídas

As saídas são gravadas na pasta `results/` com o sufixo `na_panama`:

Tabela 8 – Parâmetros do *pipeline*

Parâmetro	Valor	Origem
Caixa de estudo	$[-125,-65] \times [7,50]$	Região com maior cobertura do *Nurdle Patrol*; inclui a bacia do Mississippi inteira
Corte do Canal do Panamá	lon $> -79°$ e lat $<$ 12,6°	Exclui a América do Sul sem partir a Cidade do Panamá
Reamostragem do GEBCO	8×8 ($2'$)	Limite de 65.535 *sinks* do IPBA
Vizinhança dos *sinks* e do IPBA	4 células	Padrão do IPBA
Cobertura das bacias principais P	0,90	Especificação do trabalho
Grade de D^*	10 a 3.000 hab/km^2, passo 10	Especificação do trabalho
Grade de ℓ	100 a 5.000 m, passo 100	Especificação do trabalho
$\ell_{\min}$	1.400 m	Diagonal entre células do GPW (1.307 m)
N do estimador de Hill	50, 100 e 200	Topo do *ranking*
D^* escolhido	1.010 hab/km^2	Mínimo de Δ (Equação 4.1)
ℓ escolhido	1.700 m	Mínimo de Δ (Equação 4.1)
Realocação costeira	até 8 células do GPW (≈ 7 km)	Diferença de resolução entre GEBCO reamostrado e GPW
Margem da busca de sítios	50 km	Maior raio testado
Raio de aceitação R	1 a 50 km, passo 1	Especificação do trabalho
R_{maioria}	38 km	Menor R com $\geq 50\%$ dos sítios
Reamostragens do *bootstrap*	10.000 (2.000 na varredura de R)	Convenção
Permutações	10.000 (2.000 na varredura de R)	Convenção
Reamostragens do teste CSN	200	Convenção

Fonte**:** elaborado pelo autor.

- `cca_calibracao.json`: parâmetros escolhidos, expoentes de Hill, Δ, critério e ajuste CSN;
- `zipf_matriz_*.npz` e `zipf_curva_alpha1_*.csv`: matriz de expoentes e curva $\alpha = 1$;
- `zipf_clusters_*.csv`: todas as manchas urbanas com população, área, centroide e nome;
- `bacias_*.csv`: bacias principais com área, população, população urbana, foz, sítio mais próximo, distância e microplástico;
- `manchas_por_bacia_*.csv`: pedaços das manchas em cada bacia;
- `varredura_raio_*.csv` e `escala_pop_lixo_*.csv`: varredura do raio e ajustes de escala;
- `leis_potencia_*.csv`: ajustes de cauda;
- figuras em PDF e PNG, as mesmas usadas nesta dissertação.

APÊNDICE B – Bacias principais com sítio de coleta a até 38 km da foz

A Tabela 9 lista as 52 bacias principais com sítio do *Nurdle Patrol* a até $R_{\text{maioria}} = 38$ km da foz, ordenadas pela população. As 29 bacias com contagem positiva entram nos ajustes em log-log da Seção 5.5; as 23 com contagem zero entram apenas nas correlações de postos. "Bacia" é o rótulo do *sink* da foz no IPBA; "Lon." e "Lat." são as coordenadas do pixel da foz; "Dist." é a distância da foz ao sítio mais próximo.

Tabela 9 – Bacias principais com sítio a até 38 km da foz

Bacia	Lon.	Lat.	Área (km^2)	Pop. (mi)	Dist. (km)	*Pellets*/10 min	No ajuste
4479*	−91,18	29,58	3.150.557	70,20	37,8	47,0	sim
5937	−97,32	26,28	849.584	24,24	9,7	57,0	sim
1136*	−123,58	46,22	1.012.275	12,86	35,7	5,0	sim
2591	−122,25	38,08	177.542	9,85	21,3	0,0	não
3868	−87,98	30,72	171.579	8,62	2,0	19,0	sim
4263	−94,78	29,78	46.863	8,33	3,3	0,0	não
2228	−75,52	39,65	26.636	7,94	4,2	123,0	sim
2492	−77,02	38,35	35.859	7,43	35,9	0,0	não
3395	−118,08	33,75	5.988	6,00	0,0	41,0	sim
4372	−94,98	29,68	10.417	5,41	0,0	81,0	sim
6314	−81,05	25,15	31.631	4,85	4,3	0,0	não
3483	−79,35	33,18	40.876	4,70	36,4	0,0	não
4146	−85,58	30,05	49.156	4,35	15,9	1,0	sim
4863	−95,22	29,05	80.218	3,48	1,4	42,0	sim
5124	−96,45	28,32	28.097	3,03	1,1	38,0	sim
9208	−95,85	18,82	43.985	2,99	4,0	12,0	sim
3386	−79,25	33,78	36.791	2,81	32,5	0,0	não
1912	−72,92	41,28	30.953	2,75	15,0	0,0	não
3284	−77,88	34,08	23.128	2,48	3,7	1,0	sim
4980	−95,78	28,75	110.090	2,44	5,5	471,0	sim
3970	−81,42	30,42	13.689	2,39	13,3	0,0	não
4095	−89,62	30,18	27.922	2,07	17,5	16,0	sim
936	−122,35	47,62	5.103	2,05	6,8	0,0	não
3126	−76,95	35,05	12.760	1,97	3,8	14,3	sim
5126	−80,65	28,32	9.561	1,75	2,5	1,0	sim

Bacia	Lon.	Lat.	Área (km^2)	Pop. (mi)	Dist. (km)	*Pellets*/10 min	No ajuste
3480	−117,38	33,22	5.139	1,68	9,6	39,0	sim
3612	−80,92	32,08	36.271	1,63	11,7	0,0	não
4269	−93,55	29,78	47.887	1,42	2,1	10,0	sim
8138	−89,65	21,25	12.279	1,37	2,5	0,0	não
8390	−105,25	20,68	15.622	1,10	7,0	0,0	não
4809	−82,82	29,15	28.166	0,91	19,0	0,0	não
1002	−122,55	47,28	7.779	0,89	27,3	0,0	não
1954	−73,08	41,18	5.099	0,79	0,0	0,0	não
8260	−97,35	20,98	6.129	0,58	25,4	5,0	sim
2579	−122,52	38,12	4.947	0,53	29,8	0,0	não
3986	−88,58	30,38	20.996	0,53	2,5	7,0	sim
800	−122,22	48,02	7.574	0,48	14,8	0,0	não
1559	−124,18	43,72	23.920	0,43	28,1	5,0	sim
418*	−122,58	48,78	13.387	0,42	2,5	0,0	não
2875	−121,75	36,75	12.945	0,37	3,0	1,0	sim
3530	−79,95	32,78	8.207	0,36	0,0	0,0	não
3969	−86,22	30,42	12.178	0,28	5,5	16,0	sim
5307	−97,52	27,85	44.239	0,25	1,2	14,0	sim
4272	−93,45	29,78	6.965	0,24	4,3	19,0	sim
3906	−87,12	30,52	11.079	0,22	3,4	4,0	sim
7968	−87,95	21,55	7.047	0,20	5,4	0,0	não
5604	−82,12	26,95	5.004	0,19	22,6	0,0	não
3907	−87,02	30,52	5.612	0,16	13,0	4,0	sim
645	−122,38	48,25	8.574	0,12	10,7	0,0	não
5539	−97,38	27,18	11.505	0,11	0,0	13,0	sim
5181	−97,05	28,12	5.807	0,06	0,8	0,0	não
5636	−97,48	26,85	5.556	0,00	10,4	5,0	sim

* Bacia truncada pela borda da caixa. Fonte: elaborado pelo autor.